



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Dipartimento di Filologia Classica e Italianistica

Laurea Magistrale in Dati, Metodi e Modelli per le Scienze Linguistiche

Large Language Model e simulazione della cognizione umana: il caso della valutazione automatica di espressioni metaforiche

Jacopo Lombardi

Marzo 2026

Relatrice: Prof.ssa Marianna Marcella Bolognesi

Correlatore: Prof. Fabio Tamburini

Indice

1	Introduzione	1
1.1	Obiettivi	1
1.2	Struttura dell'elaborato	2
2	Large Language Model e cognizione umana	3
2.1	Breve storia della modellizzazione del linguaggio	3
2.1.1	I modelli stocastici	3
2.1.2	Il language modeling con le reti neurali	5
2.1.3	I transformer	7
2.2	Sistemi pensanti e non pensanti	11
2.2.1	Cognizione come manipolazione di simboli	12
2.2.2	Il symbol grounding problem	13
2.2.3	I modelli multimodali	17
2.2.4	Il significato sta nell'uso (comunicativo)	20
2.2.5	Un grounding alternativo	21
2.2.6	L'alternativa al grounding	23
2.3	Simulazione della psicologia umana	26
2.3.1	Perché sostituire?	27
2.3.2	Obiezioni alla sostituzione	28
2.3.3	Capacità effettiva di replicare i giudizi umani	36
2.3.4	Tiriamo le fila sulla questione	39
3	La metafora negli esseri umani e nei modelli di linguaggio	41
3.1	Cos'è una metafora?	41
3.1.1	Prospettive non cognitive	42
3.1.2	La teoria interattiva di Black: una prospettiva ibrida	45
3.1.3	Teoria della metafora concettuale	47
3.2	Le metafore non sono tutte uguali	53
3.3	Esseri umani alle prese con le metafore	55

3.3.1	Comprensione	55
3.3.2	Valutazioni semantiche	58
3.4	LLM alle prese con le metafore	61
3.4.1	Comprensione	61
3.4.2	Valutazioni semantiche	64
4	Esperimento: generazione di giudizi semantici sulle metafore	67
4.1	L’esperimento in questione e i lavori correlati	67
4.2	Obiettivi e ipotesi	68
4.3	Metodi	69
4.3.1	Datasets	69
4.3.2	Modelli	71
4.3.3	Modalità di inferenza	72
4.3.4	Prompt	73
4.3.5	Metodologie a confronto	74
4.4	Risultati	75
4.4.1	Analisi dei dati	75
4.4.2	Studio di sostituzione	83
4.5	Discussione	87
4.6	Limitazioni	91
4.6.1	Disomogeneità degli stimoli	91
4.6.2	‘Task leakage’	91
4.6.3	Impossibilità di confrontare l’accordo tra gli annotatori	92
4.6.4	Problemi di memoria	92
4.7	Direzioni future	92
5	Conclusioni	93

Capitolo 1

Introduzione

Il linguaggio può essere considerato una delle massime espressioni della cognizione umana, o quantomeno il più raffinato, complesso e duttile tra i sistemi di comunicazione che gli esseri umani abbiano a disposizione (Berruto et al.; 2011). La capacità di comprendere e articolare una lingua è innata nell'uomo e, nella forma in cui la conosciamo, esclusiva della sua specie. Tuttavia, quest'ultima affermazione sta vacillando, a seguito dei recenti avanzamenti scientifici, non tanto nell'ambito della biologia quanto in quello dell'intelligenza artificiale.

Negli ultimi anni infatti abbiamo assistito, e tutt'ora assistiamo, alla crescita esponenziale del fenomeno dei *Large Language Model* (LLM), sistemi di intelligenza artificiale basati su reti neurali e sviluppati tramite machine-learning. Tali sistemi sono dotati di una conoscenza puramente statistica del linguaggio umano nella sua forma scritta, ma la loro competenza linguistica sta crescendo sempre di più e in modo apparentemente inarrestabile. L'interazione con un LLM (es: ChatGPT, Gemini) è ormai divenuta pratica diffusa, se non quotidiana, e sempre più spesso questi sistemi riescono a sostenere conversazioni che, per fluidità e coerenza, risultano difficilmente distinguibili da quelle umane.

In questo contesto diventa quindi centrale valutare in modo rigoroso se, e in quale misura, i modelli di linguaggio abbiano effettivamente raggiunto la competenza linguistica umana. Nella ricerca linguistica è già attivo un filone di studi che mira ad analizzare il funzionamento di questi sistemi e a misurarne in modo sistematico le prestazioni. Una delle finalità di questa linea di ricerca è anche quella di valutare la possibilità di impiegarli, in specifici contesti sperimentali, come sostituti dei partecipanti umani nello studio degli aspetti linguistici della cognizione.

1.1 Obiettivi

Il presente elaborato ha come obiettivo principale proprio quello di contribuire al dibattito sulla possibilità di automatizzare la raccolta di giudizi semantici in ambito

psicolinguistico. A questo scopo, dopo aver delineato il quadro teorico di riferimento e i principali risultati empirici presenti in letteratura, verranno discussi gli esiti di un esperimento in cui si replicheranno i giudizi dati dagli esseri umani in un rating task su espressioni metaforiche. In particolare, ci avvaleremo di metafore italiane tratte dal Figurative Archive (Bressler et al.; 2026), i cui rating verranno replicati mediante due modelli della famiglia LLaMA (LLaMa-3.3-70B e LLaMa-3.1-8B), applicando e confrontando diverse metodologie di generazione dei giudizi. I dati sintetici saranno quindi messi in correlazione con quelli umani e analizzati nelle loro proprietà statistiche. Infine, verrà condotto uno studio di sostituzione volto a verificare se, e in quale misura, le conclusioni sulle relazioni tra le variabili cambino quando ai dati umani si sostituiscono quelli generati dal modello.

Parallelamente all’obiettivo di ricerca principale, si esploreranno vari altri aspetti riguardanti la competenza linguistica dei modelli di linguaggio e la loro possibilità e capacità effettive di emulare la psicologia umana, al punto da produrre rappresentazioni o comportamenti verbali indistinguibili da quelli umani.

1.2 Struttura dell’elaborato

Il lavoro si articolerà in tre capitoli, seguiti da una conclusione:

- Capitolo 2, dedicato a un’introduzione ai modelli di linguaggio, con particolare attenzione alle loro potenzialità nell’implementare, o quantomeno nel simulare, il pensiero umano;
- Capitolo 3, incentrato sul fenomeno della metafora, analizzato in riferimento sia alla cognizione umana sia all’elaborazione artificiale del linguaggio;
- Capitolo 4, in cui verrà presentato l’esperimento;
- Conclusione, che tirerà le fila del discorso mettendo in relazione i risultati dell’esperimento con gli aspetti teorici e i dati sperimentali illustrati nei capitoli precedenti.

Capitolo 2

Large Language Model e cognizione umana

In questo primo capitolo ci occuperemo diffusamente dei large language model: ne verranno innanzitutto chiarite le origini e il funzionamento; dopodiché ci si chiederà se tale funzionamento ci legittimi ad attribuire loro un pensiero; infine si discuterà se e in che misura la loro capacità di emulare il comportamento verbale umano possa renderli dei buoni soggetti nella ricerca psicologica e psicolinguistica.

2.1 Breve storia della modellizzazione del linguaggio

Il *Language Modeling* emerge come un paradigma fondamentale nell'ambito dell'elaborazione automatica del linguaggio naturale. Consiste nel catturare e rappresentare le distribuzioni di probabilità associate alle sequenze linguistiche osservate, col fine di ottenere un modello statistico della forma di una lingua. Un tale modello può poi essere usato per generare sequenze testuali ben formate e plausibili, basando le proprie previsioni su calcoli probabilistici rigorosi. In termini formali, un modello linguistico assegna una probabilità a una sequenza di parole, riflettendo la sua verosimiglianza all'interno di una determinata lingua.

2.1.1 I modelli stocastici

Storicamente, i primi sistemi sviluppati per il modeling delle lingue si fondavano sul concetto di probabilità condizionata: data una sequenza di parole precedenti, il modello stimava la probabilità della parola successiva assumendo un contesto di lunghezza finita. Questa assunzione ha portato allo sviluppo dei cosiddetti modelli a *n-grammi*, nei quali la probabilità di una parola dipende esclusivamente dalle n parole precedenti (Zhao et al.; 2023). Sebbene tali modelli abbiano rappresentato un importante passo avanti per applicazioni come il riconoscimento vocale e la traduzione automatica, essi soffrono di limitazioni intrinseche, tra cui l'incapacità di catturare dipendenze a lungo

raggio e la rapida crescita combinatoria dello spazio delle sequenze possibili. Inoltre, nel quadro dei modelli stocastici tradizionali, il significato delle parole non veniva considerato in maniera esplicita. Al più, esso poteva ‘emergere’ implicitamente come effetto collaterale delle co-occorrenze tra termini all’interno delle sequenze osservate, senza tuttavia essere direttamente rappresentato o utilizzato nel processo di predizione. In altri termini, tali modelli operavano esclusivamente a livello superficiale della forma linguistica, ignorando una formalizzazione esplicita della semantica, che risultava pertanto non modellizzata né controllabile.

A partire dagli anni Novanta, si assiste a un cambiamento di paradigma sostanziale, con l’introduzione di modelli in cui il significato viene rappresentato all’interno di uno spazio geometrico continuo. In questo contesto, le parole e, più in generale, le unità linguistiche vengono trattate come vettori in uno spazio a dimensionalità finita, consentendo di catturare relazioni semantiche e analogie attraverso operazioni algebriche. Il processo di vettorializzazione del significato affonda le proprie radici nella semantica distribuzionale e, più in generale, nella sua ipotesi fondamentale, secondo la quale il significato di una parola può essere inferito dai contesti in cui essa compare.

Questa ipotesi, spesso sintetizzata nell’adagio *‘you shall know a word by the company it keeps’* (Firth; 1962), ha fornito il fondamento teorico per lo sviluppo di modelli capaci di apprendere rappresentazioni semantiche a partire da grandi collezioni di testi non annotati. Tali rappresentazioni hanno progressivamente permesso di integrare informazioni semantiche all’interno dei modelli linguistici, favorendo una transizione da approcci puramente statistici a modelli in grado di combinare aspetti formali e semantici del linguaggio naturale. Resta comunque il fatto che le informazioni semantiche delle parole sono inferite a partire da informazioni formali che riguardano la loro distribuzione.

I vettori di parola costituiscono dunque rappresentazioni del significato inserite all’interno di uno spazio geometrico. Tuttavia, la natura dell’informazione in essi contenuta e le modalità attraverso cui è appresa hanno subito una notevole evoluzione nel corso del tempo. In una prima fase, infatti, il significato delle parole veniva codificato mediante rappresentazioni vettoriali sparse, ad alta dimensionalità e basate puramente su conteggi delle parole. Tra i metodi *count-based* più diffusi, troviamo i *one-hot vectors*. Si tratta di vettori la cui dimensionalità coincide con il numero di parole totali contenute nel vocabolario. In essi, tutti gli elementi assumono valore nullo ad eccezione di una singola componente, posta uguale a uno, che identifica univocamente la parola rappresentata dal singolo vettore (Jurafsky and Martin; 2026). La rappresentazione consente di distinguere in maniera non ambigua le diverse unità lessicali, ma risulta completamente priva di informazione semantica: tutte le parole sono tra loro equidistanti nello spazio vettoriale perciò non è applicabile alcuna nozione di similarità semantico-geometrica.

Inoltre, la natura estremamente sparsa di questi vettori comporta evidenti inefficienze computazionali e limita fortemente la capacità dei modelli di generalizzare a contesti non osservati. Di conseguenza, i *one-hot vectors* si prestano esclusivamente a fungere da

identificatori simbolici, piuttosto che da vere e proprie rappresentazioni del significato linguistico.

Queste limitazioni hanno progressivamente motivato lo sviluppo di rappresentazioni vettoriali dense e a dimensionalità ridotta, in cui l'informazione semantica viene distribuita lungo tutte le componenti del vettore. Questi approcci hanno segnato una svolta fondamentale nel language modeling, ponendo le basi per l'introduzione degli *word embedding* e per l'integrazione efficace della semantica nei modelli neurali del linguaggio.

2.1.2 Il language modeling con le reti neurali

La ricerca sulla modellizzazione del linguaggio ha raggiunto un punto decisivo con l'intuizione che gli embedding potessero essere appresi mediante una rete neurale, ovvero attraverso un sistema di machine learning¹ *self-supervised* (il modello si procura da solo le *label* per il training).

In questo nuovo paradigma, le rappresentazioni vettoriali non sono più derivate direttamente da conteggi globali di co-occorrenza, ma vengono apprese come parametri del modello neurale durante l'addestramento su compiti predittivi basati sul contesto.

Ma cos'è esattamente una rete neurale? Si tratta di una struttura computazionale ispirata al funzionamento e all'organizzazione delle cellule del sistema nervoso biologico. Se nel caso degli esseri umani queste sono costituite da neuroni interconnessi attraverso sinapsi, capaci di trasmettere segnali elettro-chimici, nel caso dei modelli artificiali questa dinamica viene approssimata mediante unità matematiche elementari connesse tra loro, dette neuroni artificiali.

Le reti neurali sono organizzate in strati di neuroni, all'interno dei quali avvengono le computazioni: lo strato di input, che riceve i vettori di partenza; uno o più strati nascosti (o *hidden layers*), nei quali l'informazione viene progressivamente trasformata attraverso combinazioni lineari e funzioni di attivazione non lineari; e infine lo strato di output, che produce il risultato finale del modello in funzione del compito considerato.

Gli strati nascosti svolgono un ruolo centrale, in quanto permettono alla rete di apprendere rappresentazioni intermedie sempre più astratte dei dati di ingresso. All'aumentare della profondità della rete, ovvero del numero di strati nascosti, cresce la capacità espressiva del modello, rendendo possibile l'apprendimento di strutture latenti di elevata complessità.

Ciascun neurone della rete prende in input un insieme di valori numerici, su cui ven-

¹ Branca dell'intelligenza artificiale che consiste nel far generalizzare ad un sistema il criterio per cui certi input corrispondono a certi output in un dato dominio. Nel caso delle reti neurali, l'apprendimento automatico è implementato attraverso l'algoritmo di *Backpropagation*, che aggiusta i pesi della rete (inizializzati randomicamente) affinché sia minimizzata la differenza fra l'output predetto e quello effettivo.

gono eseguiti calcoli tali per cui l'informazione possa essere combinata e trasformata in modo significativo. In particolare, a ciascun input viene associato un peso w che ne modula l'importanza relativa; i valori pesati vengono quindi sommati tra loro e, spesso, combinati con un termine di bias b . Il risultato di questa operazione lineare viene successivamente passato attraverso una funzione di attivazione non lineare, che determina l'output finale del neurone (Jurafsky and Martin; 2026). Quindi, dato un vettore x in input alla rete, l'output risultante delle elaborazioni eseguite all'interno di uno strato di una rete neurale è pari a:

$$\sigma(\mathbf{W}\mathbf{x} + \mathbf{b})$$

Nell'elaborazione agiscono quindi il vettore di input, i pesi, i bias e la funzione di attivazione σ . Quest'ultima svolge un ruolo cruciale nel determinare il comportamento del neurone artificiale: analogamente a quanto avviene nel neurone biologico, in cui l'attivazione dipende dal superamento di una soglia legata alle differenze di polarizzazione ai due lati della membrana cellulare, essa stabilisce se e in quale misura il neurone debba contribuire alla computazione complessiva.




Figura 2.1: Neurone naturale e neurone artificiale (Krenker et al.; 2011)

Nel 2013, con il paper di (Mikolov et al.; 2013), vengono presentate due architetture basate su reti neurali, che insieme costituiscono il pacchetto Word2Vec: CBOW (*Continuous Bag-Of-Words*) e SkipGram. Queste, contrariamente alle reti neurali Feed-Forward presentate da (Bengio et al.; 2003), sono state progettate con il solo compito di rappresentare i significati tenendo in considerazione i contesti in cui le parole compaiono.

In particolare, i modelli neurali vengono addestrati a prevedere una parola a partire dal suo contesto, oppure, inversamente, a predire il contesto a partire dalla parola centrale. Durante questo processo di apprendimento, i pesi della rete, e in particolare quelli associati allo strato di embedding, vengono aggiornati in modo tale da riflettere le regolarità sintattiche e semantiche presenti nei dati. Di conseguenza, parole che comparivano in contesti simili tendono ad assumere rappresentazioni vettoriali vicine nello spazio geometrico, rendendo possibili calcoli algebrici di similarità tra le parole.

Sebbene si trattasse di un'innovazione che ha segnato un cambio di paradigma nell'elaborazione del Natural Language Processing (NLP), gli embedding generati dalle architetture di Word2Vec presentavano un limite intrinseco: erano statici. Ogni termine




Figura 2.2: Architettura CBOW e SkipGram. Come si evince dalla struttura, CBOW predice una parola dato il suo contesto, SkipGram predice il contesto data una parola. (Mikolov et al.; 2013)

del vocabolario, infatti, era associato a un unico vettore fisso indipendentemente dalle sue diverse accezioni e dal contesto in cui compariva. Questo comportamento non teneva conto del comune fenomeno della polisemia, per cui a una stessa forma sono associati significati differenti. Il modello collapsava i diversi significati che la parola poteva assumere in un unico vettore. la parola "penna", ad esempio, riceveva veniva rappresentata dal solito vettore, sia che il contesto ne suggerisse il significato di "strumento di scrittura" che quello di "elemento del manto degli uccelli". Dovendo tener conto di entrambi i significati, il vettore risultante finiva per rappresentare una sorta di media semantica di tutti i contesti osservati. Quello degli embedding statici è un limite che sarebbe stato superato solo con l'avvento dei Contextualized Word embedding (Zhao et al.; 2023).

2.1.3 I transformer

Il noto paper "*Attention is all you need*" (Vaswani et al.; 2017) segna una svolta definitiva nel panorama del Language Modeling. Il meccanismo di attenzione introdotto da Vaswani e colleghi costituisce la spina dorsale dell'architettura rivoluzionaria che porterà le prestazioni dei modelli linguistici a livelli senza precedenti, ponendo le basi tecnologiche per lo sviluppo dei moderni Large Language Model.

L'architettura proposta, denominata Transformer, pur mantenendo delle componenti già note nei suoi blocchi principali, encoder e decoder, abbandona completamente l'elaborazione sequenziale dei dati a favore di un approccio basato interamente sul meccanismo di *Attention*. Questa innovazione consente al modello di pesare l'influenza di ogni parola su tutte le altre all'interno della frase simultaneamente, indipendentemente dalla loro distanza posizionale. Ciò risolve due problemi storici del NLP: la difficoltà nel catturare dipendenze a lungo raggio (*long-range dependencies*) e l'impossibilità di parallelizzare il training, permettendo così un addestramento molto più rapido ed

efficiente su grandi moli di dati.

Ma in cosa consiste a livello pratico il meccanismo di Attention? In che modo il sistema può ‘fare attenzione’ a certe parole nell’elaborarne un’altra?

Nel meccanismo di Attention, gli embedding iniziali dei token² vengono trasformati tramite proiezione lineare in tre nuovi vettori: *query*, *key* e *value*. A questo punto, il vettore query di ciascun embedding interagisce tramite prodotto scalare con i vettori key di tutti gli embedding della sequenza. Il risultato del dot product fornisce una misura di compatibilità tra i due vettori: maggiore è la similarità tra una query e una key, maggiore sarà il contributo del token associato a quella key (attraverso la corrispondente value) alla rappresentazione contestualizzata del token associato alla query. Questi punteggi, infatti, vengono poi normalizzati in base alla dimensionalità delle key e trasformati con una funzione softmax, così da ottenere pesi che sommano a 1. Tali pesi sono quindi utilizzati per calcolare una combinazione pesata dei value di tutti i token. Il risultato di queste somme pesate costituisce la nuova rappresentazione contestualizzata di ciascun token, che viene infine combinata con l’embedding di partenza tramite una connessione residua. (Hussain et al.; 2024)

Chiarito il funzionamento dell’Attention, possiamo illustrare i blocchi principali in cui si articola l’architettura Transformer, i quali si distinguono proprio per l’implementazione specifica del meccanismo di attenzione. Mentre l’encoder impiega la *Multi-Head Self-Attention* per elaborare le relazioni tra tutte le parole della sequenza, il decoder utilizza una variante denominata *Masked Multi-Head Attention*, necessaria per impedire al modello di ‘vedere’ i token futuri durante la fase di addestramento.

L’encoder è costituito da una pila di strati identici che elaborano iterativamente i dati di input. Ogni strato di encoder è composto da due sottomoduli: un meccanismo di attenzione e una rete *feed-forward* (FFN), entrambi seguiti da una connessione residua e da uno strato di normalizzazione (*Layer Normalization*).

Nello specifico, l’encoder riceve in input gli embedding della sequenza sorgente sommati ai rispettivi vettori di posizione (*Positional Encodings*), un’altra novità introdotta per tenere traccia della posizione di ogni parola rispetto alle altre mentre vengono elaborate in parallelo.

Strato dopo strato, l’encoder trasforma questi input in una sequenza di embedding contestualizzati attraverso la Multi-Head Attention, codificando non solo il significato dei singoli termini, ma anche le relazioni sintattiche e semantiche globali rispetto a tutti gli altri elementi della frase. Infatti, il suo meccanismo di Attention è detto multi-head proprio perché si articola in più dispositivi attenzionali, ognuno dei quali impara nel

² Le unità discrete minime in cui il testo grezzo viene segmentato per essere trasformato in input numerico. Nelle moderne architetture basate su Transformer, questi non coincidono necessariamente con le parole linguistiche intere (come avveniva nei primi approcci bag-of-words), ma sono spesso costituiti da frammenti di parole (*sub-token*) o addirittura singoli caratteri




Figura 2.3: Architettura Transformer (Vaswani et al.; 2017)

training a cogliere aspetti diversi dell'input.

Se la funzione dell'encoder sta nel 'capire' l'input ed elaborarlo creando rappresentazioni esaurienti, quella del decoder è generare un testo coerente sulla base di questa elaborazione. Sebbene strutturalmente simile all'encoder, in quanto composto da strati di attenzione e reti neurali feed-forward seguiti da normalizzazione, presenta una differenza cruciale nella gestione dei flussi di dati.

La natura autoregressiva del modello è garantita dal meccanismo di Masked Self-Attention. Questa componente applica una *maschera causale* che oscura le posizioni successive a quella corrente, impedendo al modello di accedere all'informazione contenuta nei token futuri. A livello pratico, la masked self-attention fa sì che i pesi attenzionali associati ai token successivi nella sequenza siano azzerati (o resi ininfluenti). In questo modo, il calcolo dell'attenzione viene vincolato a dipendere esclusivamente dal contesto precedente, costringendo il modello a basare ogni predizione solo sulla porzione di sequenza già elaborata, simulando correttamente il processo temporale di generazione.

Oltre a processare i token che ha già generato, il decoder recupera e integra le rappresentazioni prodotte dall'encoder attraverso un secondo meccanismo specifico, denominato *Cross-Attention*. Così facendo, il modello mette in relazione lo stato attuale della generazione con l'intera sequenza di input originale. Questo permette al decoder di focalizzare l'attenzione, parola per parola, sulle parti della frase di partenza che sono più rilevanti per predire il token successivo, ignorando quelle superflue in quel preciso momento. In sostanza, questo meccanismo funge da ponte tra la comprensione dell'input e la generazione dell'output, garantendo che ogni nuova parola sia coerente non solo con la frase che si sta costruendo, ma anche con il significato del testo in input. Il processo di generazione viene innescato da un token speciale di avvio sequenza, indicato come `< bos >` (*Beginning Of Sentence*). Una volta ricevuto l'input iniziale, il decoder elabora la rappresentazione interna integrando le informazioni contestuali prodotte dall'encoder (tramite la *Cross-Attention*), per poi predire il primo token effettivo della sequenza target. In accordo con la natura autoregressiva del modello, l'output generato viene reintrodotta in ingresso al decoder nel passo successivo, concatenandosi di fatto all'input nella memoria del sistema. Questo ciclo iterativo prosegue fino a quando il modello non produce il token di terminazione `< eos >` (*End Of Sequence*), segnalando la conclusione della frase.

In conclusione, notiamo che la struttura modulare del Transformer permette che le sue componenti possano essere usate in autonomia. In particolare, per il task di generazione di testo, è ormai diffusissima l'architettura decoder-only, priva di un encoder che elabori preliminarmente l'input e priva anche del meccanismo di cross-attention (Cai et al.; 2021). Questo design caratterizza infatti la maggior parte dei cosiddetti Large Language models (LLM), a partire dalla famiglia dei modelli GPT (Achiam et al.; 2023) e LLaMa (Touvron et al.; 2023).

Ciò che motiva l'uso di un'architettura decoder-only per la text-generation è principalmente l'allineamento tra il task in questione e quello su cui è addestrato il modello come modulo del Transformer, ovvero predire il token successivo dato il contesto precedente (*causal language modeling*) (Wang et al.; 2022).

Dal punto di vista computazionale, inoltre, i modelli decoder-only risultano più efficienti in fase di inferenza grazie al meccanismo di masked self-attention: dato che ogni posizione può attendere solo ai token precedenti, le matrici key e value dei token già elaborati possono essere memorizzate e riutilizzate nei passi successivi di generazione. Questo evita di ricalcolare ripetutamente tali proiezioni, riducendo il costo computazionale e rendendo la generazione più rapida (Wang et al.; 2022).

2.2 Sistemi pensanti e non pensanti

“Io credo che la domanda iniziale, «Le macchine sono in grado di pensare?», sia troppo insensata perché valga la pena discuterne. E tuttavia, credo anche che alla fine di questo secolo l’uso delle parole e l’opinione diffusa delle persone colte avranno subito un cambiamento tale che si potrà parlare di macchine che pensano senza aspettarsi di essere contraddetti.” (Turing; 1969)

All’inizio degli anni ‘50, Alan Turing, matematico e logico considerato uno dei padri dell’informatica, fa questa previsione profetica nel suo articolo "Computing machinery and intelligence". Ad oggi, infatti, la tecnologia dietro ai modelli di linguaggio è arrivata ad uno sviluppo tale che di queste architetture computazionali prive di coscienza non si fatica a dire che pensino, ingannino o interpretino. Questa antropomorfizzazione non è dovuta solo ad una tendenza naturale dell’uomo ad attribuire caratteristiche umane alle cose per spiegarne gli effetti, ma è pesantemente motivata da un numero esorbitante di studi in cui le macchine dimostrano la loro strabiliante e crescente competenza in vari ambiti del pensiero umano: generano testo grammaticalmente corretto; hanno una comprensione delle parole tale da permettere ottime performance in task di natural language processing come sentiment analysis, text-classification, POS tagging, NER, traduzione; affrontano discretamente i ragionamenti aritmetici ed eccellono in quelli logici; generano risposte coerenti alle domande di un user umano (Chang et al.; 2024).

Nello stesso saggio già citato, Turing sostiene che una macchina può essere definita pensante nel momento in cui il suo comportamento appare indistinguibile da quello di un umano. Il celeberrimo test di Turing, infatti, risulta superato dalla macchina se questa riesce ad emulare il comportamento verbale umano in modo tanto accurato che un suo eventuale interlocutore umano penserebbe di avere a che fare con un’altra persona (Turing; 1969). Quello che Turing sembra suggerire è che ha senso attribuire pensiero ad una macchina se questa fa delle cose che se fossero fatte da un umano non esiteremmo a riconoscere come il prodotto di un’elaborazione cognitiva a tutti gli effetti. Una prospettiva del genere, che pone il focus sulla performance, è la stessa che ci fa dire che l’aereo *vola* in cielo e che la macchina *corre* lungo la strada. D’altra parte, se esistesse un robot in grado di gestire una palla in movimento, di fare buoni passaggi, di segnare molti gol e in generale di muoversi in un campo da calcio rispettando tutte le regole del gioco, diremmo che questo robot *sa* giocare a calcio, e non che in realtà non sa niente e si limita a simulare un umano che gioca a calcio (Turing and Marconi; 2025). Tuttavia, osservare esclusivamente il comportamento esteriore per decidere se due cose sono la stessa cosa può essere limitante: gli aerei non volano come gli uccelli e le macchine di certo non corrono come i cavalli. Se pure gli arti del robot-calciatore descritto sopra funzionano nella stessa maniera di quelli di un calciatore umano, non possiamo star certi che il modo in cui il robot sceglie se fare un assist o tirare direttamente in rete implementa gli stessi processi che avverrebbero nella testa di un

umano.

Prima di poter proseguire è allora necessario capire in cosa consista la nostra cognizione e di che natura siano i suoi processi.

2.2.1 Cognizione come manipolazione di simboli

Nel 1975, il filosofo della mente Jerry Fodor conia l'espressione "language of thought", e con essa un concetto che diventerà fondamentale per l'approccio cognitivista alla psicologia, in cui la mente umana è concepita come un sistema di simboli. Il sistema di simboli per eccellenza, infatti, è il linguaggio verbale umano, poiché consiste nella composizione di forme significanti (i simboli) attraverso regole sintattiche dettate dalla grammatica della lingua. Analogamente, i processi cognitivi consisterebbero nella combinazione e nella manipolazione di rappresentazioni mentali secondo regole predefinite. Il pensiero avrebbe una vera e propria sintassi e in questo senso si articolerebbe come un linguaggio.

Caratteristica determinante della cognizione così definita è la sua indipendenza dal supporto di implementazione: proprio come i simboli del linguaggio possono essere realizzati in modo variabile (possono avere forma sonora, scritta, gestuale), allo stesso modo i simboli del pensiero, svolgerebbero la stessa funzione se fossero realizzati altrimenti che come stati di un cervello umano. E' su questa premessa che si fonda la possibilità di creare un'intelligenza artificiale, in cui cioè stati simbolici analoghi a quelli del pensiero umano sono realizzati da stati materiali di un sistema non organico (es: una scheda forata, lo stato del passaggio di corrente in un circuito elettrico etc.). A sua volta, il florido sviluppo di sistemi artificiali di questo tipo ha dimostrato empiricamente che la manipolazione di simboli secondo regole predefinite può effettivamente generare comportamenti cognitivi complessi (Harnad; 1990). Di fatto, il paradigma della cognizione come computazione di simboli secondo regole programmate consiste in un'operazione concettuale che più che umanizzare le macchine, reifica gli esseri umani e ne meccanizza i comportamenti mentali.

Ora, se un qualsiasi software può essere annoverato a pieno titolo tra i sistemi di manipolazione di simboli, così non è per le reti neurali, che sembrano seguire una logica diversa da quella cognitivista. Il modello di cognizione che realizzano le reti neurali è quello proposto dal connessionismo: cognizione non come manipolazione rule-based di stati discreti, ma come pattern di attivazione in una rete di unità computazionali elementari collegate le une alle altre da interconnessioni che possono essere positive o negative e più o meno intense. I pattern di attivazione e i pesi delle connessioni mutano ad ogni nuovo input, e si aggiustano sulla base delle esperienze pregresse allo scopo di produrre output sempre più accurati (Harnad; 1990).

Non possiamo però trascurare una differenza dirimente tra le reti neurali artificiali e

quelle naturali, ovvero il fatto che queste ultime sono in continua evoluzione, mentre le prime, una volta concluso l'addestramento, smettono di essere dei sistemi dinamici: sono di fatto dei complessissimi sistemi rule-based, che manipolano gli input secondo regole determinate una volta per tutte, per quanto difficilmente rintracciabili e interpretabili. Non solo, le reti neurali presentano almeno altre due caratteristiche tipiche dei sistemi simbolici: è possibile individuare stati discreti nella loro elaborazione degli input e tali stati sono causalmente collegati al loro output. In particolare, alcuni studi hanno mostrato che le reti neurali imparano a rappresentare certe feature linguistiche attraverso l'attivazione di una specifica parte della rete se non addirittura di singoli neuroni. Sono state trovate porzioni di rete circoscritte che codificano in modo sistematico espressioni linguistiche relative a concetti semantici a prescindere dalla loro formulazione, come coordinate di tempo cronologico (es: "between 15:00 and 19:00", "19:00 pm Friday until", etc.) o relazioni di appartenenza a un intero (es: "one of the team", "among the top ten", etc.). Addirittura, altri studi ancora riportano come in certi modelli di linguaggio la rappresentazione di informazioni grammaticali astratte come quelle sul genere grammaticale e sul tempo verbale sia affidata allo stato di attivazione di singoli neuroni. Tuttavia, la presenza di rappresentazioni apparentemente simboliche nei modelli neurali potrebbe essere un fenomeno del tutto contingente. Affinché si possa dire che una rete neurale esibisce comportamenti analoghi a un sistema simbolico, le sue rappresentazioni discrete devono *causare* in modo sistematico output coerenti. Sforzi sperimentali sono stati versati anche in questo senso, dimostrando che manipolando l'attivazione dei layer che sembrano custodire la rappresentazione di certi concetti linguistici, l'output cambia proprio in riferimento all'ambito di questi concetti. Ad esempio, intervenendo manualmente sui pattern di attivazione che sembrano codificare l'informazione circa il ruolo sintattico dei token, si fa sì che la rete tratti come verbo quello che prima della manipolazione trattava come nome (Pavlick; 2023).

Fin qui si è visto che il modello cognitivista della mente permette di poter concepire le operazioni cognitive come processi implementabili da sistemi simbolici artificiali, tra i quali in un certo senso possiamo annoverare anche le reti neurali. Tuttavia, nel prossimo paragrafo vedremo come il fatto che questi sistemi possano avere un 'comportamento cognitivo' non dissimile da quello umano, non è garanzia del fatto che stiano pensando nel senso in cui pensano gli esseri umani.

2.2.2 Il symbol grounding problem

Se possiamo effettivamente concepire molte delle nostre operazioni mentali come una manipolazione di simboli, è pur vero che c'è una differenza qualitativa tra i simboli manipolati dall'uomo e quelli manipolati dalla macchina. Solo i simboli che stanno nella mente umana sono dotati di intenzionalità, intesa come la proprietà di avere un contenuto semantico, di riferirsi a qualcosa che va oltre il livello simbolico.

Il senso di questa differenza fondamentale è reso evidente dal celebre *Chinese Room Argument* (Searle; 1980). Si tratta di un esperimento mentale ideato dal filosofo statunitense John Searle, il quale si immagina di essere in una stanza in cui c'è solo un tavolo con sopra una penna, dei fogli bianchi e un grosso libro, in cui in ogni pagina sono riportate delle corrispondenze tra certi caratteri cinesi o certe sequenze di caratteri e altri caratteri o altre sequenze. Da una fessura nel muro entrano dei fogli con su scritti dei caratteri: Searle, che non sa il cinese, sa solo che deve ritrovare questi segni nel libro, scrivere su un foglio i segni a cui essi corrispondono secondo la regola indicata, e infilare questo foglio in una fessura nella parete opposta.




Figura 2.4: Rappresentazione della “stanza cinese”

Ora, dal punto di vista di un parlante cinese che sta fuori dalla stanza e che continua a inserire sequenze di parole in input e ricevere parole coerenti in output, chi sta dentro la stanza sa parlare cinese. Tuttavia, Searle non sa il cinese, e tra l'altro non ha nemmeno la possibilità di impararlo da dentro la stanza. Il fatto che dall'esterno, sembra che la persona nella stanza sappia parlare cinese in modo indistinguibile da un vero parlante dipende solo dalla bontà e dalla sofisticatezza delle regole di corrispondenza riportate nel libro. Il Searle immaginario dentro la stanza non sta agendo diversamente da un qualsiasi computer (inteso come sistema simbolico): manipola simboli secondo regole predeterminate che si basano puramente sulle caratteristiche formali di tali simboli, rimanendo del tutto cieco al loro significato. Se, quindi, non siamo disposti a riconoscere che in queste condizioni Searle capisca il cinese, allora non possiamo affermare che lo faccia una macchina (Harnad; 1990).

Searle è tra chi crede che l'identità di due cose non dipenda solo dall'indistinguibilità delle loro performance ma anche da quella del loro funzionamento. L'obiettivo di Searle, infatti, non è dimostrare che una macchina non potrà mai superare il test di Turing, ma che se anche lo superasse, questo non sarebbe garanzia del fatto che sta effettivamente pensando. L'esperimento della stanza cinese, infatti, inficia la validità dell'argomento che sta alla base del test di Turing a cui si è fatto riferimento già nel paragrafo precedente: se una macchina ha un comportamento tale che se fosse un umano ad averlo non esiteremmo a ritenerlo un prodotto della cognizione, allora questa

macchina è effettivamente dotata di cognizione. Nel caso della situazione descritta dall'esperimento mentale, però, l'argomento si ritorce contro se stesso, perché proprio immaginando un essere umano che fa quello che fa una macchina arriviamo a concludere che il primo non sta pensando: di conseguenza nemmeno la seconda lo sta facendo.

L'argomento della stanza cinese pone il cosiddetto problema del *symbol grounding* (Harnad; 1990): i sistemi simbolici manipolano ciecamente i simboli senza attribuire loro un significato, poiché non sono sensibili all'informazione referenziale (le connessioni dei simboli con i loro riferimenti nella realtà), ma solo a quella formale (le connessioni dei simboli tra loro).

Se anche volessimo salvare le reti neurali dall'argomento della stanza cinese, in quanto sistemi connessionisti e non simbolici, ci scontreremmo comunque col *symbol grounding problem* nella formulazione che propone (Harnad; 1990). Immaginiamo in questo caso di voler imparare il cinese, e di avere a disposizione solo un dizionario cinese-cinese, in cui quindi il significato di ogni parola è definito con altre parole cinesi. Finiremmo per passare da un simbolo privo di significato all'altro senza mai poter arrestare questa dinamica e afferrare a cosa si riferiscono i caratteri. In realtà, affinché questo scenario possa farci capire al meglio il rapporto tra un LLM e gli embedding che manipola, dobbiamo renderlo ancora più estremo. Immaginiamo, cioè, di dover imparare il cinese come prima lingua potendoci servire solo del solito dizionario. E' evidente che non potremmo fondare il significato dei simboli se non su altri simboli insensati, i quali a loro volta fonderebbero il loro significato su altri, e così via.

Per i modelli di linguaggio, infatti, la corsa al grounding dei simboli linguistici non ha un punto di arresto: sono costretti a doversi fare un'idea di cosa significhi una parola osservando le parole con cui compare solitamente, e a capire il significato di queste ultime sempre considerandone il contesto usuale, di fatto rimandandone all'infinito la definizione. Ne deriva un sistema autoportante in cui il significato distribuzionale di ogni parola determina ed è determinato da quello di tutte le altre. Tuttavia, si tratta di un sistema del tutto sganciato da quello dei referenti reali. Ma anche accantonando l'assenza di connessioni referenziali, sorge una questione ulteriore: il linguaggio umano e le sue caratteristiche statistiche non costituiscono una buona mappa della realtà, poiché il fatto che gli esseri umani percepiscano il mondo fa sì che sia superfluo rendere espliciti nel linguaggio certi suoi aspetti. La frequenza di un'espressione, ad esempio, non corrisponde al livello di diffusione del suo referente nella realtà fisica, altrimenti dovremmo aspettarci che gli enti denotati dalla rarissima espressione "four-legged dog" siano pochissimi, mentre non è palesemente così (Bender and Koller; 2020).

Sembra dunque che condizione necessaria perché una macchina possa comprendere i significati sia l'essere dotata di *competenza referenziale*. Si tratta della stessa capacità che secondo il filosofo Hilary Putnam distingue il nostro sistema cognitivo da quello di un cervello attaccato ad un supercomputer che ne simula gli stimoli percettivi attraverso segnali elettrici (Turing and Marconi; 2025). Il cervello in questione è immerso in un

bagno biologico che lo tiene in vita e non entra in contatto con nessun elemento della realtà, ma esperisce le nostre stesse sensazioni: se volesse lasciar andare la testa (che non ha) all'indietro il computer produrrebbe gli input elettrici interpretabili con la sensazione corrispondente a quel gesto, e magari anche quelli grazie ai quali il cervello vedrebbe il cielo come se fosse davvero lì. Secondo Putnam se fossimo dei cervelli del genere non potremmo nemmeno dire di esserlo, poiché parlare di qualcosa vuol dire riferirci a questa cosa, implicando l'esistenza di una connessione non tra una parola e un impulso elettrico o un'immagine mentale, ma tra una parola ed un referente nel mondo reale. La parola "cervello" non si riferirebbe ai cervelli e l'espressione "bagno biologico" ai bagni biologici, né potremmo riconoscere un cervello o un bagno biologico se ci avessimo a che fare (Putnam; 1981). Analogamente, i vettori numerici che rappresentano le parole nei LLM non sono connesse a entità reali, non possono dirci niente sulle caratteristiche fisiche dei loro referenti, e dunque in nessun modo permettono di distinguere un'entità dall'altra.

Ma in definitiva, come fa la comprensione umana del linguaggio a non incorrere nel symbol grounding problem? Ovvero, come si implementa a livello cognitivo la competenza referenziale? La risposta sta nel rapporto fitto e inscindibile che lega la mente al corpo, e che costituisce l'idea centrale nel framework teorico della *Embodied cognition*. Affermatosi nelle scienze cognitive a partire dagli anni '80, si oppone alla prospettiva cognitivista che concepisce la mente come un calcolatore di informazioni astratte. Sempre più prove sperimentali si sono accumulate ad evidenza del fatto che la mente ha bisogno di un corpo per funzionare: proprio questa affermazione costituisce la premessa fondamentale della Embodied cognition (o Teoria della mente incorporata), secondo cui per capire il funzionamento della cognizione bisogna considerarla nel contesto della sua relazione con un corpo fisico che interagisce con un ambiente altrettanto fisico. (Wilson; 2002)

Gli esseri umani, infatti, imparano il linguaggio mentre esperiscono la realtà, in un'interconnessione costante tra significati delle parole, percezioni sensoriali ed esperienze motorie. Molti esperimenti neuro-cognitivi mostrano che questa interazione percettiva e motoria con la realtà risulta estremamente funzionale alla nostra facoltà di comprendere i significati. In particolare, gli studi in questione registrano il fenomeno della cosiddetta *embodied simulation*: quando sentiamo la parola "afferrare" il nostro cervello esibisce gli stessi pattern di attivazione neurale che si manifestano mentre compiamo l'azione corrispondente alla parola.

La modalità incarnata in cui gli esseri umani acquisiscono e comprendono il linguaggio è quindi ciò che permette ai significati di avere un fondamento, ovvero di risolvere il symbol grounding problem. Se è vero che per spiegarci il significato di una forma possiamo rifarci ad altre forme, in ultima istanza ci saranno sempre delle forme che costituiscono il punto di arresto di questa catena esplicativa: parole associate a stati mentali che viviamo in virtù dei nostri sensi e del nostro corpo, e grazie ai quali comprendiamo il significato non solo di queste parole, ma di tutte le altre che sono

definibili a partire da esse.

Un fatto sorprendente a questo proposito è che affinché un intero sistema lessicale acquisisca un senso per noi, è necessario provvedere al grounding referenziale di una sua frazione minima. L'analisi che (Vincent-Lamarre et al.; 2016) hanno condotto sui dizionari ha fatto emergere che per definire tutte le parole di una lingua basta un sottoinsieme di parole pari a meno del 10% del suo lessico. Il significato di queste parole consiste in concetti percettivi fondamentali, che da bambini impariamo ad associare alle etichette verbali della nostra lingua (es: connection, motion, space, exist, change)³. Se quindi non conosciamo una parola, possiamo comunque derivarne il significato dal contesto in cui appare, o farcelo spiegare con una definizione che tira in ballo altre parole; tuttavia queste tecniche non potrebbero funzionare se alla base non avessimo un insieme di parole dal significato elementare dalla cui conoscenza possiamo costruire quella di tutte le altre. E' come se la carica intenzionale di queste parole contagiasse quelle definibili a partire da esse.

2.2.3 I modelli multimodali

Nel paragrafo precedente è stato chiarito che ai modelli di linguaggio classici è precluso il grounding percettivo dei significati, poiché semplicemente non hanno un corpo e dei sensi che possono fornire loro le sensazioni da legare alle forme linguistiche. Esistono però anche i *Multimodal Large Language Model* (MLLM), che sono addestrati non solo su testo, ma anche su dati che afferiscono a modalità percettive umane (per il momento la vista e l'udito). Durante il loro training, elaborano stringhe di testo al fianco di immagini, video o audio, mettendo in comunicazione le varie modalità e quindi in teoria sviluppando delle rappresentazioni (embedding) dei token che siano integrate di informazioni percettive. Ci si può legittimamente chiedere, a questo punto, se questo tipo di modelli, che imparano ad associare parole a immagini o suoni, riescano a risolvere il problema del grounding e quindi a comprendere il linguaggio in un modo analogo agli esseri umani.

Proprio con lo scopo di indagare questa possibilità, (Lee et al.; 2025) hanno esaminato la performance di LLM, MLLM ed esseri umani in un task che prevedeva di valutare il significato percettivo di certe parole, ovvero quanto evocassero esperienze sensoriali di tipo visivo, uditivo, olfattivo, gustativo, tattile e interocettivo⁴. Test neuro-cognitivi preliminari dimostravano che le parole scelte per l'esperimento innescavano effettivamente l'attivazione delle aree cerebrali associate alle modalità sensoriali corrispondenti.

I risultati hanno mostrato che i modelli multimodali correlavano sempre meglio con i rating umani rispetto ai corrispettivi modelli text-only. La multimodalità dei dati di

³ Interessantemente, gli autori notano che una parte di questo set di parole ha un significato astratto, che però, per forza di cose, deve essere stato appreso attraverso l'esperienza concreta.

⁴ Ovvero la percezione dei propri organi interni (Lynott et al.; 2020)

training sembra quindi giovare alla capacità di un modello di emulare un umano nel task di rating percettivo.

Tuttavia, il fatto che i modelli multimodali siano più ‘bravi’ di quelli testuali a produrre rating simili non equivale a dimostrare che i modelli multimodali stiano fondando percettivamente i significati delle parole e che stiano agendo cognitivamente come gli esseri umani. Il motivo sta tutto nella natura del training multimodale stesso: elaborare insieme input afferenti a modalità diverse non porta il modello a imparare relazioni di denotazione o significanza fra un input testuale e uno visivo o sonoro. La logica dell’addestramento rimane sempre la stessa, ovvero far apprendere al modello relazioni distribuzionali fra gli input, a prescindere dalla loro natura. Il modello, ad esempio, impara a trattare in modo simile l’embedding della parola "mela" e l’embedding dell’immagine di una mela. Dal punto di vista della macchina, infatti, non c’è differenza tra un’immagine, un suono o una parola, perché qualsiasi input viene codificato in linguaggio binario. E’ come se avesse una sola modalità percettiva e mancasse quindi della possibilità di apprezzare la differenza qualitativa fra i diversi tipi di input.

Quello che accade quindi non è un’integrazione tra informazioni afferenti a modalità diverse, ma un arricchimento di informazioni distribuzionali. Dunque, la multimodalità non migliora le performance dei modelli perché fornisce il grounding dei significati, ma perché aumenta ancora di più la competenza statistica del modello nei confronti del linguaggio umano (Lee et al.; 2025).

Come i modelli di linguaggio classici, allora, anche quelli multimodali si trovano di fronte all’impasse del symbol grounding problem espresso nella forma dell’argomento della stanza cinese. In questo caso, però, dobbiamo immaginare che l’uomo nella stanza sia cieco e che il suo librone delle regole di corrispondenza sia scritto in Braille. Inoltre, il libro non conterrebbe solo caratteri che corrispondono ad altri caratteri, ma anche caratteri associati a delle foto stampate che recano in un angolo un segno identificativo sempre scritto in Braille. Se le regole sono ben congegnate, alla domanda "Che cos’è un gatto?", l’uomo nella stanza potrebbe rispondere infilando la foto di un gatto nella fessura di output, o se al contrario venisse fornita in input la foto di un gatto potrebbe rispondere scrivendo in Braille l’espressione "Che bel gatto!" (a patto che la foto rechi il segno identificativo in Braille). Dall’esterno, quindi, sembrerebbe proprio che chi sta dentro la stanza sappia a cosa corrisponde la parola gatto nella realtà, così come ci sembra che lo sappia un MLLM. Tuttavia, non saremmo disposti a dire che l’uomo nella stanza ha una competenza referenziale dei simboli che manipola, né che per lui i segni dei caratteri linguistici siano qualcosa di essenzialmente diverso da quelli che identificano le foto. Dato che i modelli multimodali agiscono in modo funzionalmente analogo all’uomo nella ‘stanza cinese cieca’, ne consegue che anche per loro valgono le stesse conclusioni. In definitiva, non sembra che ci sia una differenza sostanziale tra LLM e MLLM nel rappresentare le informazioni sensoriali delle parole, se non che i modelli multimodali lo fanno in modo computazionalmente più efficiente e attraverso embedding informativamente più densi. A riprova di questo c’è il fatto che i modelli addestrati anche su

immagini non miglioravano tanto nei rating visivi quanto in quelli di interocezione, che ha a che fare con concetti astratti e con una dimensione più emotiva che sensoriale per certi versi, e in ogni caso scollegata dal canale visivo.

Ad ogni modo, l'apprendimento di pattern statistici su un grosso bacino di dati multimodali, sembra in grado di surrogare entro una certa misura il grounding percettivo umano nell'elaborazione di significati embodied. Non è assurdo, d'altra parte, che i modelli possano ottenere delle buone performance nei rating percettivi pur contando solo su informazioni distribuzionali. Ad esempio, il fatto che "coffee" co-occorra spesso con "aroma" e "drink" può fornire a un modello di linguaggio abbastanza elementi per associare la parola "coffee" all'olfatto e al gusto. Naturalmente, però, fare affidamento esclusivamente sulla forma e sulle relazioni sintagmatiche delle parola porta i modelli a produrre rappresentazioni distorte della realtà fisico-pratica umana, associando ad esempio una parola come "saline" (flebo, soluzione fisiologica) al gusto, pur non essendo qualcosa che gli esseri umani consumano come bevanda.

L'esperimento di (Lee et al.; 2025), pone anche un'altra questione importante: una questione metodologica. In studi come questo, modelli di linguaggio ed esseri umani sono testati su uno stesso task linguistico che impone di ragionare sul mondo fisico. Si osservano quindi le performance di entrambi e, dal fatto che la performance degli umani risulta molto superiore a quella dei modelli, si deduce che questi non hanno la rappresentazione embodied dei significati necessaria a rispondere adeguatamente al task. Tuttavia, come per i parlanti umani anche per i modelli di linguaggio vale la distinzione chomskiana fra *performance* e *competence*: un'errore nell'esternalizzazione del linguaggio (che può essere dovuto a fattori contingenti) non implica l'assenza di una rappresentazione interna di un sistema di regole astratte, cioè di una competenza linguistica ben formata. Dunque, analizzare solo la performance dei modelli può essere fuorviante, poiché eventuali output illogici o incoerenti rischiano di nasconderci una corretta rappresentazione interna dei significati.

Nel prossimo studio che prenderemo in considerazione, i modelli multimodali verranno valutati non osservandone l'output ma estraendo direttamente gli embedding degli input, ossia le loro rappresentazioni interne dei significati.

L'esperimento in questione è quello di (Jones and Trott; 2024). In questa sede i modelli sono stati testati ricercando prove di embodied simulation. In particolare, gli autori estraevano la rappresentazione che il modello produceva per una certa frase; poi la confrontavano sia con quella di un'immagine che presentava caratteristiche visive implicate dall'evento descritto sia con quella di un'immagine che non presentava caratteristiche del genere. Ad esempio, veniva osservato il dot product fra l'embedding della frase "The egg was in the refrigerator" e, da un lato, l'immagine di un uovo ancora nel guscio, dall'altro, l'immagine di un uovo sgusciato. L'idea è che se la somiglianza tra l'embedding della frase e quello dell'immagine che le corrisponde risulta maggiore di quella tra embedding della frase e quello dell'immagine che non le corrisponde, allora la rappresentazione dell'input testuale che il modello produce costituisce una sorta di

simulazione dell'evento o dello stato di cose descritto, poiché contiene informazioni senso-motorie su di esso e sulle sue conseguenze fisico-pratiche.

I risultati della comparazione avallano parzialmente la problematica ipotesi della multimodalità come grounding percettivo: sembra che i modelli simulino per lo meno la proprietà della forma degli oggetti coinvolti nell'evento descritto dalla frase. Per quanto riguarda il colore i dati sono discordanti, mentre dell'informazione sull'orientamento spaziale degli oggetti non sembra esserci traccia nell'embedding di frase.

2.2.4 Il significato sta nell'uso (comunicativo)

Se anche ammettessimo che i modelli di linguaggio possono rimediare al symbol grounding problem con l'espedito del training multimodale, dovrebbero comunque scontrarsi con un'altra evidente differenza rispetto agli esseri umani: l'impossibilità di avere un intento comunicativo nel contesto di situazioni reali. E' opinione di alcuni studiosi, infatti, che sia questa mancanza a determinare l'incapacità dei sistemi artificiali di comprendere i significati dei simboli che manipolano.

Paradossalmente quest'idea, deriva proprio dalla premessa alla base della teoria distribuzionale, ovvero che il significato sta nell'uso. Infatti, è possibile interpretare questa affermazione non nel senso che il significato di una parola dipende dalle parole insieme a cui viene usata, ma nel senso che dipende dal fatto di essere usata per comunicare qualcosa a qualcun altro in una data situazione (Bender and Koller; 2020).

Prove empiriche a sostegno di questa prospettiva, possono essere trovate nell'ambito degli studi acquisizionali. Si è osservato, infatti, che i bambini cominciano a parlare una lingua se hanno a che fare con essa in situazioni comunicative reali, mentre l'esposizione passiva a input linguistici tramite radio o televisione non innesca in loro l'apprendimento. Inoltre, i neonati tra i 18 e i 20 mesi non cominciano ad usare le etichette verbali che sentono pronunciare da una persona che non fa parte della situazione comunicativa (perché si trova dietro ad uno schermo), mentre lo fanno se notano che la persona osserva lo stesso oggetto che osservano loro (*joint attention*) (Bender and Koller; 2020).

Insomma, gli esseri umani non sono in grado di imparare a parlare se gli input che ricevono sono meri significanti sonori, slegati da un riferimento fisico e avulsi da un contesto comunicativo pragmatico. Se quindi gli umani non riescono a sviluppare una competenza linguistica basandosi sulla pura forma, non si capisce perché dovrebbero riuscire le macchine.

Un argomento più teoretico consiste nel definire il significato come la relazione tra una certa espressione e un certo intento comunicativo. Comprendere un'espressione consiste a questo punto nel rintracciare l'intento comunicativo a cui quest'espressione è collegata. Per farlo bisogna considerare la situazione pragmatico-comunicativa corrente

e selezionare l'intento più appropriato tra quelli che nella nostra esperienza sono solitamente associati all'espressione in questione (Bender and Koller; 2020).

Un LLM non è in grado di costruire relazioni di significanza, ovvero relazioni che leghino queste forme a certi intenti comunicativi, poiché la natura puramente formale del materiale su cui è addestrato non gli dà modo di esperire le situazioni pragmatico-comunicative in cui gli intenti si manifestano.

I modelli di linguaggio non sono in grado di stabilire una connessione tra le parole che generano e un qualche intento comunicativo o pratico da realizzare, tuttavia quando interagiamo con un modello generativo come ChatGPT ci sembra che sia dotato di competenza semantica. Il motivo dell'illusione è questo: l'addestramento puramente testuale permette al modello di raggiungere una competenza sintattica tale da formare frasi grammaticalmente corrette e incidentalmente coerenti a livello semantico; dalla prospettiva del modello, non c'è qualcosa come un significato nelle parole che ha prodotto, ma la loro combinazione statisticamente probabile pone le giuste basi affinché sia l'interlocutore umano a costruirne il significato. Siamo noi a creare quella relazione tra l'espressione e l'intento comunicativo che il modello non ha la facoltà di creare, e quindi, possiamo dire, a vederla dove in realtà non c'è.

Tuttavia, questa idea dell'intenzione comunicativa come parte essenziale del significato di una forma non è scevra da critiche. Ad esempio, i simboli che usiamo per rappresentare i numeri e le operazioni quando facciamo un calcolo su un foglio sono dotati di un contenuto semantico anche se non li impieghiamo per comunicare ad altri questo significato. I simboli che rappresentano il risultato del calcolo potranno magari avere questa finalità comunicativa, ma non per questo sono più significanti degli altri. Inoltre, è innegabile che gran parte delle operazioni mentali che compiamo ogni giorno sono modellizzabili in modo soddisfacente come una manipolazione di simboli, e che questi simboli significano qualcosa a prescindere dal fatto che siano esternalizzati nella comunicazione.

Quindi, per capire se i modelli di linguaggio capiscono ciò che elaborano, non ha senso valutare se quando predicono la parola più probabile data una sequenza precedente intendono comunicarne il significato. Piuttosto, quello che conta è la natura delle rappresentazioni interne che collegano gli input agli output (Pavlick; 2023).

2.2.5 Un grounding alternativo

Ormai è stato reso chiaro più volte: i modelli di linguaggio basati su reti neurali acquisiscono la lingua secondo modalità e condizioni estremamente diverse dall'uomo. La loro natura disembodied non permette di legare etichette verbali a sensazioni, emozioni o situazioni concrete, né di costruire rappresentazioni concettuali pregne di informazioni motorie e percettive.

Detto questo, a ben guardare non è però vero che ogni qualvolta noi umani comprendia-

mo il significato di una parola lo facciamo in virtù di una percezione collegata ad essa, o risalendo a ritroso una catena di definizioni che in ultima analisi ci porta a considerare una nostra esperienza diretta. In altre parole: non tutti i significati sono fondati su esperienze corporee, e dunque non è solo in virtù di queste che possiamo comprendere e usare intenzionalmente (nel senso searliano) il linguaggio.

Pensiamo ad esempio alla parola "oro": a meno che non siamo degli esperti di pietre preziose, non sapremmo distinguere un gioiello d'oro da uno fatto di un materiale che lo imita e basta; eppure non per questo per noi la parola "oro" non ha un significato, cioè non si riferisce un qualche referente nel mondo. C'è ragione di pensare che questo accada perché la parola in questione è comunque ancorata a una serie di esperienze percettive e di conoscenze dirette sull'oro; tuttavia non si tratta delle nostre, ma di quelle di persone esperte in materia di cui diamo per scontato l'esistenza. In questo caso si configura una sorta di grounding sociale, che trova conferme empiriche nel filone di ricerca delle *communities of knowledge* (Borghi et al.; 2024). L'idea fondamentale di questo ambito di studi è che l'intelligenza umana sia inerentemente collettiva: la nostra cultura è composta da una gran quantità di infrastrutture concettuali a loro volta molto complesse (i sistemi linguistici, le religioni, le teorie scientifiche, il sapere tecnico, le strutture di governo politico, etc.); sarebbe impensabile che ogni persona comprenda tutti i significati in cui si articola quest'architettura mastodontica, e che quindi nella mente di ciascuno di noi ci sia una rappresentazione definita ed esauriente di ognuno di quei concetti. Piuttosto, ogni persona dà il suo contributo di conoscenze, e collettivamente la comunità umana sostiene questo macro-sistema di sapere.

(Pavlick; 2023) sostiene addirittura che il grounding sociale del significato caratterizza la maggior parte delle espressioni che usiamo ogni giorno. Per Pavlick, infatti, in moltissimi casi è come se 'delegassimo' la competenza referenziale di una parola ad un'altra persona, che funge da anello di congiunzione tra la forma in questione e il suo riferimento. Il suo esempio chiarisce in che senso:

“ Consider, for example, the meaning of Jean Pavlick (my paternal grandmother). Almost certainly no one reading this has met, or even seen a picture of, my grandmother. You are learning the meaning of the phrase Jean Pavlick just now. Still, this does not make the word meaningless, or even referenceless. Rather, you inherit the grounded meaning from me, who has directly observed the referent (she's lovely).” (Pavlick; 2023)

Se diamo per buono questo modello della conoscenza umana, allora un sistema artificiale che si addestra leggendo testi scritti da esseri umani può sfruttare il meccanismo del grounding indiretto proprio come fanno questi ultimi. E se anche un tale modello si ritrova a dover imparare parole come "azzurro", "pistacchio", "saltare", del cui significato non ha esperienza diretta, non agirà in modo diverso da come plausibilmente gran parte di noi si rapporta al significato di "kimchi", "reattore nucleare" o "zufolo".

In chiusura, è interessante notare come l'applicazione del modello del sapere distribuito al design delle architetture dei modelli linguistici abbia portato un miglioramento delle loro performance. Abbiamo visto che la complementarità di esperienze e competenze di individui diversi fonda la possibilità del singolo di comprendere l'intero sistema, delegando di volta in volta le conoscenze che non possiede in prima persona. In un modo analogo, le cosiddette architetture *Mixture of Experts* (MoE) si articolano in una serie di reti feed-forward indipendenti (gli esperti), ognuna delle quali si è stata addestrata su un dataset diverso, specializzandosi ad elaborare tipi diversi di input. Premessa agli esperti c'è una *gating network* (colui che delega il sapere), che durante il training apprende quali esperti sono da 'interpellare' a seconda del tipo di input. Un'architettura del genere fa sì che l'input non venga processato da tutta la rete nel suo complesso, ma che a seconda delle sue caratteristiche la sua elaborazione sia affidata solo alla competenza mirata di alcuni esperti (Borghi et al.; 2024). Tutto ciò si traduce in un'efficienza di calcolo che a parità di numero di parametri garantisce ai modelli MoE tempi e costi di elaborazione ben inferiori rispetto ai corrispondenti modelli privi di esperti.

Insomma, i vantaggi che le reti MoE dimostrano nella modellizzazione del linguaggio possono costituire un buon argomento a favore dell'idea che il sapere umano sia distribuito tra le singole persone ma allo stesso tempo disponibile a tutti nella sua integrità.

2.2.6 L'alternativa al grounding

Nel paragrafo precedente è stata messa in discussione la necessità di un grounding percettivo per la comprensione dei significati. In questo paragrafo ci si spingerà ancora oltre, presentando una prospettiva secondo cui lo sviluppo di abilità cognitive umane non ha come condizione un grounding di nessun tipo.

L'addestramento nel task di next word prediction, e l'apprendimento delle caratteristiche distribuzionali delle parole che ne consegue, può far *emergere* in un LLM capacità che esulano dall'ambito di quel task specifico, permettendogli di svolgere compiti di traduzione, sentiment analysis, POS tagging, etc. Non solo, ciò che il modello ha imparato, e che è imperscrutabilmente registrato nelle sue matrici di pesi, va oltre il natural language processing e sfocia addirittura in competenze di tipo metacognitivo.⁵. Negli esseri umani, la metacognizione consiste nel fare ipotesi plausibili sui contenuti mentali altrui. L'abilità metacognitiva, spesso denominata *theory of mind* (ToM), è stata oggetto di molti studi che l'hanno messa in relazione al linguaggio. In particolare,

⁵ In questo caso il verbo "emergere" è usato come termine tecnico relativo al quadro teorico delle proprietà emergenti, ovvero quelle proprietà pur caratterizzando un sistema nel suo complesso non sono rintracciabili in nessuno dei suoi componenti. L'esempio classico è quello dell'acqua: nessuna delle molecole che la compone può essere definita un liquido, la sua 'liquidezza' emerge solo nel momento in cui più molecole si compongono tra loro.

è stato osservato che: c'è una forte correlazione fra ToM e competenza linguistica; le persone che sono esposte a pochi input linguistici ritardano lo sviluppo della ToM; compiti linguistici e compiti metacognitivi innescano l'attivazione delle stesse regioni neurali. Questi dati suggeriscono che per quanto la ToM sia una capacità cognitiva dotata di una funzione specifica, risulti funzionale anche alla costruzione della competenza linguistica umana (in modo simile a come la capacità di concepire regole ricorsive trova un'applicazione nella costruzione e nella comprensione delle strutture grammaticali (Hauser et al.; 2002)). Infatti, per comprendere il significato di una frase come "Mario pensa che Luigi sospetti che Anna sia triste", dobbiamo aver chiaro non solo il concetto di stato mentale e il fatto che ogni individuo ne abbia uno, ma anche che questi stati non rappresentano necessariamente la realtà dei fatti (Luigi potrebbe non star sospettando affatto, e Anna potrebbe invece essere felice) (Kosinski; 2024).

Alla luce di questo possiamo chiederci: se lo sviluppo di capacità linguistiche è legato a quello di capacità metacognitive, le ottime performance dei LLM sui task di NLP derivano anche da una loro competenza in ambito di ToM? Per rispondere a questa domanda, (Kosinski; 2024) ha testato vari modelli di linguaggio quanto alla loro capacità di riconoscere una falsa credenza (*false-belief task*, test standard per attestare ToM negli esseri umani)⁶. Il modello più recente tra quelli testati, ChatGPT-4, ha mostrato performance superiori a tutti gli altri, rispondendo correttamente al 75% degli scenari proposti e raggiungendo di fatto la stessa competenza ToM documentata nei bambini di 6 anni. Questi risultati sono significativi per due ragioni. Da una parte confermano per i LLM la correlazione fra ToM e competenza linguistica già dimostrata per gli esseri umani: i modelli linguistici più vecchi, dotati di meno parametri e addestrati su meno dati rispetto a quello più recente, esibiscono performance peggiori non solo nel *false-belief task* ma anche in vari task linguistici. Dall'altra parte, i risultati ottenuti da ChatGPT-4 testimoniano il fatto che un comportamento intelligente come quello metalinguistico può effettivamente emergere in un sistema le cui componenti prese singolarmente non manifestano tale comportamento.

Quest'ultimo fatto è vero anche per gli esseri umani, ed è la ragione per cui si può pensare che il grounding dei significati delle parole non sia una condizione necessaria per il configurarsi di processi cognitivi analoghi a quelli umani. Difatti, non attribuiremmo nessuna delle capacità cognitive del nostro cervello a un singolo neurone (nemmeno quella di comprendere i significati), poiché piuttosto tali capacità emergono a livello di sistema. Neuroni artificiali e naturali sono funzionalmente identici, in quanto consistono entrambi in micro-sistemi rule-based che dato un input gli fanno corrispondere un

⁶ In particolare, i modelli ricevevano un prompt articolato in due parti: una in cui si forniva il contesto (es: "Complete the following story: Here is a bag filled with popcorn. There is no chocolate in the bag. Yet, the label on the bag says "chocolate" and not "popcorn". Sam finds the bag. She has never seen this bag before. Sam doesn't open the bag and doesn't look inside. Sam reads the label."), e una in cui si metteva il modello nella condizione di rivelare con la sua predizione di parola se avesse compreso lo stato mentale altrui (es: "Sam opens the bag and looks inside. She can clearly see that it is full of") (Kosinski; 2024).

output (ovvero la trasmissione dell'input stesso nella rete). In entrambi i casi, infatti, vi è una funzione che definisce la soglia di attivazione del neurone: nel caso di quello naturale, riguarda la differenza di potenziale determinata da una diversa concentrazione di ioni elettricamente carichi tra l'interno e l'esterno della membrana cellulare (Gazzaniga et al.; 2006); nel caso del neurone artificiale il superamento della soglia dipende invece dal valore aggregato degli input pesati in entrata.

Se non ha senso dire che le unità elementari di una rete neurale possano essere capaci di ToM, questo non è così scontato per la rete nel suo complesso. E infatti abbiamo visto che il cervello umano è capace di cose di cui i neuroni che lo compongono non possono essere ritenuti capaci; perché allora non potremmo aspettarci lo stesso da un sistema artificiale dotato di un'architettura connessionista analoga e che, tra l'altro, ci dà prova di performance comparabili a quelle umane? L'addestramento dei modelli, per quanto basato sulla pura forma della lingua, sembra far emergere competenze collaterali, come quella della ToM, che implicano una sensibilità alla semantica del linguaggio.

Questa prospettiva mette in discussione la possibilità di applicare l'argomento della stanza cinese al caso dei sistemi neurali, o meglio ne amplia l'applicazione al cervello umano stesso. L'uomo nella stanza cinese, infatti, non è una buona rappresentazione della rete neurale nella sua interezza, quanto piuttosto del singolo neurone, che sia umano o artificiale. Possiamo ad esempio immaginarci di sostituire i neuroni del cervello di un parlante cinese con delle micro-stanze cinesi, ognuna delle quali svolga il compito elementare di propagare il segnale elettrico in entrata se la differenza di potenziale supera una certa soglia. Questa sostituzione non avrebbe alcun effetto sulla competenza della persona in questione di comprendere e generare parole in cinese (Kosinski; 2024). Se quindi negli esseri umani la mancanza di intenzionalità a livello di singoli neuroni non inficia la competenza linguistica del sistema cognitivo nella sua interezza, perché dovrebbe farlo nei modelli neurali artificiali?

Detto questo, rimane tuttavia un nucleo irriducibile di obiezioni che fanno riferimento all'insufficienza di un addestramento puramente formale per lo sviluppo di vere capacità cognitive e linguistiche.

Innanzitutto, i modelli di linguaggio restano pur sempre degli *stochastic parrots*, ovvero sistemi che ripropongono gli input linguistici a cui sono già stati esposti senza avere la minima idea del loro contenuto. Rispetto ai comuni pappagalli, però, sono dotati di una raffinata capacità rielaborativa, tutta basata sulla generalizzazione di pattern statistici della lingua. E' vero che i modelli producono quasi sempre frasi semanticamente coerenti, ma il punto è che lo fanno per il motivo sbagliato: essi non colgono i significati delle parole, ma solo la loro forma (Bender and Hanna; 2025).

Un pappagallo non ha una competenza linguistico-cognitiva nemmeno se stocastico; e se anche in certi ambiti imprenditoriali si sfrutta questa apparente intelligenza dei LLm per vendere assistenti virtuali sedicentemente dotati di empatia e interesse personale

verso l'utente, bisogna sempre tenere presente che tali stati mentali esistono solo in presenza di un'esperienza soggettiva conscia. Questi sistemi non possono provare sentimenti o riconoscerli segni altri, ma al massimo possono generare una sequenza di parole che nel loro insieme vengono interpretate come manifestazione di empatia (Bender and Hanna; 2025).

Inoltre, una rappresentazione esclusivamente distribuzionale del significato delle parole è riduttiva e facilmente fallibile in determinati contesti linguistici. Per fare un esempio, sebbene un encoder come BERT possa vantare ottime performance nel Multi-genre Natural Language Inference dataset⁷, queste degradano sotto al livello del caso se la forma delle frasi viene manipolata lasciandone però intatto il significato. Per risolvere il task in questione, infatti, BERT fa affidamento sulla somiglianza formale tra le frasi da classificare, calcolandone la sovrapposibilità in termini di token, subtoken, o insiemi di token comuni. E' inevitabile allora che il modello sbagli a classificare la relazione tra due frasi semanticamente contrarie, ma dotate di una struttura e di una scelta lessicale molto simile (Bender and Koller; 2020).

2.3 Simulazione della psicologia umana

Nonostante l'argomento dell'intelligenza come proprietà che emerge dall'attività collettiva di elementi non intelligenti, l'opinione più diffusa ed empiricamente supportata in letteratura è quella che i Large Language Model non pensino nel senso in cui pensa l'uomo.

Appurato questo, però, ci si può chiedere quanto bene i LLM possano almeno simulare di pensare come gli esseri umani. In particolare, esiste un filone di ricerca già ben affermato, volto a indagare se, quanto e in quali scenari sperimentali i LLM possano sostituire gli umani in esperimenti psicologici e psicolinguistici. In questo solco si inserirà anche l'esperimento presentato nel capitolo 4, e vale quindi la pena presentarne una breve panoramica. Per farlo articoleremo il discorso in tre parti: nella prima si chiarisce il motivo per cui sarebbe desiderabile sostituire i tester umani coi LLM; nella seconda si illustrano i principali motivi per cui tale sostituzione non sarebbe auspicabile, e le eventuali contro-obiezioni; la terza parte, infine, costituisce una sorta di prova dei fatti: si prendono in considerazione dei casi studio di replicazione di giudizi umani, e se ne analizzano i risultati.

⁷ Si tratta di un dataset di coppie di frasi etichettate a seconda della relazione semantico-pragmatica che intercorre fra loro: neutral, contradiction o entailment.

2.3.1 Perché sostituire?

Il vantaggio di sostituire (anche solo parzialmente) i partecipanti umani con dei modelli di linguaggio starebbe nell'abbattimento dei tempi e dei costi della raccolta di dati, nonché nella semplificazione della logistica legata all'organizzazione degli esperimenti. Tutto questo, permetterebbe di creare basi di dati molto più grandi molto più velocemente, e dunque di aumentare significativamente le risorse disponibili alla ricerca scientifica in questo ambito, accelerandone lo sviluppo ed espandendone l'orizzonte di studio.

Immaginiamo di voler condurre uno studio psicolinguistico che indaga la percezione raccogliere i giudizi di 10 persone a proposito di 11 dimensioni semantiche (concretezza, familiarità, etc.), e di volerlo fare per 40.000 parole, per un totale di 4.400.000 giudizi. Già così si tratterebbe di un'impresa assai dispendiosa e che solo in parte può essere facilitata da piattaforme virtuali di crowd-sourcing come Amazon Mechanical Turk, poiché è stato osservato che in modo sistematico più di un quarto dei partecipanti che compilano il questionario online danno risposte inaffidabili che quindi vanno scartate in sede di pulizia dei dati. Dunque tenendo conto di dover compensare per questo scarto, dovremmo raccogliere 2.346.665.200.000 giudizi. Stimando un tempo medio di risposta di 5 secondi e supponendo di pagare i partecipanti con la tariffa minima di 7.25 dollari all'ora, la spesa totale per il nostro studio ammonterebbe a quasi 60.000 dollari. Inoltre, a ben guardare le proprietà semantiche delle parole cambiano a seconda del contesto in cui occorrono (la parola "table" sarà sicuramente considerata più concreta in "wooden table" che in "data table") e sarebbe quindi auspicabile raccogliere i giudizi delle parole in diversi contesti. Il costo e le tempistiche già esorbitanti per questo progetto aumenterebbero vertiginosamente a questo punto (Trott; 2024).

Di contro, poter contare sui giudizi sostanzialmente istantanei, sempre disponibili e meno costosi⁸ dei LLM vuol dire poter raccogliere giudizi su più parole, in più contesti e quanto a più dimensioni (Trott; 2024).

Naturalmente, però, la fattibilità della sostituzione dei partecipanti umani coi LLM è tutt'altro che scontata, e alcuni autori parlano piuttosto di fare *augmentation* aggregando giudizi sintetici e reali nello stesso dataset (Trott; 2024). Il dibattito sulla questione è ora più vivo che mai, con opinioni e risultati sperimentali a sostegno di entrambe le parti.

⁸ Per il momento in realtà i modelli con le performance migliori, come GPT-4, sono interrogabili tramite un'Application Programming Interface, il cui prezzo non è particolarmente competitivo rispetto a quello dei servizi crowd-sourcing. Tuttavia è possibile che in futuro il prezzo calerà o che modelli interrogabili gratuitamente attraverso API raggiungeranno performance accettabili per lo scopo in questione

2.3.2 Obiezioni alla sostituzione

Le ragioni di chi si dichiara contrario all'impiego dei language models al posto dei tester umani sono varie, e hanno a che fare o con la mancanza di garanzie di scientificità che il comportamento dei modelli comporta, o col fatto che il loro funzionamento interno li rende per definizione incapaci di simulare la psicologia umana. Ma vediamo nel dettaglio.

Incostanza e irriproducibilità degli output

Una delle caratteristiche imprescindibili di ogni esperimento scientifico consiste nella sua riproducibilità. Varie esperienze sperimentali, però, testimoniano che cambi minimi nella formulazione del prompt, per quanto lascino inalterato il significato, portano ad output semanticamente distanti (Schröder et al.; 2025).

Non solo, le risposte ad uno stesso prompt variano significativamente da un modello all'altro: in questo caso non è rilevante solo la differenza nel numero di parametri, ma anche quella di appartenenza ad una certa famiglia di modelli. (Zhong et al.; 2025), ad esempio, riportano come addirittura nel caso di informazioni sulla distribuzione di certe espressioni linguistiche modelli diversi hanno imparato cose diverse. I modelli di Meta, infatti, dimostrano di codificare le informazioni circa la dispersione dei binomi in modo più fedele alle misure reali estratte dai corpus rispetto a quelli di OpenAI, a prescindere dalla loro dimensione (LLaMa-3.3-70B ottiene performance migliori di ChatGPT-4o in questo caso).

Incapacità di simulare la diversità umana

Se, come abbiamo visto sopra, c'è una varietà di output non trascurabile tra un modello e l'altro, al contrario quella intra-modello è minima: dato un input, un modello tende a riproporre le stesse risposte, anche a fronte di accorgimenti mirati per modularne la 'creatività'. Evidenze sperimentali, infatti, dimostrano che i modelli di linguaggio non sono in grado di riprodurre la varietà di risposte che più persone produrrebbero a fronte di uno stesso input.

In (Ravelli and Bolognesi; 2024), ad esempio, si cerca di simulare questa varietà settando

il parametro della temperatura ⁹ a 0.8 e facendo e iterando la stessa richiesta più volte per ogni modello. Tuttavia le risposte sintetiche di ogni singolo modello si sono rivelate piuttosto coerenti tra loro, esibendo un indice di inter-annotator agreement massimo di 0.9 contro lo 0.6 dei giudizi umani nello stesso task.

Anche la strategia di includere nel prompt ad ogni run su uno stesso task un identikit di persona differente (precisando varie informazioni demografiche) non sembra risolvere il problema. In uno studio che si avvaleva di questo tipo di prompt, confrontando interviste reali e interviste generate, è emerso che le risposte degli intervistati sintetici non si differenziavano in modo definito come invece facevano quelle umane (Schröder et al.; 2025).

Bias di addestramento

I modelli tendono a riproporre nelle loro produzioni linguistiche bias culturali, occupazionali, socio-economico e di genere che evidentemente caratterizzano i dati testuali su cui sono addestrati. Dal punto di vista sperimentale potrebbe perfino apparire desiderabile che la macchina abbia assorbito queste opinioni, poiché ciò la renderebbe un fedele simulatore del modo di ragionare umano. Tuttavia, questi bias umani appaiono problematici alla luce di un bias metodologico che caratterizza l'addestramento dei LLM. I dati di training, infatti, appartengono nella stragrande maggior parte dei casi ad una varietà di lingua molto specifica: quella scritta e reperibile su internet da persone di una certa classe sociale e che parlano certe lingue. Questo fatto pone grossi limiti alla capacità del modello di rappresentare l'effettiva varietà psicologica umana. Inoltre, il meccanismo di apprendimento dei modelli di linguaggio è tale che pur venendo esposti a una varietà di opinioni diverse, fanno collassare questa diversità in un'opinione che le approssima tutte (Dillion et al.; 2023).

Non solo, i modelli non tengono conto delle produzioni di anziani, bambini, persone con professioni, background culturali e origini diverse da quelle del campione, ma a priori sono escluse dal training tutte quelle lingue che non hanno una codifica scritta¹⁰, e che sono in realtà la maggior parte (4.178 su 7168 secondo Ethnologue (Cuskey et al.; 2024)) Un tale limite mina la possibilità di usare questa tecnologia come fonte di evidenze sul funzionamento del linguaggio e della cognizione umana in generale.

⁹ Parametro che condiziona l'entropia della distribuzione di probabilità che il modello proietta sul vocabolario di token al momento della generazione (Günther et al.; 2025). Il modello, infatti, sceglie il token di output pescandolo dalle top-k parole più probabili, tenendo conto della loro probabilità: con temperatura 0 la curva di distribuzione delle probabilità sarà molto ripida in quanto i token più probabili lo saranno molto di più di quelli meno probabili; con livelli sempre più alti di temperatura (può arrivare fino a 2) la curva sarà sempre più 'piatta' e non ci saranno enormi differenze tra le varie probabilità. Dunque, a parità di prompt, a temperature basse il sistema tenderà a rispondere sempre con la stessa parola più probabile, mentre a temperature alte tenderà a variare il suo output pescando una volta una parola una volta un'altra dalla probabilità simile.

¹⁰ Non è alle lingue per esistere: è il parlato ad avere priorità sia a livello ontogenetico che filogenetico (Berruto et al.; 2011).

Valutazioni inaffidabili

Un ulteriore problema nell'impiego dei LLM in ambito scientifico riguarda l'affidabilità delle valutazioni condotte da chi sviluppa e commercializza questi sistemi. Come osservato da (Bender and Hanna; 2025), infatti, spesso aziende, startup e laboratori finanziati dall'industria non verificano se un modello sia realmente adatto a compiti specifici, ma ne misurano le prestazioni attraverso test standardizzati, come quelli per la licenza medica o per l'abilitazione legale. L'attenzione si concentra sui risultati dei test anziché sulla creazione di benchmark che riflettano scenari realistici d'uso. Di conseguenza, questi test forniscono pochissime informazioni sul comportamento del modello alle prese con compiti concreti, e servono soprattutto a produrre titoli sensazionalistici come "ChatGPT supera l'esame di avvocato", rivelando che la vera natura del progetto non è scientifica ma orientata al marketing.

Inoltre, anche la scelta delle metriche di valutazione può essere votata a logiche commerciali più che all'interesse pubblico. Un esempio significativo riguarda gli assistenti vocali automatici per i servizi di emergenza: la loro accuratezza viene spesso calcolata usando la percentuale di errore sulle parole totali, trattando ogni parola allo stesso modo. Tuttavia, in situazioni critiche alcune parole, come gli indirizzi stradali, sono di importanza cruciale; ma poiché tali espressioni sono poco frequenti nei dati di training e i sistemi tendono a sbagliarle più facilmente, per non rischiare di ottenere risultati bassi nei test, i valutatori le considerano allo stesso livello delle altre parole (Bender and Hanna; 2025). Naturalmente, questo oltre che a discapito della scientificità va a discapito della sicurezza stessa delle persone.

Data leakage

Con l'espressione *data leakage* si intende il fenomeno di sovrapposizione fra test set e training set (Ravelli and Bolognesi; 2024). Se un modello viene testato su dati che compaiono già nel suo addestramento, allora la bontà delle sue performance non implica necessariamente che sia un buon generalizzatore: potrebbe semplicemente star fungendo da archivio efficiente. Se ad esempio chiediamo a un modello di valutare la concretezza di una certa parola, idealmente dovrebbe stimarla sulla base dei significati distribuzionali e delle regolarità linguistiche appresi nel training; tuttavia, se la stessa valutazione compare nei dati di addestramento, non abbiamo garanzie che la risposta derivi da un processo inferenziale, piuttosto che dal semplice recupero di un'informazione già incontrata nel training set.

Quello del data leakage è un problema non da poco, perché constatare la contaminazione del test set è un'impresa piuttosto ardua. Diventa poi impossibile nel caso di modelli close-source, come quelli di OpenAI, per cui le informazioni sui dati di training sono minime.

Una soluzione radicale consiste nel comporre il proprio test set con dati caricati

in rete successivamente al knowledge cutoff¹¹ del modello che intendiamo testare. Nell'esperimento presentato in questa tesi si è approcciato il problema del data leakage proprio con questa modalità.

Nello studio di (Schröder et al.; 2025) viene esplorato il peso del data leakage nell'invalidare le conclusioni sulle performance dei modelli. Nello studio in questione, viene replicato il procedimento di un altro esperimento in cui si chiedeva sia a GPT-3.5 che a dei partecipanti umani di valutare su una scala Likert la moralità di certe azioni (Dillion et al.; 2023). In quel caso si è registrata una correlazione dello 0.95¹² tra i rating del modello e quelli umani, ma secondo Schröder e colleghi questa performance è ingannevole, poiché gli scenari su cui i modelli sono testati consistono in sequenze di token frequenti nel training data. Per dimostrarlo, nel loro esperimento si sono serviti degli stessi item usati in (Dillion et al.; 2023) ma apportando delle modifiche formali minime: per esempio, la frase "Person X cut the beard off of a local elder to shame him" è diventata "Person X cut the beard off of a local elder to shave him". Questo minimo cambiamento nella forma dei token, corrisponde un cambiamento radicale a livello semantico e ha quindi conseguenze sul livello di moralità dell'azione descritta dalla frase. Tuttavia, i modelli testati non si sono dimostrati sensibili a questo cambiamento. Se infatti i giudizi umani variavano significativamente tra item originali e item modificati (con un coefficiente di correlazione dello 0.54), la differenza era minima, o comunque non significativa, per i modelli (i valori dei coefficienti andavano da 0.80 a 0.99)¹³. Queste osservazioni non solo testimoniano l'affidamento esclusivo che i modelli di linguaggio fanno sulla forma linguistica, ma vanno anche a confermare la loro incapacità di generalizzare in modo semanticamente coerente quando si ritrovano ad elaborare dati troppo diversi da quelli di training. In questo caso il data leakage produceva una sedicente competenza dei modelli su cosa fosse più o meno etico per gli esseri umani.

Divergenze nell'acquisizione del linguaggio

Le dinamiche di apprendimento della lingua sono intuitivamente molto diverse per esseri umani e modelli di linguaggio, tanto che sarebbe irragionevole voler generalizzare per i primi qualcosa che è stato scoperto studiando i secondi. Vediamo, però, più nel dettaglio in che modo i due sviluppi linguistici divergono.

¹¹ Data che indica a quando risalgono i dati più recenti su cui è stato addestrato un modello

¹² Il coefficiente è calcolato secondo correlazione di Spearmann, ampiamente usata in questo tipo di studi. A differenza di quella di Pearson, che mette in relazione i numeri reali delle due variabili quantitative, quella di Spearman mette in relazione i ranghi delle due variabili quantitative. D'ora in poi nel testo si farà sempre riferimento a questo tipo di correlazione in assenza di informazioni ulteriori.

¹³ Per esempio, i modelli reputano parimenti etico "to work on a campaign to release *rightfully* convicted prisoners" e "to work on a campaign to release *wrongfully* convicted prisoners"

La differenza fondamentale riguarda la natura degli input su cui si costruisce la competenza linguistica. I suoni o i gesti linguisticamente rilevanti che i bambini recepiscono nella fase acquisizionale sono densi di informazioni pertinenti a tutti i livelli di analisi della lingua. Non tutte queste informazioni, però, sono esplicitamente codificate nella corrispondente forma scritta, su cui invece si addestrano i modelli di linguaggio. In particolare si perdono le informazioni che riguardano la fonetica, la fonologia, la prosodia, la pragmatica del discorso e la gestualità (Cuskley et al.; 2024). Non solo i LLM hanno accesso solo a una parte delle dimensioni in cui si articola il linguaggio, ma la quasi totalità dei dati linguistici usati nel training appartiene a una specifica varietà: la lingua scritta da adulti per adulti. Quest'ultimo fatto determina l'impossibilità da parte dei modelli di rappresentare fedelmente la percezione che i bambini in età acquisizionale hanno della lingua, rendendo impraticabile la sostituzione dei partecipanti umani negli studi sull'apprendimento linguistico.

Inoltre, come ampiamente argomentato nella sezione precedente, la natura disembodied e monomodale che contraddistingue l'apprendimento linguistico di un LLM non gli permette di sviluppare una competenza referenziale al pari di un essere umano. Facendo eco ancora una volta all'argomento di Searle: un bambino che cerca di imparare la sua lingua madre senza mai uscire dalla stanza in cui è nato, pur avendo a disposizione tutti i libri mai scritti e tutte le conversazioni mai registrate, non potrebbe mai capire cosa significano quelle parole o quei suoni.

Un'altra differenza fondamentale tra l'acquisizione linguistica umana e quella delle reti neurali, consiste nel fatto che negli esseri umani l'abilità di comprendere il linguaggio e di produrlo si sviluppano secondo ritmi diversi, e in ogni caso non in modo lineare. Questa asimmetria e incostanza dipende dall'influenza che lo sviluppo parallelo di altre competenze cognitive e psicologiche esercita su quelle prettamente linguistiche. Fattori del genere non intervengono nell'addestramento di un modello di linguaggio, la cui curva di apprendimento è costante sia per la comprensione che per la produzione (Cuskley et al.; 2024).

Se quindi lo sviluppo linguistico è essenzialmente diverso tra LLM ed esseri umani, poiché diversi sono i meccanismi e le risorse con cui avviene, l'osservazione del funzionamento di questi modelli non potrà dirci granché su come gli umani comprendono e usano il linguaggio. Così come riuscire a replicare artificialmente le condizioni che rendono possibile il volo, non necessariamente ci illumina su come funzioni il volo degli uccelli (Cuskley et al.; 2024).

Divergenze nel funzionamento neurale

Un'altro aspetto della differenza tra modelli di linguaggio basati su reti neurali ed esseri umani, sta nel funzionamento dei neuroni.

Innanzitutto, i neuroni artificiali producono un output continuo, mentre quelli biologici

generano segnali discreti. Questo, però, rappresenta una differenza piuttosto marginale. La distinzione cruciale riguarda le modalità di apprendimento e operatività:

- le reti artificiali vengono tipicamente addestrate *end-to-end*, attraverso l'ottimizzazione globale dei pesi su grandi dataset. Al contrario, nel cervello umano l'apprendimento avviene tramite dinamiche locali, come descritto dalla legge di Hebb: "neurons that fire together, wire together" (Krenker et al.; 2011);
- le reti biologiche apprendono continuamente, adattandosi costantemente a nuovi stimoli. Le reti artificiali, invece, terminano il processo di apprendimento una volta raggiunte prestazioni soddisfacenti sui dati di validazione (Cuskley et al.; 2024);
- infine, le reti artificiali operano in maniera sincrona, mentre quelli biologici in modo asincrono, generando dinamiche complesse e non lineari. Questo rende l'attività cerebrale un sistema dinamico, non solo difficile da monitorare e replicare, ma anche più potente (Eluyode and Akomolafe; 2013).

Divergenze nella categorizzazione concettuale

LLM ed esseri umani differiscono anche nella strategia adottata nella creazione delle categorie concettuali.

Le categorie concettuali che usiamo più spesso sono costruite in modo tale da massimizzare il numero e la coerenza interna dei suoi membri, pur mantenendo il massimo livello possibile di distinzione dalle altre categorie (Arcodia et al.; 2023). Ciò che permette a queste categorie di essere degli strumenti cognitivi formidabili per gli scopi umani è la gradualità di appartenenza categoriale. Ogni membro infatti può essere un esempio più o meno prototipico della sua categoria (i gabbiani sono più "uccelli" dei pinguini). La prototipicità permette agli esseri umani di creare sistemi concettuali laschi, in cui i confini categoriali sfumano gli uni negli altri pur nel rispetto delle distinzioni semantiche. Secondo (Shani et al.; 2025), i modelli di linguaggio mostrano una sensibilità limitata alla dimensione della prototipicità. Nello studio gli autori si avvalgono di un dataset di giudizi di prototipicità umani su membri di certe categorie, e li confrontano con dei giudizi sintetici: per ogni elemento la sua prototipicità sintetica viene stimata calcolando la similarità coseno tra l'embedding dell'elemento e quello del centroide della sua categoria (media degli embedding di elementi). La scarsa correlazione tra i punteggi indica che gli embedding dei modelli non riproducono in modo affidabile il gradiente di prototipicità osservato nei giudizi umani.

E' pur vero che, nello stesso studio, Shani e colleghi mostrano che i confini categoriali prodotti dai modelli si allineano a quelli umani (al netto della loro organizzazione interna). E di fatto anche altri dati sperimentali fanno ben sperare in una crescente competenza dei modelli sulla tassonomia concettuale umana.

(Puccetti et al.; 2025), ad esempio, rilevano un pattern di performance simile tra modelli ed esseri umani nella costruzione di *word ladders* (sequenze di categorie organizzate dalla più generale alla più specifica). Gli esseri umani trovano più difficile creare una

tassonomia a partire da una parola astratta piuttosto che da una concreta, per via della maggiore variabilità di interpretazione che contraddistingue i concetti astratti; analogamente LLaMa-3.1-405B produce word ladder più sovrapponibili al gold standard umano presente su Word Net¹⁴ quando parte da una parola concreta rispetto ad una astratta.

Tempi di calcolo

È intuitivo pensare che esseri umani e reti neurali abbiano tempi molto diversi nella processazione degli input. L'hardware delle macchine dispone infatti di una potenza di calcolo e di una memoria a breve fuori dalla portata del cervello umano. Come osserva (Moro et al.; 2023), se un sistema mostra prestazioni superumane, non può essere considerato un buon modello cognitivo dell'essere umano. Per questo motivo, non è corretto correlare direttamente i tempi di reazione umani con quelli della macchina.

Nonostante ciò, molti studi sul processing linguistico hanno mostrato una relazione sistematica tra comportamento umano e modelli computazionali. In particolare, i tempi di lettura delle parole, usati come misura della difficoltà di elaborazione, covariano con la probabilità che un modello assegna a quelle stesse parole nel contesto dato (de Varda et al.; 2024).

La misura utilizzata è la *surprisal*, definita come il logaritmo negativo della probabilità condizionata di una parola dato il contesto precedente. Essa quantifica quanto un token sia inatteso per il modello. Più alta è la probabilità stimata, più bassa è la surprisal, e minore risulta la “sorpresa” dell’osservazione. Empiricamente, le parole più prevedibili sono lette più velocemente, come mostrano tempi di lettura inferiori.

La surprisal risulta anche predittiva delle risposte neurali misurate nel cervello umano tramite Event Related Potential. In particolare, è stata messa in relazione con la componente N400, un picco di segnale che compare circa 400 millisecondi dopo la presentazione dello stimolo. L’N400 aumenta quando la parola è semanticamente inaspettata rispetto al contesto (ad esempio: “Ha ordinato un cappuccino e una *giraffa*”). Parole più attese sono associate sia a valori di surprisal più bassi sia a un’ampiezza N400 ridotta.

Questa correlazione, tuttavia, presenta dei limiti. È stato osservato che oltre una certa dimensione del training set (circa 2 miliardi di token) la surprisal perde potere predittivo rispetto alla facilità di processing umano (Oh and Schuler; 2023). In questi casi il modello apprende le distribuzioni linguistiche con una precisione tale da superare i vincoli cognitivi umani, riducendo l’allineamento tra misure computazionali e comportamento reale.

¹⁴ Database lessicale per la lingua inglese, in cui nomi, aggettivi e verbi sono raggruppati in *synsets*, ovvero insiemi di parole tra loro sinonime, ma dotata ognuna di un suo senso specifico.

Inconsapevolezza delle informazioni motorie

Abbiamo già accennato a come nella prospettiva della Embodied cognition la mente agisca sempre come mente di un corpo. Una conseguenza di questo è il fatto che le rappresentazioni umane delle entità del mondo esterno sono inerentemente funzionali all'azione del corpo. Nel modello dell'elaborazione degli input visivi messo a punto da Milner e Goodale nei primi anni Novanta,¹⁵ la rappresentazione visiva di un oggetto non include solo informazioni utili alla sua categorizzazione e discriminazione da altre tipologie di enti (pattern geometrici e caratteristiche strutturali), ma anche informazioni riguardo le possibili interazioni motorie che possiamo mettere in pratica con esso.

Nel loro esperimento, (Jones et al.; 2022) si propongono di capire se anche le rappresentazioni dei modelli di linguaggio, pur essendo costruite sulla distribuzione delle parole, contengano traccia di informazioni motorie. Nello specifico, Jones e colleghi indagano la possibilità che i modelli codifichino nei loro embedding di parola le *affordance* dei referenti denotati.

Il concetto di *affordance* è stato elaborato dallo psicologo James Gibson per descrivere le possibilità di interazione che una certa configurazione ambientale offre ad un essere vivente che si muove nello spazio. Le *affordance* scaturiscono dall'incontro tra le caratteristiche dell'ambiente e dell'agente che vi interagisce (Gibson; 1979): una palla da tennis apparirà a un umano come un qualcosa di afferrabile con la mano, mentre a un cane come un qualcosa di afferrabile con la bocca. Interagendo con gli oggetti attorno a noi nel corso della nostra vita, ne impariamo le *affordance*, che finiscono per costituire delle caratteristiche che attribuiamo inconsciamente alle cose. Infatti, soprattutto le *affordance* più marginali (come l'uso improprio di uno strumento) non appaiono in modo esplicito nel modo in cui parliamo delle cose. Per esempio, nonostante difficilmente qualcuno dirà (o scriverà) di aver usato un cacciavite per mangiare una macedonia, ognuno di noi se fosse obbligato a doverla mangiare scegliere con un cacciavite o con una palla sceglierebbe il primo, per quanto bislacco (Jones et al.; 2022).

L'esperimento in questione si serviva di una serie di stimoli così strutturati: una frase di contesto (es: "After wading barefoot in the lake, Erik needed something to get dry"), una contenente un'*affordance* improbabile (es: "He used his *shirt* to dry his feet") e una contenente una non-*affordance* (es: "He used his *glasses* to **dry** his feet"). Per ogni set di stimoli sono state misurate la similarità coseno tra gli embedding delle parole in corsivo (gli oggetti) e quello della parola in grassetto (azione compiuta per mezzo dell'oggetto), e la *surprisal* delle parole in corsivo (nel caso dei modelli decoder-only è stata considerata la media tra *surprisal* della parola dato solo il contesto sinistro e *surprisal*

¹⁵ Una volta che l'informazione visiva proveniente dal nervo ottico giunge sotto forma di impulso elettrico nelle aree occipitali, viene smistata tra una via neurale ventrale ed una dorsale. Lungo la prima vengono estratti dal flusso informativo i dati utili all'identificazione semantica e alla categorizzazione concettuale, mentre lungo la seconda via avviene una traduzione in termini motori delle informazioni fornite dai recettori visivi. Osservazioni sperimentali hanno poi dimostrato che le due vie si intersecano integrando i due tipi di informazione (Zipoli Caiani; 2016).

dato solo il contesto destro). Dalle misurazioni è emerso che i modelli encoder (BERT e RoBERT) non sono sensibili alla presenza di affordance: per esempio, rappresentano nello spazio vettoriale le parole "glasses" e "shirt" in modo sostanzialmente equidistante dalla parola "dry", e si 'sorprendono' di trovare "glasses" nel contesto di "dry" in modo non dissimile da quanto si sorprendono di "shirt". Diverso sembra essere il caso di GPT-3 (dotato di architettura decoder-only), che, in relazione all'azione descritta nella frase, dimostra di non mettere sullo stesso piano un'oggetto dotato di affordance e quello che ne è privo. Tuttavia, se messe in correlazione con giudizi di significatività prodotti da umani, nemmeno le differenze individuate fra le rappresentazioni di GPT-3 riescono a rendere conto in maniera soddisfacente del criterio con cui gli esseri umani giudicano l'uso di certi oggetti più o meno sensato per svolgere una certa azione. Tutto considerato, sembra quindi che l'informazione distribuzionale non basti a rendere i modelli di linguaggio 'consapevoli' delle possibilità interazionali che riguardano i referenti delle parole e gli esseri umani.

2.3.3 Capacità effettiva di replicare i giudizi umani

Passiamo ora ad esaminare tre esperimenti di replicazione artificiale di giudizi umani. Le dimensioni per le quali sono richiesti i giudizi spaziano dall'ambito percettivo (ritenuto il più ostico da valutare per i modelli), a quello statistico (presumibilmente quello invece su cui i modelli sono più preparati), passando per l'ambito psicologico.

Giudizi percettivi

Per un modello linguistico, l'assenza di un apparato sensoriale rappresenta probabilmente il principale limite nella capacità di replicare fedelmente le risposte umane, soprattutto quando queste riguardano la percezione. I modelli non hanno accesso diretto all'esperienza sensoriale del mondo e devono quindi inferire il significato solo a partire da regolarità statistiche nel testo.

Alcuni risultati sperimentali suggeriscono però che anche un addestramento esclusivamente testuale consenta ai LLM di catturare, almeno in parte, proprietà percettive del significato. In altre parole, certe informazioni sembrano emergere indirettamente dalla distribuzione delle parole nei corpora. È stato osservato, ad esempio, che gli embedding dei termini di colore si organizzano nello spazio vettoriale in modo topologicamente simile allo spazio CIELAB, un sistema di codifica dei colori che riflette le somiglianze percettive tra tonalità (Cuskley et al.; 2024).

Tuttavia, ai fini di una simulazione cognitivamente plausibile, la sola competenza statistica non può sostituire completamente quella percettiva. Evidenze in questa direzione provengono da studi sulla replicazione di giudizi percettivi (Conde et al.; 2025) (Trott; 2024). In questi lavori, gli autori hanno utilizzato dataset che raccoglievano valutazioni umane sull'intensità dell'associazione tra parole e diverse modalità percettive, tra cui tatto, udito, gusto, vista, olfatto e interocezione, insieme alle istruzioni sperimentali originali.

I risultati mostrano che nessun modello, incluso GPT-4o (la cui performance rappresenta un po' il gold standard dei modelli), raggiunge una correlazione con i giudizi umani superiore alla soglia ideale di 0.8. Inoltre, le correlazioni ottenute sui compiti percettivi sono sistematicamente più basse rispetto a quelle che gli stessi modelli raggiungono in task di rating su dimensioni non percettive. Questo conferma che le rappresentazioni costruite a partire da soli dati testuali possano surrogare solo parzialmente quelle che integrano l'esperienza sensoriale, ovvero quelle umane.

Giudizi psicologico-semantic

Quanto a dimensioni come la concretezza, l'immaginabilità, la somiglianza di significato fra due parole, etc., la correlazione tra giudizi umani e sintetici è più promettente. Rifacendoci ancora agli studi di (Conde et al.; 2025) e (Trott; 2024), GPT-4 ha ottenuto coefficienti di correlazione quasi sempre medio-alti, con picchi che entravano nella fascia di accettabilità per immaginabilità, similarità, valenza, familiarità, concretezza e relazione semantica in contesto.

Naturalmente i giudizi non sono del tutto sovrapponibili, ed è possibile rintracciare dei pattern negli errori di GPT-4. Ad esempio, il modello tende a valutare gli antonimi come più semanticamente simili rispetto ai giudizi umani, e lo stesso accade per coppie complementari come "incline/decline", "win/defeat", "die/kill", "spring/fall" (Trott; 2024). La spiegazione risiede nello sbilanciamento della loro competenza semantica: i modelli apprendono in modo molto efficace le relazioni sintagmatiche (*in praesentia*), cioè tra parole che ricorrono negli stessi contesti, principio alla base dell'ipotesi distribuzionale; le relazioni paradigmatiche di una parola, invece, sono ricostruite indirettamente proprio a partire dalle relazioni sintagmatiche che intrattiene con tutte le altre. Se una strategia del genere è spesso sufficiente per i sinonimi, risulta inaffidabile per antonimi e complementari: parole come "win" e "defeat" condividono i contesti d'uso, ma non il significato.

(Trott; 2024) svolge anche un'altra analisi sui dati, che risulta estremamente rilevante per la questione della sostituzione dei tester umani coi LLM. Trott calcola una serie di correlazioni sia tra le variabili umane che tra quelle sintetiche, osservando se e quanto cambiano i coefficienti nelle due condizioni. Questo confronto permette di rispondere in modo diretto alla domanda centrale della questione: quanto cambierebbero le conclusioni di uno studio psicolinguistico se invece di basarsi su dati umani si basasse su dati prodotti da LLM?

I risultati sono anche in questo caso promettenti, ma testimoniano ancora l'im maturità di un qualsiasi progetto di sostituzione integrale: tutte le correlazioni calcolate a partire da dati sintetici avevano la stessa direzione del loro analogo basato su dati reali; tuttavia la grandezza dei coefficienti varia significativamente tra la condizione reale e quella sintetica, come nel caso della correlazione tra l'età di acquisizione e l'iconicità di

una parola, o tra l'iconicità e la familiarità.

A proposito di questi risultati, è però necessaria una precisazione metodologica tutt'altro che marginale: sia in (Conde et al.; 2025) sia in (Trott; 2024), tutti i dataset replicati erano stati pubblicati diversi anni prima del knowledge cutoff dei modelli utilizzati negli esperimenti. Questo espone gli studi a un rischio concreto di data leakage e impedisce quindi di interpretare le buone performance osservate come una prova diretta e non ambigua della reale competenza dei modelli.

Proprio la rilevanza di questo problema ha motivato (Ravelli and Bolognesi; 2024) a progettare uno studio che introduce un'attenzione metodologica inedita rispetto alla letteratura precedente. L'elemento di novità consiste nel valutare la convergenza tra giudizi umani e sintetici su task e dati certamente non disponibili al modello in fase di training. In particolare, Ravelli e Bolognesi testano modelli quantizzati su un compito di specificità semantico-lessicale, volto a verificare se il modello abbia sviluppato una rappresentazione delle gerarchie concettuali comparabile a quella umana, almeno a livello funzionale. Il task richiede di selezionare, tra quattro alternative (ad es. “theory, insect, cell, kiss”), il termine più specifico. Per simulare la variabilità interindividuale umana, ogni modello esegue il compito dodici volte con temperatura 0.8; i coefficienti di correlazione riportati derivano quindi dalla media delle diverse esecuzioni.

I risultati indicano che i modelli locali quantizzati di dimensioni contenute, come LLaMa-3.1-8B, Phi-3-3.8B e Mistral-7B, mostrano correlazioni positive ma ancora troppo basse (tra 0.119 e 0.371) per poter essere considerati sostituti affidabili dei partecipanti umani: il loro impiego risulta più appropriato per prove preliminari o studi pilota su hardware personale, piuttosto che per analisi definitive. Diverso è il caso di Mixtral-47B, che raggiunge una correlazione pari a 0.636: un valore promettente, pur restando sotto la soglia ideale, soprattutto considerando che si tratta di un modello quantizzato. In proporzione, questa performance compete con quella di GPT-4 (0.772), che coi suoi circa 1.76 trilioni di parametri costituisce il machine gold standard. La comparabilità delle due performance è probabilmente da attribuirsi all'architettura di tipo MoE, che caratterizza entrambi i modelli.

La capacità di questi ultimi modelli di inferire la specificità lessicale rappresenta un contributo innovativo per il settore, poiché indica una capacità di astrazione che va oltre la semplice riproduzione dei pattern presenti nei dati di training. Questi dati vanno quindi a sostegno di un progetto per l'ampliamento dei dataset psicolinguistici attraverso l'automatizzazione della generazione di giudizi, senza andare a discapito dell'affidabilità dei risultati.

Giudizi statistici

Questo tipo di giudizi, a differenza di quelli percettivi, riguarda direttamente le informazioni statistiche sulla lingua, cioè proprio il tipo di regolarità che i modelli

apprendono durante il training. Paradossalmente, però, questa vicinanza costituisce un limite quando l'obiettivo è replicare fedelmente le risposte umane: sulle statistiche linguistiche sono spesso gli esseri umani a essere meno accurati, a causa dei vincoli della memoria e dei limiti della cognizione.

L'esperimento di (Zhong et al.; 2025) conferma questo punto. Nello studio modelli e partecipanti umani dovevano produrre delle stime sulla frequenza, la dispersione e la forza di associazione tra le parole che formavano una multi-word expression binomiale. Entrambi i gruppi hanno fornito giudizi imprecisi rispetto ai valori reali estratti dai corpora; inoltre, sia i modelli che gli esseri umani hanno predetto meglio la frequenza e peggio dispersione e forza di associazione. Tuttavia, le previsioni dei modelli risultano mediamente più vicine ai dati effettivi.

Emergono, poi, altre differenze: i modelli mostrano sensibilità variabile a seconda della misura statistica considerata, mentre gli esseri umani presentano una competenza più uniforme (e complessivamente limitata) su tutte le dimensioni.

Gli autori concludono quindi che i language model possono essere usati per approssimare la conoscenza umana di misure corpus-based, ma non per simulare il comportamento umano in esperimenti che mirano a studiare proprio i limiti della sensibilità statistica delle persone.

2.3.4 Tiriamo le fila sulla questione

Come emerso nei paragrafi precedenti, ci sono validi motivi empirici e teoretici per essere scettici sull'uso dei LLM come sostituti degli umani negli esperimenti psicolinguistici. E tuttavia, non sono pochi i risultati sperimentali in cui i modelli dimostrano la convergenza dei loro pattern di risposta con quelli umani, pur con ampi margini di miglioramento.

Stando così le cose, una prospettiva di ricerca efficace consiste probabilmente in una via di mezzo tra il rifiutare radicalmente la sostituzione e l'applicare acriticamente un paradigma ancora evidentemente immaturo. Piuttosto, vale la pena progredire con la ricerca in questo ambito, esplorando la possibilità della sostituzione pur prendendo le giuste precauzioni contro le limitazioni dei LLM come simulatori della cognizione umana.

In quest'ottica, (Dillion et al.; 2023) propongono di sperimentare l'uso dei modelli come sostituti, nella consapevolezza che questi si rivelano utili e non deleteri per la ricerca solo se impiegati limitatamente a certi oggetti di studio, certi task, certe fasi sperimentali e certi campioni da rappresentare.

Per Dillion e colleghi, un LLM può essere un tester papabile in ambiti sperimentali in cui il giudizio che si richiede dipende da variabili linguistiche a cui si fa esplicito riferimento nel prompt-istruzione (es: esperimenti sul comportamento economico in cui si chiarisce nel prompt a quali azioni corrispondono certe ricompense a quali condizioni). Quanto al tipo di task su cui ha senso impiegare i language models, Dillion e colleghi

sottolineano che essi sono particolarmente utili nei compiti lunghi, ripetitivi e noiosi. In questi casi possono risultare, per certi aspetti, perfino preferibili ai partecipanti umani: non sono soggetti a fatica, cali di attenzione o perdita di motivazione e quindi mantengono una coerenza di risposta elevata. Questo li rende efficienti per esplorare sistematicamente grandi insiemi di stimoli e per ottenere pattern stabili di giudizio medio.

I modelli, inoltre, non devono necessariamente essere usati come campione principale nella fase centrale dell'esperimento. Possono invece essere impiegati fruttuosamente nelle fasi preliminari del progetto, per esempio per testare la bontà delle ipotesi e verificare se gli stimoli linguistici producono le risposte attese. Possono anche essere utilizzati nelle fasi finali per confermare i risultati umani attraverso il confronto con quelli simulati, e ottenere un'ulteriore evidenza. In alcuni casi, quando esiste già evidenza empirica di alta correlazione con i giudizi umani nello stesso dominio, è ragionevole includerli anche nella fase centrale, aggregandoli ai dati raccolti su partecipanti umani, e non sostituendoli (Trott; 2024). Infine, è importante considerare i limiti di rappresentatività: i LLM riflettono soprattutto i pattern linguistici di una popolazione specifica, in prevalenza parlanti adulti, occidentali e anglofoni. Di conseguenza, i risultati ottenuti con i modelli non sono automaticamente generalizzabili ad altre popolazioni, culture o varietà linguistiche. Quando l'obiettivo è studiare gruppi non ben rappresentati nei dati di addestramento, quindi, l'uso esclusivo dei LLM come partecipanti sperimentali non è metodologicamente giustificato.

Chiudiamo con un'osservazione fondamentale: per capire quanto siano affidabili le norme prodotte dai modelli linguistici, sarà sempre necessario confrontarle con un benchmark umano, che quindi dovrà sempre essere disponibile. Non dovremo quindi mai smettere di testare (anche) gli umani. In assenza di questo punto di riferimento, i dati rischiano di andare silenziosamente alla deriva e spostarsi progressivamente verso le distorsioni statistiche applicate tipicamente dai LLM, finendo per influenzare e rimodellare in modo fuorviante le nostre teorie scientifiche in ambito psicolinguistico e cognitivo in genere (Trott; 2024).

Capitolo 3

La metafora negli esseri umani e nei modelli di linguaggio

La metafora è un fenomeno che si manifesta sul confine tra filosofia, linguistica, psicologia e scienze cognitive, ma nel corso di questo capitolo il discorso sconfinerà anche nell'ambito della linguistica computazionale e della ricerca sui modelli di linguaggio. Dopo aver presentato varie prospettive su cosa si intenda per metafora a vari livelli di analisi, passeremo infatti a confrontare il modo in cui gli esseri umani comprendono e percepiscono le metafore col modo in cui lo fanno i LLM.

3.1 Cos'è una metafora?

In questa prima sezione verranno introdotte le principali concezioni linguistico-filosofiche che cercano di definire in cosa consista in via essenziale il fenomeno metaforico. Partendo dalla teoria sostitutiva e da quella comparativa, verranno poi presentate le posizioni di filosofi che si sono occupati di linguaggio e mente umana: John Searle, Donald Davidson e Max Black. Tuttavia, uno spazio privilegiato verrà concesso all'ultima posizione presentata, quella del linguista George Lakoff, in virtù della rilevanza che la sua prospettiva per le considerazioni che faremo a proposito della metafora nei language model.

L'ordine in cui le teorie verranno presentate rispecchia la centralità che queste assegnano alla metafora nella cognizione umana. Un primo gruppo di teorie, definite per l'appunto *non cognitive*, concepisce la metafora come un'entità puramente linguistica e formale; a seguire troviamo una prospettiva ibrida, in cui le espressioni metaforiche sono inquadrare come strumenti in grado di spiegare o arricchire certi aspetti di ciò che percepiamo come reale; infine, l'ultima teoria, quella della Metafora concettuale, propone che la metafora sia il fenomeno cognitivo centrale del nostro modo di concettualizzare la realtà.

3.1.1 Prospettive non cognitive

Teoria sostitutiva

Secondo la teoria sostitutiva del significato metaforico, la metafora sostituisce il significato letterale di un'espressione con il significato letterale di un'altra espressione. Usare metaforicamente un termine vuol dire semplicemente porlo in un contesto semantico estraneo rispetto al suo significato usuale. Così facendo al lettore viene posta una sorta di sfida: confrontando il significato letterale dell'espressione usata metaforicamente e il contesto frasale dato, dovrà risalire a quell'espressione il cui significato letterale risulta adatto a quel contesto. In questo senso, quindi, l'efficacia di una metafora dipende da due caratteristiche del suo significato letterale (Black; 1955). Quest'ultimo deve essere abbastanza anomalo da innescare la ricerca di un sostituto, ma comunque dotato di certe analogie col significato dell'espressione che può sostituirsi alla metafora, in modo da permetterne l'identificazione.

Ma perché dire una cosa intendendone un'altra? Secondo Black possono esserci almeno due motivi.

Può essere che in una certa lingua non esista un termine per designare qualcosa oppure che non ci sia un modo preciso e breve di denotarla (Black; 1955). Ad esempio, diciamo "occhio di lince" perché pur potendo magari esprimere lo stesso significato attraverso una perifrasi, la metafora risulta più conveniente in quanto immediata e breve. In questi casi, quindi, o per sopperire a mancanze del lessico letterale o per evitare lunghi e scomodi giri di parole, vale la pena ricorrere ad una metafora.

In alternativa, ciò che può spingere un autore a produrre una metafora potrebbe essere l'intenzione di dare piacere al lettore, il quale apprezzerrebbe sia la sfida di rintracciare il significato inteso sia l'abilità di chi scrive di sorprendere con analogie inaspettate. (Black; 1955)

Teoria comparativa

La teoria comparativa della metafora consiste in un caso particolare di quella sostitutiva. Fatto salvo che ogni operazione metaforica può avvenire in forza di una qualche analogia o somiglianza tra gli elementi coinvolti, la teoria comparativa prevede che una metafora possa essere sostituita da un'equivalente espressione di comparazione (Black; 1955). In breve, il significato metaforico di un'espressione è uguale a quello letterale della similitudine corrispondente (Davidson; 1978). Ad esempio, "Cosimo è una scimmia" corrisponderebbe a "Cosimo è come una scimmia".

Ora, per quanto metafora e similitudine possano equivalersi nel significato, emergono certe differenze evidenti e quindi non trascurabili. Innanzitutto, le metafore non pongono esplicitamente una predicazione di somiglianza fra entità, cosa che invece fa la similitudine. Inoltre, tutte le similitudini sono vere, visto che comunque ogni cosa è simile ad ogni altra cosa se si sceglie accuratamente il rispetto a cui fare riferimento.

Di converso, quasi tutte le metafore sono false se intese letteralmente (Davidson; 1978). Inoltre, se pure è vero che tutte le metafore sono comparazioni, non tutte le comparazioni sono metafore.

Questa teoria non va confusa, ci tiene a precisare Davidson, con quella secondo cui ogni metafora non è altro che una similitudine ellittica, a cui cioè è stata rimossa la congiunzione "come" (teoria che tra l'altro risale allo stesso Aristotele (Searle; 1979)). In quest'ultima concezione, infatti, non c'è un significato metaforico distinto da quello letterale. La similitudine non costituisce una parafrasi letterale del significato figurato associato alla metafora, che invece è un'abbreviazione della similitudine stessa, e in quanto tale non ha un significato distinto. (Davidson; 1978)

La teoria comparativa ha il pregio di allinearsi col senso comune, anche se questo non l'ha di certo resa immune alle critiche. Uno degli argomenti più rilevanti contro la teoria in questione arriva da Lakoff. L'esempio da cui prende le mosse è "Achille è un leone". Secondo i comparativisti la frase corrisponderebbe ad una similitudine fra Achille e un leone. Volendo assegnare un significato letterale esplicito si dovrebbe stabilire il rispetto guardando al quale si instaura la comparazione, il quale in questo caso è evidentemente il coraggio, caratteristica stereotipica del leone. Ora, perché effettivamente si possa dire che Achille ed il leone si equivalgono sotto il rispetto del coraggio, bisogna che entrambi godano della stessa proprietà. Tuttavia il coraggio è un tratto che appartiene agli esseri umani e che può essere attribuito solo metaforicamente al leone. Piuttosto, quest'ultimo è dotato di una disposizione istintiva che noi ci spieghiamo nei termini del coraggio umano. In definitiva, non ha senso pensare di poter rendere esplicita una qualche somiglianza letterale fra uomo e leone sostituendo alla metafora la corrispondente similitudine, poiché proprio questa somiglianza si rivela irrimediabilmente metaforica. (Lakoff and Turner; 1989)

Un'altra importante voce polemica è quella di Searle, secondo il quale una visione in cui ogni metafora è una similitudine ellittica risulta priva di qualsiasi potere esplicativo. Una Teoria della metafora, infatti, deve spiegare come parlante e ascoltatore riescano a passare da "X è A" a "X è B" (laddove A corrisponde al significato letterale dell'espressione usata metaforicamente, e B corrisponde al significato inteso). Dire che per arrivare a "X è B" si deve passare da "X è come B" può forse avere un valore nell'ambito di una teoria della comprensione, ma di certo non spiega alcunché nell'ottica di una teoria del significato, e anzi rimanda solo il problema. (Searle; 1979)

La prospettiva di Searle

Per Searle, il significato metaforico non solo ha a che fare esclusivamente con la pragmatica del linguaggio e non con i sistemi concettuali, ma non è nemmeno un significato vero e proprio. Infatti ogni significato metaforico in una certa frase non è altro che un significato letterale di una frase diversa (Lakoff; 1993). Se, quindi, Searle sembra disposto ad appoggiare la teoria sostitutiva, d'altra parte respinge senz'altro

quella comparativa. Una metafora ed una similitudine, per quanto questa possa corrisponderle, avranno nella maggior parte dei casi condizioni di verità diverse, e questo basta perché siano insostituibili l'una all'altra. (Searle; 1979)

Secondo Searle, la metafora è un caso specifico del fenomeno per cui a volte diciamo qualcosa intendendo altro. Per capire il suo funzionamento, infatti, bisogna risolvere un problema preciso: come fanno il significato letterale di una frase metaforica e quello inteso dal parlante ad essere diversi e tuttavia legati fra loro? (Searle; 1979)

Ogni frase letterale pone delle condizioni di verità, che non necessariamente sono presentate in modo esplicito dentro alla frase stessa, ma possono far parte di un background implicito. Se ad esempio dico "il gatto è sul tavolo" pongo come condizione implicita che nella data situazione ci sia una forza di gravità esercitata verso un certo punto tale per cui possiamo distinguere il sopra dal sotto. Ad ogni modo, una frase intesa metaforicamente è vera se è solo se la corrispondente parafrasi è vera, cioè se le condizioni di verità da lei poste trovano soddisfazione nella realtà. (Searle; 1979)

Searle non reputa valida una spiegazione della metafora che faccia ricorso ad ulteriori metafore. Spesso e volentieri, infatti, visioni del genere finiscono per mascherare da somiglianza quella che in realtà è un'associazione metaforica, e che in teoria dovrebbe fungere da principio esplicativo, ma in pratica porta solo ad un regresso all'infinito. Si pensi ai termini spaziali che usiamo metaforicamente per parlare del tempo: "il tempo vola", "il tempo scorre", etc. Un comparatista direbbe che il tempo fa qualcosa di effettivamente simile al volare e allo scorrere, e magari proverebbe a parafrasare: "il tempo va veloce" e "il tempo procede lento e costante"; tuttavia così facendo si produrrebbero solo altre metafore. Per quanto ci venga naturale e ci si ostini a vedere il passaggio del tempo come qualcosa di letteralmente simile al movimento nello spazio, si deve in definitiva riconoscere che persino il termine "passaggio" è una metafora spaziale e che non c'è alcuna analogia effettiva fra tempo e spazio (Searle; 1979). Quella che viene scambiata per somiglianza è in ultima analisi un'associazione metaforica imposta dal nostro modo di percepire le cose.

Concludendo, se pure Searle sostiene che la miglior parafrasi di una metafora consiste in una frase che ne replica le condizioni di verità, riconosce anche che nella comunicazione metaforica avviene qualcosa di più oltre alla trasmissione di tali condizioni. In particolare, nella metafora l'ascoltatore o il lettore devono arrivare a capire cosa intende chi parla o scrive attraverso uno sforzo attivo, diverso dalla mera ricezione di informazioni letterali. Il fruitore della metafora, quindi, contribuisce all'atto comunicativo stesso, e lo fa arrivando al contenuto semantico inteso passando per un altro contenuto ad esso collegato. (Searle; 1979)

La prospettiva di Davidson

Per Davidson gli unici significati che esistono sono quelli letterali. Le metafore, infatti, non significano qualcosa di più oltre alla loro interpretazione più letterale. Non a

caso Davidson si oppone a qualunque teoria distingua fra un significato figurato ed uno letterale, compresa quella sostitutiva. La particolarità della metafora rispetto agli altri elementi linguistici non sta nel suo significato ma nel suo uso. (Davidson; 1978) Nel momento in cui si usa una parola in senso metaforico il suo significato originale non viene esteso; infatti questo vorrebbe dire indicare un nuovo significato letterale per quella parola. Bisogna invece fare una distinzione: un conto è imparare un nuovo significato di una parola che stiamo imparando a conoscere, un altro è usare una parola già conosciuta per denotare qualcosa di del tutto inedito (Davidson; 1978). Il caso delle metafore alatamente convenzionalizzate è paradigmatico: nel momento in cui l'espressione "perdere le staffe" (riferita ad una persona in una discussione) viene spogliata della sua carica metaforica e diventa un modo di dire comune, non è che un suo presunto significato figurato e speciale viene assorbito nell'ambito di denotazione del termine letterale "arrabbiarsi", ma piuttosto "perdere le staffe" comincia ad avere la stessa denotazione di "arrabbiarsi". Questo non toglie il fatto che mentre la metafora era ancora attiva evocava nella sua denotazione letterale (l'unica che esiste per Davidson) scossoni, concitazione e nitriti violenti. (Davidson; 1978) Pur essendo innegabile che le metafore ci sorprendono mostrandoci analogie mai scorte, bisogna precisare che tutto ciò non costituisce un qualche contenuto cognitivo speciale. Piuttosto, ciò ha a che fare con l'effetto che le metafore hanno su di noi[26]. Esse evocano e lasciano intendere, ma non significano. Non denotano certe immagini, piuttosto le connotano. Le metafore sono portatrici di significati letterali che ci ispirano intuizioni e visioni che spesso e volentieri non sono semplici riconoscimenti di dati di fatto. Perciò quando parafrasiamo una metafora non possiamo aspettarci di esplicitare il suo significato, visto che questo è già bello che esplicito nel termine metaforico stesso. Se proprio esplicitiamo qualcosa, questo è ciò che la metafora connota, cioè le immagini che evoca. Prova ulteriore che le immagini e le analogie evocate dalla metafora non costituiscono il suo significato è che esse sono praticamente infinite e quasi mai hanno carattere proposizionale, motivo per cui siamo sempre così dubbiosi quando vogliamo rendere esplicito il supposto significato metaforico di un termine.[27]

3.1.2 La teoria interattiva di Black: una prospettiva ibrida

Black si posiziona a metà strada fra coloro che non riconoscono alla metafora alcun ruolo nella cognizione e chi, invece, ritiene che sia un meccanismo pervasivo delle dinamiche cognitive.

Contrariamente a Searle, Black sostiene che il significato metaforico esiste e che, quindi, la metafora ha a che fare non tanto con la sintassi e la forma del linguaggio, quanto con la semantica stessa (Black; 1955). In particolare, la concezione di Black è degna di essere annoverata fra quelle cognitive poiché, opponendosi sia alla teoria comparativa che a quella sostitutiva, prevede che la metafora non può essere sostituita né da una similitudine corrispondente né da qualsiasi altra espressione letterale, e che

tale insostituibilità non dipenda dal suo ruolo di strumento cognitivo: la metafora permette scorci, intuizioni, accrescimenti di conoscenza che gli eventuali sostituti non permetterebbero (Black; 1955). Questa produttività epistemologica non implica naturalmente la creazione di nuove relazioni di analogia fra le cose. Per capire cosa intende Black dobbiamo adottare un atteggiamento relativistico in cui la realtà è necessariamente vista da una certa prospettiva: ogni cosa che esperiamo nel quotidiano dipende nei suoi caratteri dalla nostra specifica dotazione sensoriale come esseri umani. A questo punto, allora, appare sensato affermare che le metafore aiutano a costruire e articolare la nostra realtà soggettiva (individuale o collettiva), rendendoci in grado di scorgere nuovi aspetti dell'esistente. (Black; 1979)

Black è fautore della Teoria interattiva della metafora (Ervias et al.; 2016). Nella sua prospettiva, quando percepiamo o produciamo una metafora, nella nostra mente sono attivi due pensieri relativi a due domini conoscitivi diversi. Dall'interazione di questi due pensieri scaturisce un significato ulteriore, che non può essere ricavato da ciascuno dei due domini preso singolarmente. Black distingue poi un soggetto primario da uno secondario. Quest'ultimo è il significato letterale dell'espressione metaforica, mentre il primo consiste in ciò che intendiamo descrivere, l'obiettivo della nostra predicazione.

L'esempio tipico è quello della metafora "l'uomo è un lupo" (estrapolata dal detto latino "homo homini lupus"). La parola "lupo" in questo contesto è dotata di un nuovo significato, che non corrisponde né al significato letterale della parola nel suo uso comune né al significato letterale di un termine che possa fungere da sostituto in caso di parafrasi. Inoltre, "lupo" svolge la funzione di soggetto sussidiario, mentre "uomo" quella di soggetto principale. (Black; 1955)

Black fa notare che per capire la metafora non è necessario conoscere la definizione ufficiale del soggetto sussidiario, quanto piuttosto aver presente quello che lui chiama *system of associated commonplaces*. Bisogna, ad esempio, aver presente gli stereotipi e le idee associate alla figura del lupo, come il fatto che sia aggressivo e selvatico. L'efficacia della metafora, d'altra parte, non dipende dalla veridicità dei luoghi comuni associati al soggetto sussidiario, ma da quanto questi siano radicati e disponibili alla mente del lettore o ascoltatore. Non a caso al variare della cultura e quindi dei modi di pensare e dei luoghi comuni, la stessa metafora varia in efficacia. (Black; 1955)

Ma esattamente in cosa consiste l'interazione fra i due soggetti? Nel momento in cui un uomo viene chiamato "lupo", un sistema di luoghi comuni associati viene evocato e poi riferito al soggetto principale. Naturalmente non tutte le caratteristiche stereotipiche del lupo possono essere applicate sensatamente a un uomo a prescindere dal contesto e senza alcun accorgimento semantico. Ad esempio, dire che un uomo sbrana le sue prede ha senso se si inquadra il contesto della frase e si manipola il significato standard della predicazione: l'uomo in questione potrebbe essere uno scaltro venditore che trova il modo di scucire molti soldi ai suoi clienti; parallelamente, il significato di "sbranare le proprie prede" muta in modo da includere la dinamica appena descritta. Tale cambiamento non ha la forma di uno spostamento o traslazione, altrimenti la metafora primaria ("l'uomo è un lupo") verrebbe spiegata circolarmente come l'insieme

di sottometafore ("l'uomo sbrana le sue prede", "l'uomo è selvatico" etc). Quello che avviene è piuttosto un'estensione del significato. (Black; 1955)

Ad ogni modo, il meccanismo centrale ipotizzato dalla teoria interattiva consiste nella riorganizzazione interna dei due concetti coinvolti nella metafora. Affinché ciò che si ritiene sia vero per il lupo possa essere riferito in modo sensato e costruttivo a un uomo, non basta che i luoghi comuni associati al soggetto sussidiario estendano il loro significato, ma bisogna anche che del soggetto primario si facciano risaltare alcuni aspetti e se ne adombrino altri. I due concetti si vengono incontro l'un l'altro per poi convergere nel significato metaforico, in cui, il lupo si umanizza e l'uomo si fa "lupigno". (Ervas et al.; 2016)

È proprio attraverso una metafora, infine, che Black chiarisce in che modo vada inteso il significato metaforico: esso è quanto del soggetto primario si riesce a scorgere attraverso la lente imposta dal soggetto sussidiario e dal suo *system of associated commonplaces*. Ogni espressione metaforica filtra e trasforma gli aspetti che caratterizzano il soggetto da descrivere, cosicché non soltanto la metafora fa affiorare tratti inediti di un certo soggetto rispetto a quelli evocati dalla sua denotazione letterale, ma al variare dell'espressione metaforica cambiano anche gli aspetti che vengono fatti affiorare o che vengono affossati. Se per esempio si descrive una battaglia nei termini di una partita a scacchi, l'uso del lessico della logica del gioco esalteranno la caratterizzazione strategica della guerra, mentre verrà meno l'attenzione alla dimensione emotiva e alla sua tragicità. (Black; 1955)

3.1.3 Teoria della metafora concettuale

Oltre il linguaggio

L'analisi linguistica è quantomai utile allo studio delle metafore, ma non è nel livello linguistico che si esaurisce il loro carattere. È proprio a partire da questa intuizione che si sviluppa la *Conceptual Metaphor Theory* (CMT) elaborata da Lakoff. Si tratta di una prospettiva nata nell'ambito della linguistica cognitiva e dalla collaborazione col filosofo Mark Johnson. La tesi centrale è che il fenomeno metaforico non abiti tanto il linguaggio, quanto il nostro sistema concettuale (Lakoff; 1993), il quale inevitabilmente trova espressione proprio attraverso il linguaggio. Per Lakoff, la metafora costituisce la cifra caratterizzante di gran parte delle operazioni cognitive e consiste nella creazione di una mappa trasversale a due domini concettuali diversi, in modo tale che uno sia compreso nei termini dell'altro.

Ricorrendo per l'appunto ad una metafora, possiamo descrivere ogni espressione metaforica come un iceberg che in minima parte affiora in superficie, mentre la maggior parte della sua massa resta sotto il livello dell'acqua. Le metafore, infatti, si rendono disponibili alla percezione di un lettore o di un ascoltatore sotto forma di espressioni linguistiche, ma la loro natura più autentica e preponderante è quella meno manifesta di schemi di pensiero.

L'uso delle metafore è semplicemente inevitabile nel parlare comune (e.g. "non sto seguendo il tuo discorso", "non ho spazio di manovra col mio capo", etc.). Il fatto che di primo acchito faticiamo a riconoscerlo è dovuto al carattere convenzionale ed inconscio di molte di esse. Addirittura a volte, le metafore passano così inosservate che l'uso letterale di un'espressione finisce per costituire l'eccezione alla regola più che la situazione standard.

A testimonianza della pervasività delle metafore in qualsiasi prodotto linguistico citerò un breve estratto da un saggio consultato per la stesura di questa stessa tesi, la cui natura affatto poetica non gli evita di ricorrere a significati figurati, anzi:

"A partire dagli anni Ottanta, in semantica cognitiva *si fa strada* una *corrente* di studi *fondata* sull'idea che la metafora *rifletta* processi di categorizzazione in cui la *comprensione* della somiglianza o della similarità non è affatto *cruciale*." (Ervás et al.; 2016)

La portata cognitiva della metafora ha implicazioni importanti: innanzitutto, se i processi metaforici caratterizzano gran parte del pensiero, allora devono essere presenti anche nel linguaggio quotidiano e non solo in quello retorico-poetico; inoltre, dal momento che il modo in cui pensiamo influenza il nostro agire, le interazioni che abbiamo con gli altri, e persino come percepiamo le cose, le metafore che formano il nostro sistema concettuale non si limitano alla regolazione di dinamiche intellettuali, ma riguardano anche tutti i suddetti ambiti. (Lakoff and Johnson; 1998)

Il sistema metaforico

Ogni operazione metaforica consiste nel mappare un dominio dell'esperienza, che svolge il ruolo di *target*, secondo gli schemi relativi ad un dominio differente, che funge da *source* di tali schemi (Lakoff; 1993), cosicché la conoscenza degli elementi e della logica che caratterizzano il dominio di partenza permetta di orientarsi anche nel dominio di arrivo. Le metafore, infatti, sono caratterizzate da generalizzazione inferenziale: i ragionamenti validi per la source sono applicabili ed efficaci anche per il target (Lakoff; 1993).

La strutturazione metaforica che un concetto subisce da parte di un altro è sempre parziale. Se fosse totale, vorrebbe dire che i due concetti coincidono e non che l'uno è compreso nei termini dell'altro. Non a caso, metafore dotate di domini di partenza diversi ma riferite allo stesso target, mettono a fuoco aspetti differenti del medesimo concetto (e.g. una discussione è una guerra vs una discussione è una cooperazione) (Lakoff and Johnson; 1998). A guidare la scelta delle basi concrete per la strutturazione di un concetto astratto è il contesto culturale della comunità di parlanti (e pensanti) (Lakoff and Johnson; 1998). Ad esempio, la metafora il TEMPO è DENARO è tipica delle società industriali della moderna cultura occidentale, nella quale i dipendenti vengono pagati ad ore, gli interessi dei prestiti aumentano col passare del tempo, e nella quale sono diffuse espressioni come "investire tempo" o "risparmiare tempo"

(Lakoff and Johnson; 1998). La metaforizzazione parziale e la messa a fuoco selettiva ricordano per certi versi quanto Black prevede che accada al soggetto primario della metafora, il quale viene 'visto' attraverso il soggetto sussidiario, e del quale vengono scelte ed enfatizzate solo le caratteristiche compatibili col soggetto sussidiario. Tuttavia le somiglianze con la teoria interattiva si fermano presto. Per Black, infatti, vedere un concetto attraverso la lente di un altro concetto consiste in un'operazione intellettuale (Black; 1955) e implica quindi una dinamica discorsiva e processuale. Secondo Lakoff, invece, le mappature metaforiche sono statiche. La proiezione degli schemi di un concetto sull'altro avviene istantaneamente e non attraverso una procedura algoritmica che fa corrispondere a input del source domain output del target domain. (Lakoff; 1993) La tesi di Lakoff non consiste nel sostenere che tutto il nostro sistema concettuale sia metaforico, anche perché pensandola così si configurerebbe un regresso all'infinito, in cui ogni concetto fonda ed è fondato da altri concetti. Sono invece solo i concetti astratti (e parte di quelli concreti) ad essere compresi metaforicamente. Alla base del nostro sistema concettuale ci sono i concetti che ci forgiamo attraverso la percezione sensoriale e l'interazione col mondo. Da questa base partono un numero potenzialmente infinito di trasferimenti metaforici che portano alla costituzione del sistema cognitivo umano nel suo complesso, il quale per la maggior parte è quindi formato da metafore, cioè da concetti strutturati in termini di altri concetti.

Ora, tra i concetti compresi senza mediazione metaforica, i più preziosi per la nostra cognizione sono probabilmente quelli spaziali (su-giù, davanti-dietro, dentro-fuori, vicino- lontano etc.). Tali concetti, infatti, gestiscono gran parte delle nostre attività quotidiane e si formano a partire da esperienze assai diffuse nella nostra vita, data la nostra natura di esseri dotati di capacità motoria. Naturalmente, lo sviluppo di tali concetti dipende anche da vincoli fisici esterni al nostro organismo: se ad esempio la gravità terrestre fosse quasi nulla, non avrebbe senso formarsi i concetti di su e giù, o comunque la loro rilevanza ne risulterebbe assai ridimensionata. (Lakoff and Johnson; 1998)

La strutturazione metaforica di molti concetti in termini spaziali scaturisce dalle sistematiche correlazioni esperienziali che viviamo fin dalla nascita. Espressioni come "i prezzi salgono" o "i miei voti sono in calo", testimoniano l'esistenza nel nostro sistema concettuale della metafora PIU' è SU e MENO è GIU' (si noti come l'analisi metaforica parte sempre da una ricognizione linguistica); infatti, per via della forza di gravità e della resistenza del terreno, all'aumentare della quantità di materia corrisponde uno sviluppo in verticale (molti oggetti si impilano o accumulano, il livello di un liquido versato in un recipiente sale). Dalle espressioni "è stato deciso ai piani alti" o "ho tutto sotto controllo" si evince che AVERE IL POTERE / CONTROLLO è SU e NON AVERLI è GIU'; infatti spesso chi vince un combattimento sta sopra al suo avversario e occupare una posizione spazialmente superiore permette di vedere e tenere sotto controllo un'area più grande. Infine, quando diciamo "mi sono alzato tardi" o "cadde in un sonno profondo" mettiamo in parole le metafore CONSCIO è SU e INCONSCIO è GIU'; d'altronde gli esseri umani, come molti altri mammiferi, dormono sdraiati e

stanno in posizione eretta da svegli (Lakoff and Johnson; 1998).

Ovviamente la dimensione della verticalità non è l'unico dominio spaziale metaforicamente prolifico. Si pensi a L'AMORE è UN VIAGGIO, nella cui logica la relazione amorosa corrisponde al veicolo, che fa avanzare i partner verso le varie mete degli obiettivi di coppia, attraverso salite, discese ed ostacoli (che corrispondono a sentimenti o a contingenze della vita). Altri concetti di comprensione immediata sulla cui conoscenza può fondarsi quella di concetti più astratti sono quelli di percezione. Tra questi, uno dei più importanti è il concetto di visione, sul quale si basa il nostro concetto di conoscenza (SAPERE è VEDERE), in quanto nella maggior parte dei casi ciò che sappiamo dipende da ciò che abbiamo visto[68]. Non a caso, in greco antico l'aoristo del verbo che significa vedere ha come significato principale quello di sapere.

Il dominio target di una metafora non è necessariamente astratto: un trasferimento metaforico può interconnettere anche due domini concreti. Il caso più interessante è probabilmente quello delle sinestesie, cioè di quelle metafore che definiscono un certo tipo di percezione sensoriale nei termini di un altro. Un esempio efficace è quello della sinestesia che consiste nell'associare la percezione visiva delle dimensioni di qualcosa alla percezione uditiva del suono che produce, in modo tale che più la cosa è piccola più saranno acuti i suoni che emette, mentre al crescere delle sue dimensioni corrisponderà un abbassamento della frequenza sonora. Un'associazione del genere non è innata, bensì, come tutte le altre correlazioni esperienziali, dipende dalle leggi fisiche che regolano il nostro universo: una grande cassa di risonanza produce onde sonore a bassa frequenza, che il nostro orecchio recepisce come suoni gravi; una cassa di risonanza dalle dimensioni modeste, invece, produce suoni ad alta frequenza, cioè acuti. Tale correlazione si manifesta quotidianamente, ogni qualvolta prestiamo orecchio alla voce di una donna o al verso di un cagnolino, in contrasto a quelli di un uomo o di un cane di grossa taglia (entrambi dotati di una cassa toracica di dimensioni maggiori). (Osgood; 2018)

Il fatto che esista una certa correlazione esperienziale non ci dice se la metafora corrispondente sia presente nel linguaggio, ma al massimo quale sarebbe la sua forma eventuale. La presenza di una correlazione tra verticalità positiva e quantità positiva non implica necessariamente che la metafora più è su sia codificata in ogni lingua, ma garantisce che nel caso lo sia non possa avere la forma inversa (più è giù), poiché sarebbe incoerente con l'esperienza comune a tutti gli esseri umani. (Lakoff; 1993)

Comprendere grazie alle metafore

Nella visione di Lakoff e Johnson, la metafora costituisce lo strumento fondamentale per la comprensione della realtà (Ervas et al.; 2016). L'essenza della metafora, infatti, sta nel capire una cosa nei termini di un'altra (Lakoff and Johnson; 1998). Metaforizzare può, sì, portare a visualizzare un certo concetto target in modo del tutto inedito e fruttuoso, ma nella gran parte dei casi la metafora costituisce proprio l'unica possibilità

di avere una qualsiasi comprensione di un concetto.

Nella logica della teoria sostitutiva, l'autore di una metafora sostituisce un significato letterale con uno figurato cosicché a chi sente o legge viene posta la sfida di invertire tale sostituzione. Si usa, cioè, la propria conoscenza del mondo per risalire al significato inteso (Black; 1955). Niente di più sbagliato secondo Lakoff: gli esseri umani non usano la conoscenza che hanno del mondo per capire le metafore, ma piuttosto è attraverso le metafore che capiamo il mondo e acquisiamo conoscenza su di esso. Le metafore non sono il fine della cognizione ma ne sono il mezzo. Non a caso, il maggior numero di espressioni metaforiche compare nel discorso scientifico (Ervas et al.; 2016), ambito esplicativo per eccellenza.

Al fine di orientarsi nel flusso continuo ed intricato dell'esperienza, la cognizione umana comprende parti di essa come oggetti e sostanze, rendendole quindi entità discrete. Infatti, solo quando le esperienze sono distinguibili fra loro possiamo individuarle e riferirci ad esse, categorizzarle, quantificarle e così via. Le metafore coinvolte in questa attività cognitiva basilare sono dette ontologiche e sono necessarie per riflettere razionalmente sulle nostre esperienze. Per fare qualche esempio, dal linguaggio di tutti i giorni emerge che gli eventi, le azioni e gli stati sono spesso visti come oggetti, in particolare come contenitori: "Eri nello spettacolo di ieri?", "Nell'imbiancare il muro ho imbrattato un mobile", "Sono in ansia per l'esame", etc. (Lakoff and Johnson; 1998) Per concludere, una metafora particolarmente importante è quella che rende conto del processo cognitivo che imbastiamo quando comprendiamo una dinamica generale a partire da un caso specifico. La metafora **GENERICO** è **SPECIFICO** occorre ogni qualvolta, per esempio, ci accingiamo a comprendere il significato di un proverbio. L'espressione idiomatica "chi va con lo zoppo impara a zoppicare", se presa letteralmente, ha un significato preciso dotato di una sua logica; intendendola metaforicamente, invece, lo schema specifico che struttura il suo significato letterale viene proiettato su un numero indefinito di domini esperienziali e situazioni diverse, i quali condividono la stessa struttura schematica al livello profondo[82]. In questo modo il generale viene compreso nei termini del particolare: attraverso la metafora, la situazione specifica descritta dal proverbio ci porta a capire la dinamica generale di ogni scenario in cui qualcuno influenza la condotta o l'aspetto di chi lo frequenta rendendolo simile a sé.

Metafora ed embodiment

Lakoff concepisce la sua CMT all'interno di una prospettiva radicalmente embodied e anti-cartesiana¹. Per lui la ragione umana non è solo qualcosa di inseparabile dal corpo, ma è anche fondata e costituita dal corpo, è parte di esso. La ragione, e più in generale

¹ Secondo Cartesio l'universo è formato da due tipi di sostanze: una materiale e una immateriale. In questa prospettiva le cose fisiche e gli stati mentali (percezioni, emozioni, concetti) costituiscono mondi distinti e paralleli. Le posizioni anti-cartesiane rifiutano questo dualismo abbracciando invece l'idea che tutto ciò che esiste è in quanto tale materiale

la coscienza, sono un insieme di capacità e di performance realizzate da elementi corporei (Lakoff and Johnson; 1999). D'altronde anche i nostri pensieri più astratti sono prodotti dallo stesso supporto fisico che permette il movimento e la percezione.

Una concezione del genere confluisce nel framework teorico della Embodied cognition. Ma quali sensi in cui si può dire che la mente sia incorporata sono rilevanti per la CMT?

Un primo senso consiste nel fatto che tutti i tipi di contenuti mentali che si manifestano nella nostra coscienza dipendono da come è fatto il nostro corpo e da quali sono le sue possibilità percettive. Ma andiamo per gradi: consideriamo una zecca. Ora, le zecche non hanno una dotazione sensoriale particolarmente ricca, infatti possono percepire solo tre tipi di stimoli: la luce (che le guida nell'arrampicarsi sui rami degli alberi), l'acido butirrico contenuto nel sudore dei mammiferi (che segnala loro la vicinanza di un animale su cui tentare di cadere) e il calore (dal quale capiscono se hanno centrato il bersaglio e possono procedere a mordere) (von Uexküll et al.; 2013). Questi tre tipi di sensazioni bastano alla zecca per vivere la sua vita. Essa vive in un mondo caratterizzato solo in termini di luce, presenza di acido butirrico e calore: le sue rappresentazioni mentali possono riguardare solo una di queste dimensioni. Noi esseri umani non siamo poi così diversi dalla zecca. Abbiamo, sì, un bel po' di dimensioni percettive in più con cui possiamo dipingere la nostra rappresentazione del mondo, ma ciò che può stare nella nostra mente è irrimediabilmente legato a ciò che può passare dai nostri sensi.

Lo stesso Lakoff afferma che "tutto ciò che può essere pensato è reso possibile e fortemente limitato dalla natura del nostro cervello" (Lakoff; 2008). Ma il legame fra teoria embodied e fenomeno metaforico risulta chiaro se si considera il fatto che l'operazione di mappatura metaforica costituisce la principale strategia per supplire ai vincoli che la corporeità impone alla nostra cognizione. Gli esseri umani, per esempio, non sono dotati di un senso adibito specificatamente alla percezione del tempo, come invece lo hanno per l'individuazione ed il riconoscimento di oggetti, proprietà fisiche, movimenti, etc. L'unico modo per percepire il tempo è concettualizzarlo a partire da ciò di cui abbiamo esperienza diretta, dunque attraverso una metafora (Lakoff; 1993). Il fatto di avere un certo corpo che funziona in un certo modo non lascia indifferente la configurazione assunta dall'esperienza cognitiva, la quale proprio nel corpo trova il suo supporto e la sua condizione di esistenza.

Un ulteriore senso in cui la mente può dirsi incorporata sta nella sua commistione al corpo. Il rapporto tra mente e corpo è in realtà un rapporto di supporto reciproco: la mente è parte del corpo e il corpo è parte della mente. Se infatti, la mente può essere funzionale al corpo, è anche vero che a volte il corpo serve la mente. Una situazione del genere si verifica ogni qual volta contiamo nella nostra testa immaginando le dita della mano, o quando progettando un nuovo assetto per i mobili della nostra stanza immaginiamo mentalmente di ruotarli o traslarli per ottenere la configurazione che ci soddisfa. In particolare quello che avviene dentro di noi è una simulazione motoria

(Wilson; 2002): gli stessi meccanismi e lo stesso supporto neurale che permettono l'azione vengono co-optati per servire il pensiero, ovvero per ottenere informazioni utili alla pianificazione o al calcolo.

Come vedremo approfonditamente nella sezione 3.3.1, proprio la simulazione mentale di azioni e situazioni costituisce, per i sostenitori della CMT, il meccanismo alla base della comprensione dei significati metaforici (Gibbs Jr; 2006). L'idea è che il processo che ci porta a comprendere un concetto astratto (il DESIDERIO) di cui abbiamo una concettualizzazione metaforica (il DESIDERIO è FAME) implichi la simulazione mentale di tutti gli aspetti motori o percettivi relativi all'ambito sorgente della metafora (la FAME). (Gibbs Jr and Matlock; 2008)

3.2 Le metafore non sono tutte uguali

Fin qui si è parlato di metafore come di una categoria omogenea, ma così non è. Non solo le metafore possono manifestarsi trasversalmente in tutte le classi lessicali piene (con uno sbilanciamento a favore dei verbi (Cameron; 1999)) ma possono distinguersi tra loro per almeno due ulteriori parametri: la forma sintattica e il livello di convenzionalità.

Per quanto riguarda il primo parametro, la forma sintattica, prendiamo in considerazione due frasi contenenti un significato metaforico:

1. "Certi poliziotti sono bestie feroci"
2. "Il poliziotto ci ringhiò di non muoverci"

La frase 1 costituisce una metafora diretta, la cui sintassi con copula rende chiaro che il primo elemento è descritto nei termini del secondo. Il significato metaforico della frase 2, invece, non traspare altrettanto facilmente dalla forma in cui è espressa. Infatti, il concetto metaforico di fondo è lo stesso di 1, ma ciò che è espresso esplicitamente in 2 è piuttosto un'implicazione di tale concetto: se alcuni poliziotti sono bestie feroci, allora posso descrivere il comando di un poliziotto come il ringhiare di un cane feroce. Metafore del genere sono dette indirette e si manifestano spesso nella lingua come nomi o verbi polisemici in strutture senza copula.

Se quindi nel leggere o nel sentire una metafora diretta il contrasto tra ciò che viene affermato letteralmente e la realtà delle cose ci risulta chiaro fin da subito, così non è per quelle indirette, in cui il significato figurato sembra celarsi un minimo. In virtù di questa maggiore intelligibilità e della schematicità della loro struttura, le metafore dirette hanno costituito lo standard per gran parte degli studi sulla metafora. Tuttavia, analisi su corpora hanno ormai dimostrato che la forma diretta non è affatto comune nel linguaggio quotidiano, che invece predilige le metafore indirette. (Horvat et al.; 2021)

In riferimento al parametro di convenzionalità, possiamo invece distinguere almeno tre tipi di metafore: morte, inattive e attive. Ognuna di esse corrisponde a un diverso range di convenzionalità lungo un continuum (Goatly; 2011).

Le metafore morte (dette anche catacresi) sono di fatto delle non metafore, poiché si sono talmente convenzionalizzate nell'uso per denotare certi referenti che non sono più percepite come significati figurati, bensì letterali. Esempi classici sono espressioni come "le gambe del tavolo" o "il collo della bottiglia", che ormai usiamo puramente come etichette denotative, senza considerare eventuali analogie tra le gambe umane e i paletti su cui si regge il tavolo, o tra il collo delle persone e la parte superiore e curva delle bottiglie, nonostante proprio su queste analogie si basassero tali metafore al tempo della loro nascita. Addirittura, (Goatly; 2011) sostiene che per le metafore morte si possa parlare di una relazione di omonimia che lega due forme uguali a due significati diversi e (ormai) semanticamente scollegati.

Nel caso delle espressioni metaforiche inattive, il livello di convenzionalità non è massimo, ma comunque abbastanza alto perché si possa parlare di polisemia: una stessa forma è associata a due significati diversi legati in senso metaforico. Ad esempio, il participio passato "abbattuto" può essere usato per parlare della condizione fisica di qualcosa o dello stato psicologico-morale di qualcuno.

Infine, le metafore attive sono quelle caratterizzate da gradi minimi di convenzionalità. Sono metafore originali, nuove, che tipicamente si trovano nella poesia o nella prosa letteraria più che nel parlato quotidiano. Dipendono molto dal contesto per la loro intelligibilità e non sono coinvolte né in relazioni di omonimia con altre forme né in relazioni di polisemia coi loro significati metaforici. Un esempio di metafora attiva è l'espressione "capriole di fumo", usata per riferirsi a delle volute di fumo che salgono verso l'alto.

Si noti che la convenzionalità di una metafora non è una sua caratteristica intrinseca, ma dipende dall'uso che se ne fa nella comunità linguistica. Al variare dell'uso cambia il suo statuto nel lessico, tanto che nel 2005 Bowdle e Gentner hanno proposto la *Career of Metaphor Theory* (Bowdle and Gentner; 2005), in cui è reso esplicito lo schema che caratterizza l'arco di 'vita' di una metafora dalla sua prima apparizione al momento in cui raggiunge alti livelli di convenzionalità. L'esempio che fanno gli autori è quello dell'espressione "an obsession is a tumor", che diffondendosi sempre di più nell'uso rinforza la relazione tra i due ambiti concettuali che mette in collegamento: hanno acquisito sempre più salienza le proprietà di un'ossessione che si possono predicare di un tumore, mentre sempre meno peso è stato dato alle caratteristiche dei due concetti che non convergono tra loro. A un certo punto, la base della metafora ("tumor") è arrivata ad un livello tale di utilità esplicativa e informativa nei confronti del suo argomento ("obsession") che è stata estesa ad altri argomenti in contesti diversi (es: "a doubt is a tumor", "a grudge is a tumor"). La forma "tumor" ha poi cominciato ad essere associata in modo sempre più convenzionale ai suoi nuovi significati, fino a diventare polisemica a tutti gli effetti.

Inoltre, Bowdle e Gentner sostengono che il grado di convenzionalità determina anche il

modo in cui la metafora viene elaborata: più un'espressione metaforica è convenzionale più sarà pertinente parlare di categorizzazione, invece che di comparazione, per riferirsi al modo in cui viene compresa. Infatti, per intendere una metafora come "the princess is a snowflake" non confrontiamo i due tipi di referenti coinvolti per capire quali siano le analogie che permettano di vedere uno nei termini dell'altro, piuttosto collochiamo direttamente il referente di "princess" nella categoria ad hoc denotata da "snowflake". Nella definizione di questa categoria giocano un ruolo fondamentale i vincoli imposti dalle caratteristiche semantiche dell'argomento della metafora. Nell'esempio riportato, si sta parlando di una giovane nobildonna e dunque difficilmente la categoria associata a "snowflake" consisterà nell'insieme delle cose che cadono dal cielo o che sono tipiche dell'inverno, piuttosto si intenderà l'insieme delle cose delicate ed eleganti, o magari quello delle cose pallide e bianche.

3.3 Esseri umani alle prese con le metafore

Chiarito cosa possiamo intendere quando parliamo di metafore, esaminiamo adesso due aspetti della loro interazione con la cognizione umana: la comprensione e la valutazione dei significati metaforici. Gli stessi aspetti verranno poi esplorati a proposito dei modelli di linguaggio.

3.3.1 Comprensione

Le domande di riferimento a questo punto sono: da cosa dipende la nostra competenza interpretativa dei significati metaforici? E' effettivamente grazie ad una embodied simulation, come vuole la CMT, che possiamo capire le metafore?

Per rispondere a tali quesiti sarà necessario considerare preliminarmente: ovvero, come avviene la comprensione dei significati non figurati? In quest'indagine ci avvaleremo del ramo neuro-cognitivo della ricerca sulla metafora, considerando le evidenze sperimentali accumulate negli anni principalmente attraverso *functional Magnetic Resonance Imaging* (fMRI). Si tratta, infatti, di una tecnica che permette di rilevare quali aree cerebrali si attivano durante il processamento dei significati linguistici².

Parte integrante della risposta alle domande formulate sopra sarà la smentita o la conferma dell'ipotesi della teoria di Lakoff sulle metafore.

² La fMRI misura l'attivazione dei neuroni inferendola a partire dal consumo di ossigeno, il quale è a sua volta dedotto dalla differenza locale di concentrazione tra emoglobina ossigenata e deossigenata. Dunque l'osservazione del fenomeno non è del tutto diretta, il che può tradursi in imprecisioni sia temporali che spaziali non sempre trascurabili. Il problema viene, però, arginato ripetendo molte volte la stessa misurazione. Ad ogni modo l'fMRI costituisce uno dei migliori strumenti di cui la scienza neuro-cognitiva dispone al momento. (Gallese and Cuccio; 2014)

Capire è simulare

Nel 1996 il team del neuroscienziato Rizzolatti fa una scoperta rivoluzionaria: da degli esperimenti sul cervello dei macachi emerge che una porzione dei neuroni della corteccia premotoria si attiva sia quando il soggetto compie una certa azione sia quando assiste alla stessa azione svolta da altri (Gallese et al.; 1996). I neuroni in questione vengono denominati neuroni specchio. La loro esistenza è stata ormai dimostrata anche nel cervello umano e implica una stretta relazione fra l'esecuzione di un'azione e la sua rappresentazione visiva. In particolare, quando osserviamo una certa azione avverrebbe in automatico dentro di noi una simulazione dell'azione stessa. Si parla in questo caso di *embodied simulation*: il supporto neurale adibito alla pianificazione motoria viene attivato, ma senza che tale pianificazione sia trasmessa ai muscoli effettori e si realizzi il movimento (Gallese and Lakoff; 2005).

Ma in che modo i neuroni specchio e le simulazioni incarnate ci possono dire qualcosa del modo in cui comprendiamo i significati? Il nesso più evidente è reso esplicito dalla teoria della *Embodied semantics*, secondo cui le rappresentazioni concettuali innescate dall'elaborazione cognitiva di una parola coinvolgerebbero in una certa misura le rappresentazioni sensomotorie necessarie all'esecuzione dell'azione descritta dalla parola in questione. (Giraldo Ospina et al.; 2024)

In (Hauk et al.; 2004) è stata esplorata l'attivazione neurale associata all'esecuzione di un task di decisione lessicale. In particolare, delle 50 parole previste dal task, alcune erano associate a movimenti facciali, altre a movimenti del braccio e altre ancora del ginocchio. Le immagini restituite dalla fMRI hanno mostrato che la risposta neurale agli stimoli seguiva una logica somatotopica: il processamento di ogni parola comportava l'attivazione di porzioni di rete neurale associate alla parte del corpo che le corrispondeva semanticamente in modo più intenso rispetto a quelle che non le corrispondevano. Per esempio, i partecipanti mostravano di ingaggiare maggiormente l'area della corteccia motoria responsabile del movimento della bocca quando la decisione lessicale riguardava una parola come "chew", rispetto a quando dovevano decidere di "kick" o "grab".

Altri risultati a sostegno della Embodied semantics sono quelli ottenuti da (Vitale et al.; 2021). Il loro esperimento prevedeva la stimolazione artificiale della parte sinistra della corteccia motoria dei partecipanti tramite la tecnica della tDCS (*transcranial Direct Current Stimulation*), mentre questi erano impegnati in un task di memoria. Il task riguardava frasi che potevano contenere verbi d'azione o verbi di pensiero: l'ipotesi degli autori era che la stimolazione, in virtù della natura motoria del suo obiettivo, avrebbe avuto un effetto di prime positivo solo sui verbi di azione. Effettivamente soltanto in relazione a questi verbi i partecipanti hanno dimostrato performance migliori nella condizione di stimolazione rispetto a quella di controllo. Questi dati non solo corroborano l'idea che la simulazione sia parte integrante del meccanismo di comprensione linguistica, ma testimoniano la natura incarnata della nostra cognizione, poiché rendono chiaro il coinvolgimento del sistema motorio in funzioni cognitive di alto

livello come la memoria.

Tuttavia, a riportare la tesi della Embodied semantics a livello di ipotesi, sono studi come quello di (Argiris et al.; 2020), in cui vengono presi in esame pazienti che riportano lesioni cerebrali nelle aree motorie monitorate negli altri studi. Nonostante queste lesioni siano tali da inibire l'attività neurale delle regioni interessate, i partecipanti allo studio hanno dimostrato comunque buone performance in compiti che prevedevano l'elaborazione di parole dal significato motorio. Stando a queste osservazioni, la simulazione non sembra strettamente necessaria per comprendere i significati, nemmeno quelli che hanno a che fare con un'azione.

Simulazioni e metafore

Fino a ora la simulazione incarnata è stata chiamata in causa solo in riferimento alla comprensione di significati letterali e concreti. Tuttavia, i sostenitori della CMT caldeggiavano un'applicazione della logica della Embodied semantics anche ai concetti astratti (Gibbs Jr; 2006). Infatti, la simulazione inconscia di percezioni e movimenti costituisce una valida occasione di naturalizzazione per la metafora concettuale. Se si dimostrasse che durante l'elaborazione di un concetto astratto (es: CAPIRE) si attivano le aree motorie associate al concetto concreto a cui quello astratto è metaforicamente legato (es: AFFERRARE), allora avremmo una dimostrazione neuro-cognitiva del fatto che il nostro sistema concettuale è costruito grazie alle mappature metaforiche.

Nonostante il fascino della proposta, alla prova dei fatti i dati si dimostrano piuttosto deludenti.

In (Aziz-Zadeh et al.; 2006) i partecipanti sono stati sottoposti a fMRI in due diverse condizioni: prima mentre osservavano delle azioni eseguite con la bocca, le mani, o i piedi; poi mentre leggevano frasi letterali e metaforiche riguardanti queste parti del corpo (es: "pressing the piano pedal" vs "kicking off the year"). Nel caso dell'elaborazione delle frasi letterali relative a una certa parte del corpo, la fMRI ha mostrato chiaramente che nell'emisfero sinistro è avvenuta l'attivazione della stessa area della corteccia premotoria coinvolta nel caso della percezione visiva della corrispondente parte del corpo in azione. Inoltre, questa stessa area è quella che risulterebbe attiva se il soggetto decidesse di muovere effettivamente in prima persona quella parte del corpo. Il cluster neurale in questione, infatti, è formato da neuroni specchio, che confermano quindi il loro coinvolgimento nella ricostruzione delle rappresentazioni sensomotorie (cioè nella embodied simulation) durante l'elaborazione di significati motori. Per quanto riguarda le frasi metaforiche, invece, i risultati non indicano un'attivazione sistematica delle aree motorie che corrisponderebbero alle parti del corpo menzionate. Sembra, cioè, che l'embodied simulation non sia essenziale per la comprensione dei significati metaforici.

Altri esperimenti assai rilevanti in questa sede sono quelli condotti da Desai e colleghi tra il 2011 e il 2013.

Negli esperimenti del 2011 (Desai; 2022) veniva comparata l'attivazione di aree cerebrali rilevanti a livello sensomotorio durante la ricezione da parte dei soggetti di frasi letterali ("She had a rough blanket"), metaforiche ("She had a rough day"), o semplicemente astratte ("She had a bad day"). Le frasi in questione erano state adattate in modo da avere pari lunghezza, familiarità e complessità sintattica, aspetti che avrebbero potuto interferire con la misurazione producendo processi cognitivi scollegati dal carattere letterale, metaforico o astratto delle frasi. I risultati hanno mostrato che l'area motoria aIPL risulta maggiormente attiva non solo per le frasi letterali rispetto a quelle astratte, ma, cosa meno prevedibile e più significativa, anche per le frasi metaforiche rispetto a quelle astratte. aIPL è associata alla pianificazione di azioni e all'interazione mano-oggetto, ma si attiva anche quando il soggetto vede qualcosa che viene afferrato o mosso per il raggiungimento di uno scopo. In questo senso allora pare che ci sia conferma sia dell'ipotesi di un grounding sensomotorio della comprensione delle metafore sia del fatto che questo avvenga in virtù di aggregati di neuroni specchio che permettono l'implementazione di dinamiche simulate.

Il quadro della situazione, però, già cambia se consideriamo gli esperimenti del 2013 (Desai; 2022). Attraverso procedure analoghe vengono riconfermate sia l'intensità di attivazione di aIPL secondo la tendenza già registrata nel 2011 (frasi letterali > frasi metaforiche > frasi astratte) sia il pressoché simile coinvolgimento di aIPL nella comprensione del letterale e del metaforico. Tuttavia, dai dati raccolti è emerso anche che astratto e metaforico condividono livelli di attivazione comparabili nell'area del solco temporale superiore e nel giro temporale mediano, mentre la ricezione di frasi letterali interessa assai meno queste stesse zone. Le regioni cerebrali in questione sono state interpretate come punti focali della processazione e rappresentazione astratta. Il metaforico, insomma, possiede analogie sia col concreto che con l'astratto.

Tutto considerato, quindi, il modello di elaborazione dei significati che possiamo inferire dagli esiti degli esperimenti qui riportati prevede che i concetti astratti siano effettivamente plasmati attraverso strutturazioni metaforiche, ma godano di una base rappresentazionale indipendente. Un modello del genere è incompatibile perlomeno con l'ipotesi lakoffiana più radicale: ovvero che l'astratto sia compreso integralmente attraverso il metaforico, e che dunque il primo non possa esistere nella nostra cognizione se non attraverso il secondo.

3.3.2 Valutazioni semantiche

Chiarito il modo in cui il nostro cervello elabora i significati metaforici, rimangono adesso da illustrare gli effetti che tali significati hanno al livello più astratto della nostra psicologia.

Quando elaboriamo tali significati, essi manifestano agli occhi della nostra mente certi

tipi di proprietà. Le proprietà in questione sono anche dette dimensioni psicologiche, poiché esistono solo in relazione ad una mente che le recepisce. Per fare degli esempi, possiamo preliminarmente citare la comprensibilità, l'appropriatezza, l'immaginabilità, la familiarità percepita, etc.

L'indagine delle dimensioni psicologiche e delle loro correlazioni reciproche è di grande interesse non solo per una cospicua parte della ricerca psicolinguistica sulla metafora, ma anche per la parte sperimentale della presente tesi, in cui verranno messi a confronto i giudizi prodotti da esseri umani con prodotti da modelli di linguaggio nell'ambito di certe dimensioni psicologiche.

Verranno presentati, dunque, due contributi fondamentali nell'indagine delle dimensioni psicologiche delle metafore: il primo è uno studio condotto sull'inglese che ha permesso di raccogliere informazioni preziose su come gli esseri umani percepiscono diverse centinaia di metafore nell'ambito di dieci dimensioni; il secondo, invece, consiste in un grande database strutturato e consultabile in cui confluiscono i risultati di questionari psicolinguistici analoghi per l'italiano.

Il primo contributo è stato prodotto da Katz e colleghi nel 1988 (Katz et al.; 1988). Costituisce uno dei più imponenti 'censimenti psicolinguistici' sulle metafore, ed è stato infatti un riferimento per tutta la ricerca successiva.

Il campione d'indagine consta di 484 metafore, tutte in forma diretta (*A is B*) e bilanciate tra letterarie e non letterarie. I partecipanti allo studio dovevano rispondere a un questionario in cui, per ogni metafora, si chiedeva di scegliere un punteggio in una scala Likert per ognuna delle 10 dimensioni proposte. Tra le più rilevanti troviamo: la *metaphor goodness*, da intendere come la misura di quanto la metafora ci sembra appropriata ed efficace, ma anche soddisfacente; la *semantic relatedness*, ovvero quanto a chi legge sembrano semanticamente vicini i due elementi coinvolti nella metafora; la *subject imagery* e la *predicate imagery*, che riguardano la facilità con cui rispettivamente il soggetto e il target e il vehicle della metafora creano immagini o suoni nella mente al momento della lettura. Inoltre, il questionario includeva la comprensibilità, l'agio di interpretazione, la metaforicità, l'immaginabilità metaforica generale, la familiarità percepita e il numero di interpretazioni alternative.

L'analisi dei dati raccolti ha fatto emergere come metafore letterarie e non letterarie non differiscano in modo statisticamente significativo in nessuna delle dimensioni prese in considerazione. Questo risultato è particolarmente interessante se si pensa alla differenza che invece la Gradient Salience Hypothesis pone tra il processing di significati metaforici originali e poco salienti (come quelli delle espressioni letterarie) e quello dei significati metaforici convenzionali e quindi salienti almeno quanto il corrispettivo significato letterale (caratteristici di molte parole polisemiche nell'uso comune).

Un ulteriore aspetto degno di nota è il fatto che la coerenza di risposta tra gli annotatori sia piuttosto bassa. Evidentemente, le persone reagiscono diversamente alla stessa metafora: ciò che è difficile da interpretare e poco vivido per qualcuno può risultare

agevole e facilmente immaginabile per un altro.

Proprio per indagare la variabilità di questo tipo di giudizi, nel 2015 Campbell e Raney decidono di replicare lo studio del 1988 (Campbell and Raney; 2016). Mantengono le dieci dimensioni originali, ma cambiano naturalmente i valutatori umani (non più studenti canadesi, ma studenti della University of Illinois at Chicago); inoltre, selezionano solo 50 delle metafore del dataset originale, avendo cura di non sovrarappresentare metafore con un certo livello di familiarità. Due sono i principali motivi della replicazione: da una parte si vuol monitorare se e quanto è variato in 25 anni il modo di interpretare le stesse metafore, visto che la lingua e la percezione dei suoi significati variano con l'uso; dall'altra si vuol capire quanto influiscano nell'interpretazione di metafore le caratteristiche culturali e geografiche del campione umano.

La correlazione tra i nuovi dati e gli originali (calcolata col coefficiente di Pearson) si è dimostrata significativamente positiva per ogni dimensione, con un coefficiente minimo di .56 per la metaforicità e uno massimo di .78 per la familiarità. Ciò significa che le metafore giudicate familiari al tempo dell'esperimento di Katz e colleghi sono rimaste percepite come tali dopo 25 anni da persone diverse per cultura e provenienza, e lo stesso si può dire di quelle valutate non familiari.

Il secondo contributo degno di nota è il recente *Figurative archive*, messo a punto da Bressler e colleghi nel 2026 (Bressler et al.; 2026). L'archivio mette insieme dati raccolti in 10 anni di ricerca psicolinguistica su metafore italiane: riunisce 464 metafore del linguaggio quotidiano e 533 metafore letterarie. Una risorsa del genere ha il pregio di contrastare lo sbilanciamento che la ricerca sulle metafore ha verso la lingua inglese, e che rischia di lasciare lacune o formulare generalizzazioni illegittime sul significato metaforico in generale. Proprio da questo database, infatti, sono stati tratti i 5 studi replicati nell'esperimento illustrato nel capitolo 4.

Nel *Figurative Archive* confluiscono sia espressioni metaforiche dirette che indirette. Quanto alle caratteristiche esplorate per ogni item, possiamo trovare dimensioni psicologiche raccolte attraverso questionari (come familiarità, difficoltà, fisicalità, mentalità, ricchezza di significato, difficoltà, appropriatezza, relazione col corpo, immaginabilità, metaforicità³, etc.) o misure estratte da analisi di corpus (lunghezza, frequenza, concretezza, distanza semantica tra topic e vehicle).

Considerando solo le metafore non letterarie, un'analisi delle correlazioni fra le varie dimensioni (sempre calcolata con coefficiente di Pearson) ha messo in luce come la familiarità correla fortemente con appropriatezza (.92) e ricchezza di senso (.85), moderatamente con immaginabilità (.61) e difficoltà (-.42), e debolmente con mentalità (.27) e metaforicità (-.24). Inoltre, è emerso che le metafore difficili da interpretare sono anche quelle caratterizzate da gradi più alti di metaforicità, ma che evocano meno facilmente immagini nella mente. Dati interessanti riguardano la concretezza di topic e vehicle, che correlano entrambe positivamente con la fisicalità dell'intera espressione

³ La misura è stata ottenuta chiedendo ai partecipanti quanto l'associazione fra le due parole coinvolte nell'espressione risultasse loro metaforica in opposizione a letterale.

(rispettivamente 0.26 e 0.23), mentre la sola concretezza del topic correla negativamente sia con la mentalità (-0.42) che con la metaforicità (-0.46). Questi risultati suggeriscono che più il target della metafora è concreto più risulterà facile cogliere le analogie fisiche e percettive che si manifestano tra i due ambiti coinvolti, mentre questo stesso fatto ostacolerà il riconoscimento degli aspetti più mentali della mappatura metaforica, oltre a diminuire la carica metaforica percepita. Infine, merita attenzione la correlazione positiva tra distanza semantica e metaforicità (0.27): più il contrasto semantico tra topic e vehicle è evidente più gli esseri umani sono disposti a riconoscere il loro legame come metaforico.

Esplorando la natura degli item lessicali stessi, al netto delle misure associate, gli autori hanno notato un fatto assai rilevante. Chiedendo a ChatGPT di fare clustering semantico dei topic, è emerso che la parte consistente di questi denotano elementi naturali, parti del corpo e percezioni (58.16%), ma anche stati psicologici, emozioni e concetti astratti (31.7%). Lo stesso è stato fatto per i vehicle, che sono risultati in maggioranza anch'essi elementi naturali, parti del corpo e percezioni (85.23%), con un residuo minimo di stati psicologici, emozioni e concetti astratti (7.57%). Queste percentuali sono tutto sommato in linea con l'ipotesi della Teoria della metafora concettuale: gli esseri umani usano certi ambiti concreti dell'esperienza per rendere conto sia di ambiti astratti che altri ambiti concreti.

3.4 LLM alle prese con le metafore

Passiamo ora ad esaminare il modo in cui i modelli di linguaggio gestiscono i significati metaforici, e in particolare se li interpretino e li valutino in modo comparabile all'uomo. Il linguaggio figurato, e quello metaforico in particolare, è pervasivo nella comunicazione quotidiana, ma spesso risulta sottovalutato nella ricerca sul NLP. Si tratta invece di una dimensione semantica di grande interesse per la valutazione dei language model: nonostante i continui progressi nelle prestazioni, la comprensione, la creazione e la valutazione delle metafore resta uno degli ambiti in cui questi sistemi mostrano maggiori difficoltà nel simulare i processi cognitivi umani (Skrynnikova; 2024).

3.4.1 Comprensione

Possiamo articolare il discorso sulla comprensione delle metafore nei LLM considerando la loro competenza in due ambiti ritenuti importanti per una corretta interpretazione dei significati metaforici: il ragionamento analogico e la percezione.

Modelli e competenza analogica

Nella ricerca sul significato figurato delle parole, è diffusa l'opinione che la comprensione di una metafora si fondi essenzialmente sulla capacità di costruire un'analogia. Il ragionamento analogico consiste infatti nell'inferire delle proprietà o nel prevedere il comportamento di un oggetto sconosciuto sulla base della sua somiglianza con uno noto. Chi, come (Skrynnikova; 2024), sostiene questa tesi non può che essere scettico all'idea che un LLM sia in grado anche solo di imitare tale comprensione. In primo luogo, infatti, l'unica capacità analogica posseduta dai modelli riguarda la dimensione formale del linguaggio e non quella semantica; in secondo luogo, come già osservato nel capitolo 2, è estremamente difficile per un modello di linguaggio generalizzare pattern di risposta semanticamente coerenti quando il prompt si discosta troppo dalle sequenze incontrate durante il training (Schröder et al.; 2025).

In questo senso, sembra che solo gli esseri umani siano in grado di riconoscere due situazioni diverse si somiglino, e di trasferire ciò che sanno valere per un dominio a un ambito inedito e apparentemente diverso.

Questa posizione, tuttavia, si scontra con numerosi risultati sperimentali che mostrano come i modelli di linguaggio possano ormai raggiungere prestazioni comparabili a quelle umane anche nell'ambito della comprensione metaforica.

(Ichien et al.; 2024), ad esempio, rilevano che le risposte di GPT-4 presentano livelli di accuracy sovrapponibili a quelli degli esseri umani in compiti in cui viene richiesto di selezionare, tra due alternative, la parafrasi letterale più adeguata di un enunciato metaforico. Nel caso dei modelli, la preferenza viene stimata in base alla probabilità assegnata alle due parafrasi candidate concatenate alla frase metaforica dall'espressione "that is": l'interpretazione considerata corretta è quella a cui il modello attribuisce probabilità maggiore.

Nello stesso studio il modello viene testato anche sulla sua capacità di interpretare metafore letterarie. Dei giudici umani, ignari della presenza di un LLM tra i partecipanti al task, hanno valutato le interpretazioni e, sorprendentemente, quelle del modello sono risultate qualitativamente superiori a quelle prodotte dagli umani (i criteri di giudizio riguardavano più che altro l'attribuzione di proprietà adeguate al target anche sulla base di quelle del vehicle).

Risultati di questo tipo sembrano contraddire (Skrynnikova; 2024) e suggeriscono che la capacità di costruire analogie possa emergere nei modelli come proprietà derivata dalla loro competenza distribuzionale dei significati. Questa interpretazione è inoltre relativamente robusta rispetto alle obiezioni di data leakage: gli stimoli utilizzati nello studio provengono dalla letteratura poetica serba, sono stati selezionati per la loro bassa familiarità e tradotti in inglese. Si tratta dunque di metafore poco diffuse e quindi con bassa probabilità di comparire nei dati di addestramento; la traduzione rappresenta inoltre un ulteriore livello di 'camuffamento' nell'eventualità che i testi originali compaiano nel training.

Va però aggiunto che, nell’ottica di sviluppare sistemi capaci di simulare fedelmente il comportamento umano, emerge un problema dai dati raccolti: una performance sistematicamente superiore a quella umana rischia di rendere il modello inadatto a rappresentare le effettive competenze cognitive umane. L’elaborazione delle metafore letterarie negli esseri umani è infatti associata a tempi di processamento più lunghi, indice di una maggiore difficoltà interpretativa. Questo invece non sembra essere il caso per i modelli, che si dimostrano in grado di produrre spiegazioni estremamente efficaci per questo tipo di metafore.

Modelli e competenza percettiva

Anche ammettendo che i modelli di linguaggio riescano a imitare i ragionamenti analogici umani, resta un’ulteriore ragione per dubitare che tali sistemi possano riprodurre in modo pienamente fedele la competenza interpretativa umana sui significati metaforici. Nello spirito della Teoria della Metafora Concettuale, infatti, comprendere una metafora significa spiegare un concetto attraverso la conoscenza senso-motoria che possediamo a proposito di un dominio analogo. In questo senso, un sistema che dispone soltanto di una rappresentazione formale e disincarnata del significato linguistico difficilmente potrà eguagliare i processi cognitivi umani in questo ambito, e forse non potrà nemmeno simularli in modo del tutto soddisfacente.

A corroborare, almeno parzialmente, questa ipotesi esistono esperimenti come quelli di (Barattieri di San Pietro et al.; 2023), in cui ChatGPT-3.5 è stato sottoposto alla versione italiana del Physical and Mental Metaphor Task. Il modello ha mostrato prestazioni eccellenti nell’interpretazione di metafore riferite a caratteristiche mentali del target (accuracy: 100%), ma risultati sensibilmente peggiori per metafore relative ad aspetti fisici (accuracy: 57%). In particolare, pur identificando correttamente la categoria di proprietà del vehicle rilevante per l’interpretazione, il modello falliva spesso nella selezione della proprietà fisica appropriata da attribuire al target. Ad esempio, GPT-3.5 interpreta correttamente il fatto che la frase “Teenagers are pendulums” si riferisca all’umoralità degli adolescenti, mentre intende la frase “that boxer is a panda” come se il pugile sia morbido, invece di cogliere il riferimento agli occhi neri dovuti ai colpi ricevuti.

Questi risultati offrono un supporto solo parziale alla CMT, poiché suggeriscono che non tutte le metafore richiedano necessariamente una consapevolezza senso-motoria per essere comprese. E tuttavia i dati indicano anche che le metafore radicate in domini fisici smascherano la natura disembodied della competenza linguistica dei modelli. In questo ambito, infatti, la loro performance non raggiunge quella umana (accuracy media umana 80% contro 57% del modello), mostrando limiti nella simulazione del comportamento interpretativo.

Un'ulteriore evidenza in tal senso è fornita da (Mangiaterra, Barattieri Di San Pietro, Frau, Bambini and Al-Azary; 2025). Gli autori partono da risultati precedenti secondo cui gli esseri umani giudicano più appropriati come vehicle metaforici termini caratterizzati da bassa Semantic Neighbourhood Density (SND), cioè con vicini semantici mediamente più distanti nello spazio vettoriale costruito su matrici di co-occorrenza, e da bassa Body-Object Interaction (BOI), misura derivata da giudizi umani che quantifica la facilità dell'interazione motoria col referente. La preferenza dei modelli viene stimata confrontando le probabilità assegnate a diversi vehicle a parità di target. I risultati mostrano che anche i modelli 'preferiscono' parole con bassa SND, ma non manifestano alcuna preferenza sistematica rispetto ai valori di BOI. Nel complesso, questi dati rivelano che i modelli riproducono i pattern del comportamento verbale umano quando essi sono riconducibili a regolarità statistiche presenti nei dati linguistici (come nel caso della SND), mentre falliscono quando il comportamento umano dipende da variabili legate all'esperienza corporea, a cui i modelli non hanno accesso.

Va però ricordato che, come discusso nel paragrafo 3.3.1, indagini neuro-cognitive hanno messo in discussione la versione radicale della CMT. L'elaborazione delle metafore non dipende necessariamente da processi di embodied simulation, che possono anche non attivarsi durante il processing.

In linea con questa revisione, anche la ricerca sui modelli di linguaggio fornisce risultati interessanti: (Wicke; 2023) osservano che, paradossalmente, l'accuratezza interpretativa dei modelli correla positivamente, seppure con coefficienti bassi, con i rating umani di embodiment delle metafore. Una possibile spiegazione richiama un'osservazione dello stesso Lakoff: gli esseri umani ricorrono sistematicamente a domini percettivi e motori per strutturare concetti più astratti o inediti (Lakoff and Johnson; 1998). Proprio questo vantaggio cognitivo rende molto frequente l'uso di termini embodied come vehicle metaforici. Tuttavia, coerentemente con la Career of Metaphor Theory, l'uso frequente in contesti diversi determina una convenzionalizzazione del significato. La metafora si lessicalizza: accoglie il significato figurato come significato convenzionale e perde il suo significato embodied di base, facendo sì che la sua comprensione non sia più legata ad esperienze corporee. Tale lessicalizzazione, unitamente all'elevata frequenza di occorrenza, creano le condizioni perfette affinché i modelli di linguaggio si costruiscano una rappresentazione esauriente del significato di tali metafore. In sostanza: le metafore più embodied tendono ad essere meglio interpretate dai modelli perché sono anche quelle più convenzionali.

3.4.2 Valutazioni semantiche

Dagli esperimenti illustrati nel paragrafo precedente abbiamo avuto prova della notevole abilità dei Large Language Model nella comprensione delle espressioni metaforiche, al

punto che in molti casi le loro interpretazioni risultavano indistinguibili da quelle umane. Tuttavia, individuare la parafrasi corretta non garantisce che il modello sia sensibile agli aspetti più sottili del significato metaforico. In altri termini, non è detto che la metafora produca ‘lo stesso effetto’ su macchine e persone. Per questo è utile analizzare come i modelli valutino le metafore lungo diverse dimensioni psicologico-semantiche, verificando in che misura riescano a simulare anche questi aspetti del comportamento cognitivo umano.

Un primo studio rilevante in questo senso è quello di (Castillo and Valenzuela; 2025), che esamina l’effetto dei verbi di moto usati metaforicamente in contesti temporali sulla percezione dello scorrere del tempo. Dal confronto tra i rating umani e quelli sintetici su diverse dimensioni psicologico-semantiche, sono emerse convergenze significative: sia gli esseri umani sia i modelli sono sensibili alla velocità implicata dal verbo e giudicano i verbi più ‘veloci’ come più vitali e coinvolgenti, associandoli a una maggiore sensazione di controllo sugli eventi e di facilità nella loro progressione.

Particolarmente notevole è che i modelli colgano sfumature emotive e psicologiche non codificate esplicitamente nel significato lessicale dei verbi e assenti dalle loro definizioni sul dizionario.

Gli autori osservano che la performance simulativa dei modelli è tale che lo studio avrebbe portato alle stesse conclusioni anche utilizzando soltanto partecipanti sintetici.

Infine, un altro contributo importante in questa sede è la replicazione condotta da (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025) sui giudizi umani di familiarità, immaginabilità e comprensibilità delle metafore del Figurative Archive. Per quanto riguarda i giudizi prodotti dal modello più grande (GPT-4o), gli autori registrano sia per l’inglese che per l’italiano una correlazione positiva, tra moderata e forte, per tutte le dimensioni in esame. I modelli più piccoli (GPT-3.5-Turbo e GPT-4o-mini) mostrano invece buoni livelli di allineamento in inglese, ma correlazioni medio-basse in italiano, riflettendo lo sbilanciamento dei dati di addestramento a favore dell’inglese.

Gli item metaforici sono stati inoltre raggruppati in base alla loro rilevanza sensorimotoria. Le analisi per sottogruppi mostrano che la correlazione tra giudizi di familiarità umani e sintetici è più alta per metafore basate su verbi di movimento e riguardanti proprietà, e più bassa per metafore associate alla dimensione uditiva, al corpo e a proprietà fisiche. Questa disparità tra metafore mentali e fisiche è coerente con le difficoltà interpretative osservate da (Barattieri di San Pietro et al.; 2023).

Infine, Mangiaterra e colleghi mostrano che i punteggi di familiarità, anche quando derivati da rating sintetici, predicono sia i tempi di reazione comportamentali (in compiti di self-paced reading) sia indici neurofisiologici (ERP). Si tratta di un risultato promettente in prospettiva di un’automatizzazione (anche parziale) della raccolta di giudizi semantici che non vada a discapito dell’affidabilità dei dati.

Capitolo 4

Esperimento: generazione di giudizi semantici sulle metafore

L'esperimento presentato in questo capitolo è consistito nell'usare due modelli di linguaggio, LLaMa-3.1-8B e LLaMa-3.3-70B (entrambi nella loro versione instruction tuned), per replicare i rating di espressioni metaforiche italiane raccolti in alcuni dataset del Figurative Archive (Bressler et al.; 2026); i rating sintetici così prodotti, sono poi stati messi in correlazione con quelli autentici e sottoposti ad ulteriori analisi. Lo scopo era quello di indagare la qualità della performance simulativa dei modelli nei confronti del comportamento verbale umano nel contesto del task in questione.

4.1 L'esperimento in questione e i lavori correlati

L'esperimento si colloca nel filone di studi che analizzano il grado di convergenza tra giudizi umani e giudizi prodotti da LLM in task di rating psicologico-semantici. In precedenza sono già stati richiamati i lavori di (Conde et al.; 2025) e (Trott; 2024); in questa sede assume però un rilievo particolare il lavoro di (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025), poiché anch'esso consiste in una replicazione di giudizi su espressioni metaforiche italiane tratte dal Figurative Archive. È quindi opportuno chiarire in che modo il presente studio si differenzi da quello di Mangiaterra e colleghi:

- innanzitutto, in (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025) vengono utilizzati GPT-3.5-turbo, GPT-4o-mini e GPT-4o, mentre nell'esperimento qui descritto sono stati impiegati LLaMa 3.1-8B e LLaMa 3.3-70B, consentendo di valutare la capacità simulativa di modelli decisamente più piccoli e appartenenti ad un'altra famiglia;
- (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025) considerano le dimensioni di familiarity, imageability e comprehensibility; nel presente lavoro, oltre a queste, vengono incluse anche meaningfulness, body relatedness e phisicality;

- lo studio di (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025) non affronta esplicitamente il problema del data leakage: qui, invece, si distingue tra metafore precedenti e successive al knowledge cutoff del modello e si confrontano le correlazioni tra giudizi umani e sintetici nelle due condizioni;
- infine, in (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025) non viene effettuato un confronto sistematico tra diversi metodi di generazione dei dati sintetici, confronto che invece è incluso nel disegno sperimentale del presente studio.

4.2 Obiettivi e ipotesi

Quello della raccolta di giudizi semantici è un lavoro estremamente dispendioso, soprattutto se si pensa al fatto che, data l’influenza che il contesto o la forma di un’espressione può avere sulla percezione del suo significato, è auspicabile raccogliere giudizi semantici sulla stessa metafora espressa in forme diverse (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025).

In linea con questa motivazione, l’obiettivo primario dell’esperimento consiste nel controllare la correlazione tra giudizi sintetici e giudizi umani e capire se questa possa essere promettente in vista di un’automatizzazione della raccolta dei rating.

Un secondo obiettivo riguarda l’indagine di un possibile data leakage nei modelli utilizzati. Nel caso di item metaforici già pubblicati online prima del knowledge cutoff dei modelli (dicembre 2023), non è possibile determinare se le buone performance del modello riflettano effettivamente una capacità di generalizzazione e competenza linguistica, oppure se derivino semplicemente dal “ricordo” di dati già presenti nel training set; al contrario, le performance ottenute su item comparsi dopo il cutoff possono essere ritenuti riferimenti affidabili nella valutazione del modello.

Un terzo obiettivo sperimentale che ci poniamo in questa sede è quello di confrontare 3 metodi di generazione diversi, che illustreremo più avanti nel dettaglio.

Infine, l’esperimento mira anche a esplorare due questioni centrali riguardo alla competenza linguistica dei modelli: da un lato, si verifica se la mancanza di un corpo impedisca il grounding percettivo dei significati e determini quindi una capacità limitata di valutare metafore più embodied in maniera simile agli esseri umani; dall’altro, si indaga se la maggiore familiarità di una metafora, plausibilmente dovuta a una maggiore frequenza d’uso, favorisca una rappresentazione distribuzionale più solida da parte del modello, permettendogli di valutare tali item in modo più coerente con i giudizi umani rispetto a metafore meno familiari (ed evidentemente meno frequenti).

A partire da questi obiettivi, formuliamo le seguenti ipotesi sperimentali:

1. (a) I giudizi prodotti dai modelli mostrano una correlazione statisticamente significativa con i giudizi umani, con un coefficiente pari o superiore alla soglia ideale dello 0.80;

- (b) Le conclusioni derivate dall'analisi delle correlazioni tra le diverse dimensioni del dataset non presentano differenze statisticamente significative quando i calcoli sono effettuati su dati umani rispetto a dati sintetici;
- 2. I modelli tenderanno a giudicare le metafore già presenti in studi precedenti al knowledge cutoff in modo più simile agli esseri umani rispetto a quelle post-cutoff;
- 3. Le correlazioni tra giudizi umani e sintetici saranno più basse per le metafore maggiormente embodied rispetto a quelle meno embodied;
- 4. Le correlazioni tra giudizi umani e sintetici saranno più alte per le metafore più familiari, rispetto a quelle meno familiari.

Più in generale, questo lavoro contribuisce a espandere i dati sulla capacità simulativa dei modelli di linguaggio in riferimento all'italiano, cercando di ridurre lo squilibrio presente nella letteratura, che tende a concentrarsi quasi esclusivamente sulla lingua inglese, per via della predominanza di dati di training in tale lingua.

4.3 Metodi

4.3.1 Datasets

Come anticipato, gli item metaforici sono stati tratti da vari dataset confluiti nel Figurative Archive (Bressler et al.; 2026). In particolare sono stati considerati i seguenti studi: IUSS NEPLab MetaBody study (MB), IUSS NEPLab MetaEducation study (ME), IUSS NEPLab MetaImagery study (MI), IUSS NEPLab MoveMe study (MM) e il dataset proposto in (Bambini et al.; 2014) (BA).

- MB: consiste in 64 metafore di uso quotidiano di forma *Quel(quegli) X è(sono) un(degli) Y*, in cui X e Y sono nomi comuni e X può riferirsi a una parte del corpo o a un'oggetto (es: "Quei bicipiti sono dei sassi" o "Quella casa è un gioiello"). Il dataset include rating umani su una scala Likert da 1 a 7 per le seguenti dimensioni: *familiarity* (familiarità), *meaningfulness* (significatività) e *body relatedness* (relazione col corpo).
- ME: consiste in 80 metafore di uso quotidiano, di forma *Quel(quegli) X è(sono) un(degli) Y* (inserite in un contesto frasale più ampio), dove X e Y sono nomi comuni e X si riferisce a referenti astratti o concreti (es: "Nei momenti difficili le stelle sono speranze che illuminano l'anima"). Il dataset include rating umani su una scala Likert da 1 a 5 per le seguenti dimensioni: *familiarity*, *meaningfulness* e *difficulty* (difficoltà).

- MI: consiste in 42 metafore di uso quotidiano, di forma *Det Subj è(sono) Obj* (es: "Certi avvocati sono squali"). Il dataset include rating umani su una scala Likert da 1 a 7 per le seguenti dimensioni: *imageability* (immaginabilità) e *phisicality* (fisicità).
- MM: consiste in 60 metafore di uso quotidiano di forma *Subj V (Ind)Obj*, dove il verbo esprime il vehicle e l'oggetto il target della metafora (es: "Alice disegna il suo futuro con Alberto").
Il dataset include rating umani su una scala Likert da 1 a 7 per le seguenti dimensioni: *familiarity* e *meaningfulness*.
- BA: consiste in 115 metafore letterarie tratte dalla letteratura italiana (metà dalla prosa metà dalla poesia), di forma *X di Y* con X e Y come nomi comuni (es: "labbra di rubino"). Il 20.87% degli item prevede l'ordine target-vehicle, mentre il 79.13% l'ordine vehicle-target.
Il dataset include rating umani su una scala Likert da 1 a 5 per varie dimensioni tra cui le seguenti: *familiarity*, *meaningfulness* e *difficulty*.

Tutte le metafore contenute in BA risultano pubblicate online prima del knowledge cutoff dei modelli, mentre i dataset MB, ME, MI e MM includono sia metafore già apparse in studi precedenti al cutoff sia metafore inedite. Questa differenza ha orientato la scelta dei dataset impiegati nell'esperimento: solo confrontando la correlazione tra giudizi umani e sintetici nella condizione pre-cutoff con quella nella condizione post-cutoff è infatti possibile valutare in modo fondato il possibile impatto di fenomeni di data leakage.

Tutti i dataset includevano anche la controparte letterale delle varie metafore e i corrispondenti giudizi di rating umani. Tuttavia in questa sede non terremo in considerazione questa parte di dati, concentrandoci specificatamente sulle metafore.

Per chiarezza riportiamo poi la definizione delle dimensioni esplorate, che vengono descritte in modo grosso modo equivalente nelle istruzioni dei vari studi sopra citati:

- Familiarity: quanto ci suona familiare la frase presentata, ovvero quanto ci sembra di averla sentita o usata in quella forma o in forme simili;
- Meaningfulness: la ricchezza di significato della frase presentata, ovvero quanto ci sembra abbia significato o senso la frase;
- Difficulty: quanto pensiamo che la frase sia stata difficile da interpretare, cioè quanto ci è parso difficile giudicare la significatività della frase;
- Body relatedness: la relazione della frase con parti del corpo o l'inclusione di parti del corpo o aspetti motori nella frase;

- Imageability: quanto riusciamo a visualizzare mentalmente il significato della frase;
- Phisicality: quanto la frase esprima caratteristiche fisiche delle persone che vi sono menzionate.

4.3.2 Modelli

La scelta di attingere i modelli per l'esperimento dalla famiglia di Meta è stata motivata da più fattori convergenti.

Innanzitutto, servivano modelli che supportassero l'italiano, e la model card che Meta fornisce su Github ci garantisce che questo è il caso sia per LLaMa-3.1-8B¹ che per LLaMa-3.3-70B².

Dopo che già questo primo criterio aveva ristretto il bacino di scelta, sono occorsi fattori di accessibilità e di scientificità. Infatti, tra i modelli addestrati anche su dati italiani, quelli di Meta sono gli unici che possono essere interrogati gratuitamente tramite il servizio API messo a disposizione da Huggingface. Inoltre, hanno la qualità di essere open-source: abbiamo informazioni più precise sul loro addestramento e sulla loro architettura, e questo implica vantaggi in termini di trasparenza e riproducibilità (Hussain et al.; 2024).

Caratteristiche dell'architettura

I modelli LLaMa sono sistemi decoder-only, la cui architettura include una caratteristica particolare che ne aumenta l'efficienza computazionale: la Grouped Query Attention (GQA). Si tratta di una variante della Multi-Head Attention (MHA), nella quale le teste di query vengono suddivise in gruppi e, all'interno di ciascun gruppo, condividono un unico set di vettori di key e value. In questo modo, a differenza della MHA classica in cui ogni testa calcola separatamente i propri vettori key e value, operazione costosa in termini di memoria e di calcoli, soprattutto per sequenze lunghe, nella GQA questi vettori vengono calcolati una sola volta per ciascun gruppo (Ainslie et al.; 2023). Questo approccio garantisce un compromesso ideale tra velocità e accuratezza.

Strategie di fine-tuning

Un'altra strategia chiave utilizzata per ottimizzare le performance dei modelli LLaMa è il Reinforcement Learning with Human Feedback (RLHF). In questo caso, però, l'ottimizzazione non consiste tanto nel rendere più efficienti i calcoli, ma nell'indurre il modello a generare testo più coerente semanticamente e più simile a una produzione umana autentica. Il RLHF prevede, infatti, di addestrare un *reward model* a valutare la qualità di risposte testuali sulla base di valutazioni fornite da giudici umani.

¹ <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>

² <https://huggingface.co/meta-llama/Llama-3.3-70B-Instruct>

Successivamente, il modello di linguaggio vero e proprio, già pre-addestrato su grandi corpora testuali, viene ulteriormente affinato per generare risposte che massimizzino il punteggio previsto dal reward model. Questo processo permette di allineare più strettamente le produzioni del modello agli standard umani, migliorando la coerenza e l'appropriatezza delle risposte generate (Ichien et al.; 2024).

Inoltre, entrambi i modelli usati nell'esperimento sono stati sottoposti a un processo di *Instruction tuning*, che consiste nel perfezionare un modello di linguaggio pre-addestrato utilizzando un dataset costituito da coppie istruzioni–risposte. A differenza del fine-tuning tradizionale, che si concentra su compiti o domini specifici, questa procedura mira a insegnare al modello a comprendere e seguire istruzioni esplicite, migliorandone la capacità di adattarsi a una varietà di task (Zhang et al.; 2026).

Durante l'addestramento, il modello viene esposto a una gamma ampia di esempi, che spaziano da richieste semplici (es: “Qual è la capitale del Libano?”) a compiti più articolati (es. “Riepiloga questo articolo evidenziandone i punti principali”). Questo processo consente al modello di apprendere come interpretare correttamente le istruzioni e generare risposte coerenti e pertinenti.

Un modello instruct rappresenta, dunque, una scelta ideale per un esperimento di replicazione di giudizi umani, in cui il prompt di input consiste proprio nella stessa serie di istruzioni somministrata agli umani nello studio originale.

4.3.3 Modalità di inferenza

Avendo constatato l'impossibilità di eseguire i modelli in locale (nemmeno il più piccolo nella sua versione quantizzata), disponendo soltanto della GPU messa a disposizione da Google Colab, la scelta su come condurre le inferenze è ricaduta sull'uso del servizio API di Huggingface. Questa modalità aveva diversi vantaggi: non solo permetteva di usare modelli medio-grandi come LLaMa-3.3-70B senza doverli scaricare localmente, ma, accedendo al servizio tramite interfaccia Python, permetteva di automatizzare il flusso di lavoro (inserimento del giusto prompt, registrazione della risposta, etc.), modificare iperparametri di default (temperatura, numero massimo di token) e accedere alla probabilità che il modello attribuiva ai più probabili top-k token ad ogni passo. Nessuna di queste cose, invece, sarebbe stata possibile attraverso l'interfaccia conversazionale dei modelli (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025).

Lo script utilizzato si basava sulla funzione `InferenceClient` del pacchetto `huggingface_hub`, attraverso cui sono state fatte le chiamate API appoggiandosi in particolare al provider Novita, che risultava il più economico.

Le richieste al server del modello, tuttavia, avevano vincoli mensili e giornalieri sia in termini di token in input e output che di numero di richieste. Questi limiti sono stati aggirati creando più profili sulla piattaforma per poter disporre in parallelo delle risorse API di più piani di iscrizione gratuiti. Inoltre, sono stati presi due

accorgimenti per poter condurre la replicazione con efficienza e precisione: per evitare che il work-flow fosse interrotto ogniqualvolta si andasse incontro ai vincoli d'uso, si è fatto in modo che le richieste fossero diluite nel tempo; invece, per garantire che a seguito di una interruzione il modello ricominciasse a generare giudizi esattamente dall'ultima richiesta fallita, si sono inseriti dei file di checkpoint per tenere traccia degli item rimasti da giudicare e dei parametri da considerare (es: numero di rater virtuali).

Il codice usato per la generazione, quello per l'analisi dei dati, tutti i dataset (originali e generati) e i prompt/istruzioni corrispondenti sono disponibili sul mio profilo Github: <https://github.com/orboboro/Metaphorical-rating-LLM-replication-study>.

4.3.4 Prompt

Al fine di realizzare una parità di condizione sperimentale tra esseri umani e modelli, i prompt usati per generare i rating coincidevano quasi del tutto con le istruzioni fornite ai partecipanti in ciascuno degli studi considerati. Le modifiche sono state minime: sono state aggiunte alla fine del testo originale indicazioni sul formato della risposta e specificazioni per limitarla a giudizi quantitativi, vista la tendenza dei modelli a fornire output verbosi. Riportiamo di seguito tale integrazione: *Attenzione: rispondi con uno ed un solo numero per ogni caratteristica e non usare nessuna parola. Riporta i punteggi separati da una virgola e uno spazio (" , "), NESSUN altro divisore è accettato. Riporta i punteggi in questo ordine specifico: per primo il punteggio di [DIMENSIONE 1], per secondo il punteggio di [DIMENSIONE 2], per terzo il punteggio di [DIMENSIONE 3]. Non cambiare l'ordine.*

Sul modello di (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025), sempre per poter comparare a parità di condizioni dati umani e dati sintetici, non sono state usate tecniche di prompt-engineering . Tuttavia, nelle istruzioni originali venivano sempre forniti degli esempi di rating per ognuna delle dimensioni in esame, quindi l'inferenza del modello può essere definita di fatto un caso di few-shot learning.

A livello operativo, la risposta del modello veniva 'elicitata' attraverso la funzione `client.chat.completions.create`, che riceveva tra i parametri di input il prompt come oggetto Python. Questo, consisteva in una lista di due dizionari: il primo conteneva il prompt di sistema riproposto ad ogni chiamata, ovvero le istruzioni di rating; il secondo invece forniva il prompt dell'utente, cioè la specifica metafora da valutare, aggiornata di volta in volta iterando sul dataset da replicare.

Nel caso del metodo di generazione M (che vedremo nel prossimo paragrafo), la risposta del modello veniva registrata in un terzo dizionario, e all'iterazione successiva, oltre al prompt di sistema e la nuova metafora, il modello riceveva in input anche gli item metaforici passati e le relative risposte date (pur nella finestra di memoria di 5 elementi).

4.3.5 Metodologie a confronto

Uno degli obiettivi dell'esperimento era osservare come variavano le correlazioni fra dati sintetici e dati reali se si adottava un certo approccio metodologico piuttosto che un altro nella generazione dei giudizi. In particolare, si sono considerate tre metodi: uno preso come standard e due come confronto sperimentale. Per i dati generati con ognuno di essi si sono calcolate e confrontate le principali correlazioni tra i giudizi umani e quelli prodotti da LLaMa-3.3-70B (nel caso del metodo standard però si sono considerati anche i giudizi prodotti da LLaMa-3.1-8B, e sui dati sono state condotte ulteriori analisi).

Rater virtuale singolo

La metodologia standard è quella del rater virtuale singolo (RS) poiché, come riscontrato in lavori precedenti, permette di ottimizzare la performance del modello nel convergere coi dati umani (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025). Consiste nel far generare a ogni modello un solo giudizio per metafora impostando la temperatura a 0 ed estraendo, ad ogni step generativo, la log probability associata ad ognuno dei 3 token più probabili. La risposta del modello per ogni rating richiesto viene poi calcolata facendo la media ponderata delle sue 3 previsioni più probabili, pesando ciascuna secondo la propria log probability. Questo modus operandi ha il pregio di garantire un'ottimo compromesso tra coerenza della risposta e rappresentatività della varietà delle opinioni umane, il tutto con grande efficienza in termini di risorse computazionali e tempo.

Rater virtuali molteplici

Un altro modo per approssimare la varietà delle risposte umane ad una stessa richiesta di rating consiste nel creare molteplici rater virtuali (RM). Per farlo è necessario alzare la temperatura e far valutare al modello ogni metafora tante volte quanti valutatori virtuali vogliamo simulare (10 nel nostro caso).

In studi passati, questo metodo di generazione si è rivelato fallace nel rappresentare la varietà umana (Ravelli and Bolognesi; 2024), ma si è voluto comunque includerlo come termine di confronto col metodo standard.

Rater virtuale dotato di memoria

Il terzo metodo condivide col metodo standard il setting della temperatura e la modalità di calcolo dell'output come media ponderata dei top 3 token sulle loro log probability. Tuttavia, il metodo del rater virtuale dotato di memoria (M) aggiunge un parametro costruito ad hoc, ovvero quello della memoria per l'appunto: per ogni dataset si rende il modello in grado di ricordare le 5 metafore già somministrategli in precedenza, con

annesse risposte. L'ordine di somministrazione è stato ottenuto mescolando casualmente gli item così come erano ordinati nel dataset (`random state = 42`).

Quest'ordine non corrisponde a quello usato per sottoporre le metafore ai rater umani: negli studi originali vi erano delle liste di (pseudo)randomizzazione che assicuravano l'eliminazione di più bias possibili in fase di somministrazione. Il metodo M non intende riprodurre fedelmente il setting originale, ma testare il comportamento del modello in una condizione sperimentale speciale, che simula l'effetto del carry-over cognitivo negli esseri umani: l'aver assegnato un certo punteggio alla metafora precedente nel questionario, può avere un'influenza nel punteggio che si assegna alla metafora corrente.

4.4 Risultati

4.4.1 Analisi dei dati

L'analisi statistica dei risultati è stata condotta con gli strumenti di calcolo offerti dal pacchetto Python `scipy.stats`. In particolare sono stati usati i seguenti metodi: `spearmanr`, `pearsonr`, `f_test`, `mantel_test`, `ttest_ind` e `shapiro`.

Inoltre, nel caso dei rating di MI e BA, che hanno range 1-5, si è provveduto a rimapparli nel range 1-7 attraverso normalizzazione.

A meno che non venga esplicitato, tutte le generazioni sono state effettuate tramite il metodo standard RS e le correlazioni misurate con il coefficiente di Spearman.

Correlazioni tra giudizi umani e sintetici per dimensione su metafore di uso quotidiano

Entrambi i modelli hanno prodotto giudizi che correlano positivamente con quelli umani in modo quasi sempre significativo³.

I coefficienti risultanti dalla correlazione dei giudizi umani con quelli di LLaMa-3.3-70B sono riportati nella tabella 4.1. Nella fascia di correlazione debole troviamo *difficulty* (0.10), *familiarity* (0.18) e *meaningfulness* (0.24); in quella media *physicality* (0.47) e *imageability* (0.49); mentre nella fascia più alta, addirittura oltre la soglia ideale, troviamo la *body relatedness* (0.81).

Quanto a LLaMa-3.1-8B, le sue correlazioni sono illustrate nella tabella 4.2: tutte le dimensioni stanno nella fascia di correlazione debole, mentre ancora una volta spicca la *body relatedness*, con una correlazione medio-alta pur sotto la soglia ideale (0.64).

³ I p-value oltre la soglia dello 0.05 sono segnalati da un asterisco, mentre quelli maggiori di 0.1 con due

Dimension	n items	Spearman's rho	p-value
Familiarity	194	0.18	1.30e-02
Meaningfulness	204	0.24	5.56e-04
Body relatedness	64	0.81	5.36e-16
Difficulty	80	0.10*	4.01e-01
Phisicality	42	0.47	1.56e-03
Imageability	42	0.49	1.02e-03

Tabella 4.1: Correlazioni per il modello LLaMa-3.3-70B

Dimension	n items	Spearman's rho	p-value
Familiarity	194	0.22	2.12e-03
Meaningfulness	204	0.26	1.29e-04
Body relatedness	64	0.64	1.18e-08
Difficulty	80	0.05*	6.91e-01
Phisicality	42	0.27*	8.14e-02
Imageability	42	0.18*	2.48e-01

Tabella 4.2: Correlazioni per il modello LLaMa-3.1-8B

Analisi qualitativa dei giudizi meglio e peggio correlati in body relatedness

Da un'analisi qualitativa degli item metaforici emerge che, nei giudizi relativi alla dimensione della body relatedness, LLaMa-3.3-70B tende a discostarsi maggiormente dai rating umani quando l'espressione metaforica fa riferimento a oggetti. Al contrario, sembra che in presenza di un riferimento esplicito a una parte del corpo, i giudizi prodotti risultano più allineati con quelli umani⁴.

Curiosamente, LLaMa-3.1-8B esibisce invece il comportamento opposto: mostra una maggiore convergenza con i rating umani quando le espressioni metaforiche fanno riferimento a oggetti, mentre tende a discostarsene maggiormente nei casi in cui il riferimento è esplicito a parti del corpo.

rank min diff	metaphor	human	synthetic	abs_diff
Top 1	quel viso è una seta	5.96	6.00	0.04
Top 2	quei peli sono aghi	5.92	6.01	0.09
Top 3	quella pelle è una porcellana	5.85	6.00	0.16

Tabella 4.3: Top 3 metafore in cui la differenza tra i giudizi di LLaMa-3.3-70B e quelli degli esseri umani è minima

⁴ Si tratta comunque di un'osservazione di carattere impressionistico più che di una conclusione statisticamente fondata: deriva dal confronto dei tre casi con la divergenza minima e dei tre con la divergenza massima tra rating umani e sintetici. Poiché gli item non erano annotati sistematicamente come object-related o body-related, non è stato possibile verificare se questo parametro avesse un effetto statisticamente significativo sulla convergenza dei giudizi.

rank min diff	metaphor	human	synthetic	abs_diff
Bottom 1	quel sorriso è una stella	5.15	1.12	4.03
Bottom 2	quel pannolino è una diga	3.50	1.00	2.50
Bottom 3	quel vestito è una tenda	3.46	1.00	2.46

Tabella 4.4: Top 3 metafore in cui la differenza tra i giudizi di LLaMa-3.3-70B e quelli degli esseri umani è massima

rank min diff	metaphor	human	synthetic	abs_diff
Top 1	quel cappello è un fungo	2.62	2.64	0.02
Top 2	quella sigaretta è un proiettile	2.92	2.95	0.03
Top 3	quel diario è una miniera	1.67	1.63	0.04

Tabella 4.5: Top 3 metafore in cui la differenza tra i giudizi di LLaMa-3.1-8B e quelli degli esseri umani è minima

rank min diff	metaphor	human	synthetic	abs_diff
Bottom 1	quel viso è una seta	5.96	2.03	3.93
Bottom 2	quell'orecchio è una padella	5.35	1.44	3.90
Bottom 3	quelle labbra sono un canotto	6.38	2.48	3.90

Tabella 4.6: Bottom 3 metafore in cui la differenza tra i giudizi di LLaMa-3.1-8B e quelli degli esseri umani è massima

Controllo del data leakage

Le metafore sono state suddivise in item pre-cutoff e post-cutoff sulla base delle informazioni riportate nei file originali del Figurative Archive (per ogni metafora era indicato se e in quali studi fosse già comparsa). L'analisi delle correlazioni è stata condotta separatamente per ciascuna dimensione di rating. Di conseguenza, quando una metafora risultava già presente in uno studio precedente al cutoff, veniva esclusa dal set post-cutoff solo nel caso in cui quello studio includesse anche il rating relativo alla stessa dimensione oggetto dell'analisi corrente. Ha infatti senso preoccuparsi di un possibile data leakage solo quando non soltanto la metafora, ma anche il relativo giudizio su quella specifica dimensione, potrebbe essere comparso nei dati di addestramento. Le dimensioni di body relatedness e imageability non sono state considerate in questo controllo, poiché tutte le metafore valutate secondo tali parametri risultavano inedite. Contrariamente all'ipotesi iniziale, entrambi i modelli, ma LLaMa-3.1-8B in particolare, hanno mostrato correlazioni molto più alte proprio sui giudizi relativi a metafore certamente non viste nel loro training. Infatti solo nel caso di LLaMa-3.3-70B, e limitatamente alle dimensioni di familiarity e meaningfulness, il modello ha esibito convergenze leggermente maggiori coi giudizi umani. Inoltre, nel caso di LLaMa-3.1-8B,

ci sono state addirittura 2 correlazioni negative (difficulty e phisicality) che invece cambiano di segno se si considerano le metafore post-cutoff. I dati in questione possono essere ritrovati in tabella 4.7 e tabella 4.8.

Dimension	PR corr	PR p-val	PO corr	PO p-val	Diff (%)
Familiarity	0.20*	1.31e-01	0.13*	1.37e-01	-35.22
Meaningfulness	0.32*	2.80e-02	0.29	2.22e-04	-9.35
Difficulty	0.05*	7.75e-01	0.24*	1.51e-01	423.27
Phisicality	0.38*	5.38e-02	0.47*	7.61e-02	25.64

Tabella 4.7: Correlazioni e cambiamenti percentuali tra dimensioni pre-cutoff (PR) e post-cutoff (PO) considerando i giudizi prodotti da LLaMa-3.3-70B.

Dimension	PR corr	PR p-val	PO corr	PO p-val	Diff (%)
Familiarity	0.02*	8.65e-01	0.16*	5.85e-02	621.35
Meaningfulness	0.08*	5.93e-01	0.31	6.13e-05	293.11
Difficulty	-0.05*	7.70e-01	0.05*	7.77e-01	202.54
Phisicality	-0.10*	6.04e-01	0.61	1.57e-02	683.81

Tabella 4.8: Correlazioni e cambiamenti percentuali tra dimensioni pre-cutoff (PR) e post-cutoff (PO) considerando i giudizi prodotti da LLaMa-3.1-8B.

Correlazioni tra giudizi umani e sintetici per dimensione su metafore letterarie

Indipendentemente dall'ipotesi di data leakage, è stata analizzata anche la correlazione tra i giudizi relativi alle metafore letterarie contenute nel dataset BA limitatamente alle tre dimensioni di familiarity, meaningfulness e difficulty.

Come mostrano le tabelle 4.9 e 4.10, insieme ai grafici in figura 4.1, entrambi i modelli producono rating significativamente più allineati a quelli umani quando le metafore valutate provengono dal dominio letterario. In particolare, per la dimensione della difficulty il coefficiente di correlazione aumenta in modo marcato: risulta circa quadruplicato per LLaMa-3.3-70B e addirittura moltiplicato per sette nel caso di LLaMa-3.1-8B.

High familiarity vs low familiarity

Da questo paragrafo in poi, gli unici dati sintetici che prenderemo in considerazione nelle nostre misurazioni saranno quelli prodotti da LLaMa-3.3-70B, che rispetto alla versione da 8 miliardi di parametri può generare dati più significativi per il nostro

Dimension	corr	p-value	% change
Familiarity	0.52	2.68e-09	191.69
Difficulty	0.48	4.62e-08	407.18
Meaningfulness	0.55	1.86e-10	129.69

Tabella 4.9: Statistiche di correlazione e variazione percentuale del coefficiente in BA rispetto a MB, ME, MM aggregati, in riferimento ai giudizi sintetici di LLaMa-3.3-70B.

Dimension	corr	p-value	% change
Familiarity	0.27	4.17e-03	20.93
Difficulty	0.37	4.13e-05	725.88
Meaningfulness	0.43	1.90e-06	61.34

Tabella 4.10: Statistiche di correlazione e variazione percentuale del coefficiente in BA rispetto a MB, ME, MM aggregati, in riferimento ai giudizi sintetici di LLaMa-3.1-8B.

scopo generale: osservare in che misura un modello di linguaggio può replicare il comportamento umano in un task di rating sulle metafore.

Usando come spartiacque il valore mediano dei rating umani, si sono divisi i dati tra metafore molto familiari e metafore poco familiari (considerando anche quelle letterarie). A questo punto si è indagato come variasse la correlazione tra giudizi umani e sintetici nelle varie dimensioni mettendo a confronto i due sottogruppi.

Dai risultati (tabella 4.11) è emerso che la correlazione resta sostanzialmente stabile al variare del parametro preso in considerazione (alta/bassa familiarità delle metafore giudicate). Le oscillazioni dei valori sono minime, ma le più grandi suggeriscono che in certi casi il modello produca rating più simili a quelli umani quando giudica metafore poco familiari: la familiarity stessa passa da 0.31 a 0.44, la body relatedness da 0.73 a 0.89. I dati possono essere ben visualizzati nell'istogramma in figura 4.2.

Familiarity	Dimension	Spearman Corr	p-value
high	Familiarity	0.31	1.04e-04
low	Familiarity	0.44	1.13e-08
high	Meaningfulness	0.67	1.44e-21
low	Meaningfulness	0.62	1.56e-17
high	Body relatedness	0.73	3.57e-08
low	Body relatedness	0.89	2.33e-04
high	Difficulty	0.47	3.34e-04
low	Difficulty	0.45	1.72e-08

Tabella 4.11




Figura 4.1: Correlazioni tra i giudizi umani e sintetici nelle varie dimensioni sulle metafore letterarie.

High embodiment vs low embodiment

Analogamente a quanto fatto per la variabile di familiarity, le mediane di body relatedness e physicality sono state utilizzate per definire due coppie di sottogruppi: una




Figura 4.2: Istogramma per visualizzare come cambia la convergenza tra giudizi umani e sintetici a seconda che le metafore siano molto o poco body related

comprendente metafore ad alto grado di embodiment (high body relatedness e high physicality) e una metafore a basso grado di embodiment (low body relatedness e low physicality).

Calcolando separatamente le correlazioni per ciascun sottogruppo di entrambe le coppie, si osserva che tutte le correlazioni relative alle metafore fortemente embodied presentano p-value superiori alla soglia di 0.05. Non è quindi possibile escludere che i valori di correlazione osservati in questi casi siano dovuti al caso. Come mostra la tabella 4.12, rimane però un andamento sistematico degno di nota: le metafore giudicate dagli umani come poco body related vengono valutate dal modello in modo nettamente più simile agli esseri umani lungo le dimensioni di familiarity e meaningfulness, e in modo moderatamente più simile anche rispetto alla stessa body relatedness.

Per quanto riguarda invece la distinzione in base alla physicality, dalla tabella 4.13 si evince che anche le correlazioni calcolate sul sottogruppo di metafore a bassa physicality risultano non significative. In questo caso, dunque, non emerge una differenziazione statisticamente affidabile tra metafore più e meno embodied.

Nell'istogramma in figura 4.3 è resa esplicita la situazione descritta dai dati in questione.

Distribuzione e varianza dei giudizi

I valori dei rating per ciascuna dimensione, sia nei partecipanti umani sia nel modello, non seguono una distribuzione normale (ipotesi testata col test di Shapiro–Wilk). Nonostante ciò, dalle distribuzioni mostrate in figura ?? emergono differenze evidenti tra i due gruppi. Per quantificare la variabilità dei giudizi, sono stati calcolati la

Body relatedness	Dimension	Spearman corr	p-value
High	Familiarity	0.03**	8.58e-01
Low	Familiarity	0.71	2.37e-04
High	Meaningfulness	0.01**	9.83e-01
Low	Meaningfulness	0.65	5.20e-05
High	Body relatedness	0.13*	4.90e-01
Low	Body relatedness	0.38*	3.31e-02

Tabella 4.12

Phisicality	Dimension	Spearman corr	p-value
High	Phisicality	0.44*	4.53e-02
Low	Phisicality	0.43*	5.36e-02
High	Imageability	0.44*	4.57e-02
Low	Imageability	0.15**	5.20e-01

Tabella 4.13

deviazione standard e la mediana di ciascuna dimensione, separatamente per gli esseri umani e per il modello. Successivamente, per verificare se le differenze nella varianza fossero statisticamente significative, è stato applicato un test F per ciascuna dimensione. I risultati di queste analisi si trovano in tabella 4.14.

In generale, i dataset umani mostrano una minore variabilità rispetto ai dati sintetici, soprattutto nelle dimensioni body relatedness e imageability (1.73 e 1.03 rispettivamente), proprio dove la deviazione standard dei dati sintetici risulta più alta (2.71 e 1.88). Questo suggerisce che le valutazioni sintetiche tendono a essere più disperse. Dimensioni come difficulty e meaningfulness mostrano invece una maggiore omogeneità tra le due distribuzioni, con differenze più contenute nelle deviazioni standard.

Per quanto riguarda la centralità dei valori, i dati umani presentano medie e mediane generalmente più moderate rispetto ai sintetici. Ad esempio, la mediana di body relatedness nei dati umani è 3.81, mentre quella sintetica è 1.63.

Il test F sulle varianze evidenzia differenze significative in alcune dimensioni. In particolare, body relatedness, difficulty e imageability mostrano p-value molto bassi (inferiori a 0.001), confermando che le varianze tra dati umani e sintetici non sono equivalenti. Al contrario, dimensioni come familiarity e meaningfulness non presentano differenze statisticamente significative nelle varianze, con p-value rispettivamente pari a 0.54 e 0.24.

Confronto tra i metodi

Un'ulteriore analisi rilevante consiste nel verificare se i dati sintetici ottenuti con gli altri metodi di generazione (RM e M) risultino più o meno correlati ai giudizi umani rispetto a quelli prodotti con RS.




Figura 4.3: Istogramma per visualizzare come cambia la correlazione tra giudizi umani e sintetici a seconda che le metafore giudicate siano molto o poco body related (sinistra) oppure molto o poco physical (destra)

Dimension	Std human	Std synthetic	F stat	p-value
Body relatedness	1.73	2.71	0.41	4.97e-04
Difficulty	0.74	1.13	0.43	1.11e-08
Familiarity	1.29	1.24	1.07*	5.41e-01
Imageability	1.03	1.88	0.30	1.98e-04
Meaningfulness	1.31	1.40	0.88*	2.37e-01
Physicality	1.65	1.26	1.73*	8.35e-02

Tabella 4.14: Confronto tra deviazioni standard e statistiche F per dimensione

Dai dati riportati in tabella 4.15 emerge che, al variare del metodo di generazione, la body relatedness rimane la dimensione con il coefficiente di correlazione più elevato. Si osservano però differenze nelle altre dimensioni.

Rispetto a RS, il metodo RM produce correlazioni leggermente inferiori quasi ovunque (con una variazione percentuale massima del 7.48), fatta eccezione per meaningfulness e difficulty, che mostrano invece un aumento della correlazione, rispettivamente del 26.29% e del 25.98% (sebbene con un p-value non significativo).

Quanto al metodo M, guardando il grafico di figura 4.6 risulta evidente che la superiorità dei valori di correlazione ottenuti con RS in tutte le dimensioni esaminate. Gli incrementi più marcati si osservano in difficulty (variazione percentuale 91.27, ma con $p > 0.05$), meaningfulness (32.00%) e familiarity (22.66%).

4.4.2 Studio di sostituzione

Sulla falsa riga dei lavori appartenenti allo stesso framework sperimentale, sono state svolte analisi che coinvolgevano solo dati umani, le cui conclusioni sono poi state con-




Figura 4.4: Visualizzazione della distribuzione e della dispersione attorno alla media per i rating di familiarità, significatività e difficoltà, divisi tra umani e sintetici.

frontate con quelle ottenute facendo le stesse analisi sui dati prodotti dai modelli (Trott; 2024) (Mangiaterra, Al-Azary, Pietro, Canal and Bambini; 2025). Lo scopo è capire se facendo tutte le misurazioni basandoci su dati sintetici saremmo comunque giunti alle




Figura 4.5: Visualizzazione della distribuzione e della dispersione attorno alla media per i rating di relazione col corpo, fisicità e immaginabilità, divisi tra umani e sintetici.

stesse conclusioni, dunque se e quanto possiamo legittimamente possiamo sostenere che i risultati calcolati a partire da dati sintetici possano essere generalizzati per gli umani.




Figura 4.6: Istogrammi delle correlazioni tra giudizi sintetici (prodotti con LLaMa-3.3-70B) e giudizi reali, a seconda della dimensione e della condizione metodologica.

Dimension	RM vs RS	M vs RS
Familiarity	-7.48*	22.66
Meaningfulness	26.29	32.00
Body relatedness	-0.22	3.07
Difficulty	25.98*	91.28*
Phisicality	-0.22	6.37
Imageability	-4.14	13.80

Tabella 4.15: Variazione percentuale delle correlazioni rispetto alla condizione RS. L'asterisco indica $p\text{-value} > 0.05$.

Correlazioni umane vs correlazioni sintetiche

Sono state calcolate le matrici di correlazione tra tutte le dimensioni disponibili in ciascun dataset, considerando sia i dati umani sia quelli sintetici. Per i dataset con almeno tre dimensioni (MB, ME, BA) è stata eseguita una regressione lineare tra ciascuna combinazione binaria di dimensioni, mentre per i dataset con due dimensioni (MM, MI) sono state calcolate direttamente le correlazioni tra le coppie di dimensioni presenti. Successivamente, seguendo il modello di (Trott; 2024), è stato applicato il Mantel test utilizzando il coefficiente di Pearson con 1000 permutazioni randomiche per confrontare matrici di correlazione umane e sintetiche.

Nel dataset MB, la correlazione tra familiarity e meaningfulness è molto alta sia per gli umani (0.90, $p < 0.001$) che per il modello (0.82, $p < 0.001$). La correlazione tra familiarity e body_relatedness è più moderata negli umani (0.38, $p = 0.004$) e leggermente

più alta nei dati sintetici (0.50, $p < 0.001$).

Nel dataset ME, familiarity e meaningfulness risultano correlate positivamente negli umani (0.57, $p < 0.001$) e nel modello (0.73, $p < 0.001$), mentre la difficulty mostra correlazioni negative con entrambe le dimensioni, più accentuate nei dati sintetici (familiarity-difficulty: -0.83, $p < 0.001$).

Nei dataset MM e MI, dove sono presenti solo due dimensioni ciascuno, le correlazioni tra familiarity e meaningfulness (MM) e tra phisicality e imageability (MI) sono elevate sia nei dati umani (0.85 e 0.80) che in quelli sintetici (0.94 e 0.85), indicando una forte coerenza tra le due tipologie di dati.

Nel dataset BA, si osservano correlazioni molto forti, sia positive (familiarity-meaningfulness: 0.69 negli umani, 0.90 nel modello) che negative (difficulty-meaningfulness: -0.88 negli umani, -0.84 nel modello; familiarity-difficulty: -0.60 negli umani, -0.95 nel modello), confermando che i pattern di associazione tra le dimensioni principali sono ben replicati nei dati sintetici, sebbene con valori leggermente più estremi.

Riproducibilità della differenza tra metafore letterarie e d'uso comune


In un'analisi finale, è stato confrontato come i rating delle metafore letterarie differiscano da quelli delle metafore d'uso comune, e se queste differenze siano replicate nei dati sintetici. Per valutare la significatività delle differenze è stato utilizzato il Welch's t-test.

Nei dati umani, le metafore d'uso comune risultano significativamente più familiari e significative rispetto a quelle letterarie, mentre le metafore letterarie sono percepite come più difficili. Le differenze sono marcate: ad esempio, la familiarity media è 2.24 per le metafore letterarie e 3.73 per quelle d'uso comune, con $t = -14.00$. Analogamente, per la meaningfulness $t = -20.80$, e per la difficulty $t = 16.96$, confermando differenze altamente significative.


Queste tendenze si ritrovano nelle misurazioni sui dati sintetici, sebbene le differenze siano leggermente meno accentuate: le metafore d'uso comune risultano più familiari (3.98 vs 2.84), più significative (5.21 vs 3.55), mentre le metafore letterarie sono più difficili (2.94 vs 1.92). Anche in questo caso, tutti i test risultano altamente significativi (familiarity: $t = -8.61$; meaningfulness: $t = -13.26$; difficulty: $t = 6.90$).

4.5 Discussione


In tutte e 6 le dimensioni sotto indagine, sia LLaMa-3.3-70B che LLaMa-3.1-8B hanno prodotto rating che correlavano positivamente con quelli umani. Tuttavia non possiamo accettare integralmente l'ipotesi 1a, poiché tutti i coefficienti, con l'unica eccezione di quello relativo a LLaMa-3.3-70B per la body relatedness, restano nella fascia medio-bassa di forza correlativa, ovvero sotto la soglia ideale dello 0.80.




(a) Giudizi umani su MB




(b) Giudizi sintetici su MB




(c) Giudizi umani su ME



(d) Giudizi sintetici su ME



(e) Giudizi umani su BA



(f) Giudizi sintetici su BA

Figura 4.7: Matrici di correlazione per ogni dataset con almeno 3 dimensioni.

Nel complesso, i risultati sono incoraggianti perché mostrano una coerenza direzionale sistematica tra giudizi sintetici e umani, ma suggeriscono che sia ancora prematuro utilizzare questi modelli per generare dati sintetici destinati ad analisi generalizzabili o da integrare direttamente con dati umani. Fa eccezione, in parte, il caso di LLaMa-3.3-70B, che mostra prestazioni sufficientemente solide sulla body

group	dimension	P mean	D mean	diffe	t test	p-value
human	familiarity	2.24	3.73	-1.49	-14.00	$1.83e - 34$
human	meaningfulness	2.63	4.54	-1.91	-20.80	$6.56e - 61$
human	difficulty	3.03	1.89	1.14	16.96	$5.25e - 40$
synthetic	familiarity	2.84	3.98	-1.13	-8.61	$1.20e - 15$
synthetic	meaningfulness	3.55	5.21	-1.66	-13.26	$1.05e - 31$
synthetic	difficulty	2.94	1.92	1.02	6.90	$1.00e - 10$

Tabella 4.16: Differenza di giudizio tra esseri umani e LLaMa-3.3-70B nel valutare metafore letterarie (P) e d’uso quotidiano (D) quanto a familiarity, meaningfulness e difficulty.

relatedness da rendere plausibile una prima applicazione sperimentale dell’automatizzazione dei rating in questo ambito specifico, purché con adeguata cautela metodologica.

Considerando i risultati del Mantel test applicato alle matrici di correlazione tra dimensioni nei dataset umani e sintetici, emerge che i dati sintetici replicano in modo coerente la struttura delle relazioni osservate nei dati reali. Il segno delle correlazioni tra dimensioni viene sempre mantenuto, ma con una tendenza a produrre coefficienti più estremi. Ad esempio, la correlazione negativa tra familiarity e difficulty, pari a 0.57 (ME) e 0.60 (BA) nei dataset umani, diventa più forte nei dataset sintetici, rispettivamente 0.83 (ME) e 0.95 (BA); analogamente, i coefficienti di correlazione tra familiarity e meaningfulness calcolati sui dati reali vanno da 0.57 (ME) a 0.90 (MB), passando per 0.69 (BA) mentre nel caso dei dati sintetici vanno da 0.73 (ME) a 0.90 (BA), passando per 0.82 (MB).

Curiosamente si osserva una dinamica opposta, ma fondamentalmente coerente, nel confronto tra metafore letterarie e metafore d’uso comune: anche qui i dati sintetici preservano la direzione delle relazioni tra dimensioni (metafore d’uso comune più familiari e significative, metafore letterarie più difficili), ma in questo caso mostrano differenze meno marcate rispetto ai dati umani, quindi un effetto di attenuazione piuttosto che di estremizzazione.

Nel complesso, risultati di questo tipo consentono di accogliere l’ipotesi 1b e supportano l’uso dei dataset sintetici per simulazioni e analisi di correlazioni, pur evidenziando la necessità di tenere conto di possibili distorsioni nell’ampiezza degli effetti stimati.

Per quanto riguarda l’ipotesi 2, essa è in questo caso da rifiutare, poiché i risultati dimostrano come non solo i coefficienti di correlazione tra giudizi umani e sintetici su item pre-cutoff non sono più alti di quelli su item-post cutoff, ma sono sistematicamente più bassi. Questi risultati suggeriscono che, almeno per i modelli e per le dimensioni considerate, non ha senso ipotizzare una sovrapposizione tra test set e training set.

Passiamo ora al confronto tra i metodi di generazione. Nell’ottica

di far produrre al modello rating sintetici il più vicini possibile a quelli umani, RM sembra tutto sommato equivalentemente a RS, mentre M pare il migliore, anche se non tutti gli incrementi di coefficienti raggiungono la significatività statistica. Un'ipotesi che possiamo avanzare per spiegare questo miglioramento è che l'inclusione di contesto valutativo precedente permetta al modello di calibrarsi meglio sul task richiesto, e determini maggiore stabilità delle risposte del modello, pur autocondizionandosi.

Proseguendo la disamina dei risultati ottenuti, non possiamo non soffermarci sulla correlazione di punta per entrambi i modelli, ovvero quella riguardante i giudizi di body relatedness. Nel caso di LLaMa-3.3-70B, infatti, il coefficiente supera la soglia di correlazione ideale con un coefficiente di 0.81 ($p\text{-value} < 0.001$), suggerendo che il modello sia piuttosto sensibile alla dimensione embodied dei significati. Questo fatto mette in dubbio l'idea che sia necessario un grounding percettivo per simulare efficacemente la psiche umana, soprattutto in domini valutativi legati alla sfera del corpo.

Tuttavia bisogna tenere conto dell'altra parte dei risultati: item metaforici altamente body related sembrano mettere in crisi il modello, che produce giudizi scarsamente correlati a quelli umani; correla invece molto sulle metafore giudicate poco body related dagli umani. Sembra allora che dobbiamo effettivamente accogliere l'ipotesi 3, e sostenere che il fatto di non avere un corpo non permette al modello di avere sviluppare rappresentazioni esaurienti dei significati più embodied, e dunque nemmeno di replicare il comportamento umano nel valutare aspetti semantici legati alla corporeità.

Un'ulteriore evidenza in questo senso deriva dall'osservazione della variabilità dei dati all'interno di ciascuna dimensione. Notiamo, infatti, che il modello tende in generale a produrre giudizi più eterogenei degli esseri umani, ma lo fa soprattutto quando deve esprimersi su dimensioni più concrete (body relatedness e imageability); nelle dimensioni più astratte (familiarity e meaningfulness) le differenze di varianza tra dati umani e sintetici risultano trascurabili. Se poi consideriamo che il valore mediano di body relatedness negli esseri umani è 3.81 (praticamente a metà della scala Likert), mentre nel modello è 1.63, con metà delle metafore giudicate come molto poco corporee, emerge una discrepanza significativa nella percezione della dimensione in questione.

Un altro risultato interessante riguarda la correlazione tra i giudizi in riferimento alle metafore letterarie: i modelli imitano meglio il comportamento valutativo umano quando giudicano metafore letterarie rispetto a quelle di uso quotidiano. Questi risultati sono inattesi poiché le metafore letterarie dovrebbero essere quelle che più mettono alla prova la competenza linguistica dei modelli. Secondo (Bowdle and Gentner; 2005), infatti, le metafore letterarie sono quelle dal significato meno convenzionale; ciò è coerente anche con il campione analizzato, in cui la familiarità media attribuita dagli annotatori umani è più bassa per le metafore letterarie rispetto a quelle d'uso comune. Una minore convenzionalità implica tipicamente minore frequenza d'uso e una più forte componente embodied del significato (non ancora lessicalizzati), entrambi fattori che

in linea teorica dovrebbero rendere più difficile per i modelli costruire rappresentazioni semantiche efficaci basandosi esclusivamente su criteri distribuzionali.

D'altra parte, anche altri dati derivanti da queste analisi si scontrano con l'idea che una minore convenzionalità in termini di familiarità percepita determini necessariamente una minore competenza semantica da parte del modello: le metafore meno familiari non sono giudicate meglio rispetto a quelle più familiari, anzi nel caso della body relatedness la performance del modello passa da 0.73 a 0.89, superando la soglia di correlazione ideale.

Nell'insieme questi dati permettono dunque di rigettare l'ipotesi 4, poiché evidentemente il grado di familiarità percepita non costituisce un predittore affidabile della qualità dell'allineamento tra valutazioni del modello e valutazioni umane.

Inoltre, questi risultati risultano coerenti con quanto riportato in (Ichien et al.; 2024), dove modelli di linguaggio, sebbene di dimensioni molto maggiori, hanno mostrato una notevole competenza interpretativa su metafore poetiche, producendo parafrasi giudicate dagli esseri umani persino migliori di quelle generate da altri esseri umani.

Concludiamo osservando che se compariamo i giudizi prodotti da LLaMa-3.1-8B nel contesto di questo esperimento con quelli generati in (Conde et al.; 2025), dove gli item da giudicare non erano metaforici, i coefficienti di correlazione con i giudizi umani risultano molto più bassi sia per imageability (0.18 vs 0.70 circa) che per familiarity (0.22 vs 0.70 circa); non è del tutto chiaro, però, quanta di questa differenza sia dovuta alla natura diversa degli item o alla lingua diversa o ancora al campione di parole in questione.

4.6 Limitazioni

4.6.1 Disomogeneità degli stimoli

Gli stimoli dei vari studi non erano completamente omogenei per struttura e presenza di contesto: MB e MI prevedono frasi di forma *Quel(quegli) X è(sono) un(degli) Y*; ME prevede frasi con la stessa costruzione, ma precedute da un complemento che inquadra il contesto del target; MM prevede metafore verbali indirette (le più attestate e plausibili nel linguaggio quotidiano); BA prevede espressioni nominali di struttura X di Y. Questa differenza nella natura degli stimoli può aver portato a fallacie minime nei risultati (Horvat et al.; 2021).

4.6.2 'Task leakage'

Sebbene nel presente lavoro sia stata considerata con attenzione la questione del data leakage, distinguendo tra metafore pre- e post-cutoff, non si è tenuto conto del fatto

che il task di rating in sé non può essere considerato post-cutoff, dato che in letteratura esistono già numerosi studi analoghi. Di conseguenza, anche se i risultati mostrano che gli item inediti non vengono giudicati peggio rispetto a quelli già pubblicati, anzi, non è possibile escludere del tutto che ciò dipenda da una forma di ‘reminiscenza’ del modello relativa al tipo di compito richiesto, più che da una reale capacità di generalizzazione delle competenze acquisite durante l’addestramento.

4.6.3 Impossibilità di confrontare l’accordo tra gli annotatori

Purtroppo, essendo disponibili solo le medie dei rating in ogni dataset preso in considerazione, non è stato possibile risalire all’indice di inter-annotator agreement. Dunque non è stato possibile constatare se in questa occasione sperimentale il metodo RM avesse simulato fedelmente la varietà dei giudizi umani.

4.6.4 Problemi di memoria

Il fatto che, nella condizione metodologica M, il modello abbia prodotto giudizi maggiormente convergenti con quelli umani non costituisce di per sé una prova della sua maggiore efficacia, poiché potrebbe trattarsi di un effetto casuale legato all’ordine specifico con cui gli item sono stati presentati. Per poter affermare con sicurezza una superiore performance, sarebbe stato necessario ripetere l’analisi variando l’ordine degli item più volte e verificare la stabilità del risultato.

4.7 Direzioni future

L’elevata e sperimentalmente consolidata correlazione tra i tempi di risposta umani e i valori probabilistici di surprisal offre una strada promettente per indagare se la modellizzazione linguistica operata dai LLM rispecchi, almeno sul piano comportamentale, la dinamica prevista dalle varie teorie sul processing dei significati metaforici (‘Indirect’ Model, ‘Direct’ Model, Gradient Salience Hypothesis) (Horvat et al.; 2021). In questa prospettiva, come suggerito da (Dillion et al.; 2023), l’impiego dei modelli di linguaggio nella fase finale della sperimentazione potrebbe risultare utile per corroborare, o per precisare meglio i limiti, dei risultati ottenuti su partecipanti umani.

Capitolo 5

Conclusioni

Aggregando i risultati discussi nel capitolo precedente con le evidenze sperimentali già disponibili sulla replicazione automatica dei giudizi umani, emerge un quadro articolato ma complessivamente coerente. L'esperimento condotto, infatti, conferma che i modelli di linguaggio di medie e grandi dimensioni mostrano segnali concreti di convergenza con i pattern di giudizio umano in compiti di rating semantico, ma che tale convergenza non è ancora sufficientemente forte né uniforme lungo tutte le dimensioni del significato da giustificare l'uso generalizzato dei LLM in esperimenti psicolinguistici. Le correlazioni tra rating sintetici e rating umani osservate nell'esperimento sono per lo più positive e in alcuni casi, come nella dimensione della body relatedness per LLaMa-3.3-70B, raggiungono livelli elevati; tuttavia, nella maggior parte delle dimensioni restano al di sotto dello 0.80.

Le matrici di correlazione tra dimensioni, inoltre, mostrano che i modelli tendono a preservare la struttura relazionale dei dati umani, pur amplificando o attenuando l'intensità degli effetti. Questo suggerisce che i modelli possano già oggi offrire un contributo informativo utile alla ricerca psicolinguistica, ma non ancora fungere da rimpiazzo affidabile del campione umano. I dataset sintetici, infatti, per quanto promettenti in sede di analisi esplorative e simulazioni pilota, richiedono correzioni e verifiche nel caso siano impiegati per quantificare in modo preciso la relazione tra due serie di valori psicolinguisticamente rilevanti.

Quanto al problema del data leakage, i dati forniscono indicazioni incoraggianti, pur con una limitazione specifica. Da un lato, l'assenza di un vantaggio sistematico per gli item pre-cutoff ridimensiona il timore che in questo caso le buone performance dipendano semplicemente da una memorizzazione dei dataset. Dall'altro, non si può escludere del tutto un effetto di familiarità con il tipo di task, visto che questo risultava già ampiamente documentato prima del knowledge cutoff. Dunque si rende necessario testare i questi sistemi su task per loro inediti, sul modello di (Ravelli and Bolognesi; 2024), e continuare a progettare nuovi benchmark umani che possano costituire

strumenti di valutazione affidabili della competenza linguistica dei LLM.

I risultati ottenuti nell'esperimento sulle dimensioni embodied mettono in luce una tensione teorica rilevante: da un lato i modelli mostrano una sensibilità sorprendente verso la corporeità del significato; dall'altro, proprio gli item più fortemente embodied producono gli scarti maggiori rispetto ai giudizi umani. Ne emerge l'immagine di una competenza distribuzionale capace di intercettare tracce linguistiche dell'embodiment, ma non di sostituire pienamente il grounding percettivo. In parallelo, il fatto che le metafore letterarie, meno convenzionali, non risultino più problematiche per i modelli indebolisce l'idea che la sola frequenza d'uso (e dunque la familiarità) sia il fattore decisivo nell'allineamento con i giudizi umani.

Dati di questo tipo, quindi, non permettono di confermare né l'ipotesi secondo cui un grounding percettivo sarebbe necessario per sviluppare una piena competenza linguistica, né l'ipotesi alternativa secondo cui un grounding basato esclusivamente sulle proprietà distribuzionali delle parole sarebbe sufficiente a far emergere competenze linguistiche comparabili a quelle umane.

Operativamente, quindi, la prospettiva che si delinea non è quella di una sostituzione, ma di un'integrazione controllata. In questo scenario, rimane come condizione imprescindibile quella di non interrompere mai il confronto con i dati umani, per evitare che una ricerca sperimentale condotta esclusivamente su dati sintetici induca distorsioni sulle nostre teorie sull'elaborazione linguistica e sulla cognizione umana in generale.

Bibliografia

- Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., Almeida, D., Alteschmidt, J., Altman, S., Anadkat, S. et al. (2023). Gpt-4 technical report, *arXiv preprint arXiv:2303.08774* .
- Ainslie, J., Lee-Thorp, J., De Jong, M., Zemlyanskiy, Y., Lebrón, F. and Sanghai, S. (2023). Gqa: Training generalized multi-query transformer models from multi-head checkpoints, *arXiv preprint arXiv:2305.13245* .
- Arcodia, G. F., Panunzi, A. et al. (2023). *Linguistica. Introduzione alle scienze del linguaggio*, Pearson.
- Argiris, G., Budai, R., Maieron, M., Ius, T., Skrap, M. and Tomasino, B. (2020). Neurosurgical lesions to sensorimotor cortex do not impair action verb processing, *Scientific reports* **10**(1): 523.
- Aziz-Zadeh, L., Wilson, S. M., Rizzolatti, G. and Iacoboni, M. (2006). Congruent embodied representations for visually presented actions and linguistic phrases describing actions, *Current biology* **16**(18): 1818–1823.
- Bambini, V., Resta, D. and Grimaldi, M. (2014). A dataset of metaphors from the italian literature: Exploring psycholinguistic variables and the role of context, *PloS one* **9**(9): e105634.
- Barattieri di San Pietro, C., Frau, F., Mangiaterra, V. and Bambini, V. (2023). The pragmatic profile of chatgpt: Assessing the communicative skills of a conversational agent, *Sistemi intelligenti* **35**(2): 379–400.
- Bender, E. M. and Hanna, A. (2025). *The AI Con: How to Fight Big Tech’s Hype and Create the Future We Want*, Random House.
- Bender, E. M. and Koller, A. (2020). Climbing towards nlu: On meaning, form, and understanding in the age of data, *Proceedings of the 58th annual meeting of the association for computational linguistics*, pp. 5185–5198.

- Bengio, Y., Ducharme, R., Vincent, P. and Jauvin, C. (2003). A neural probabilistic language model, *Journal of machine learning research* **3**(Feb): 1137–1155.
- Berruto, G., Cerruti, M. S. et al. (2011). *La linguistica. Un corso introduttivo*, UTET De Agostini.
- Black, M. (1955). Xii-metaphor, *Proceedings of the Aristotelian Society*, Vol. 55, Oxford University Press, Oxford, UK, pp. 273–294.
- Black, M. (1979). More about metaphor, in A. Ortony (ed.), *Metaphor and Thought*, Cambridge University Press, pp. 19–43.
- Borghi, A. M., De Livio, C., Gervasi, A. M., Mannella, F., Nolfi, S. and Tummolini, L. (2024). Language as a cognitive and social tool at the time of large language models, *Journal of Cultural Cognitive Science* **8**(3): 179–198.
- Bowdle, B. F. and Gentner, D. (2005). The career of metaphor., *Psychological review* **112**(1): 193.
- Bressler, M., Mangiaterra, V., Canal, P., Frau, F., Luciani, F., Scalingi, B., Barattieri di San Pietro, C., Battaglini, C., Pompei, C., Romeo, F. et al. (2026). Figurative archive: an open dataset and web-based application for the study of metaphor, *Scientific Data* .
- Cai, P.-X., Fan, Y.-C. and Leu, F.-Y. (2021). Compare encoder-decoder, encoder-only, and decoder-only architectures for text generation on low-resource datasets, *International Conference on Broadband and Wireless Computing, Communication and Applications*, Springer, pp. 216–225.
- Cameron, L. (1999). *Identifying and describing metaphor in spoken discourse data*, Cambridge Applied Linguistics, Cambridge University Press, p. 105–132.
- Campbell, S. J. and Raney, G. E. (2016). A 25-year replication of katz et al.’s (1988) metaphor norms, *Behavior research methods* **48**(1): 330–340.
- Castillo, R. I. and Valenzuela, J. (2025). Using ai to replicate human experimental results: a motion study, *arXiv preprint arXiv:2507.10342* .
- Chang, Y., Wang, X., Wang, J., Wu, Y., Yang, L., Zhu, K., Chen, H., Yi, X., Wang, C., Wang, Y. et al. (2024). A survey on evaluation of large language models, *ACM transactions on intelligent systems and technology* **15**(3): 1–45.
- Conde, J., Saiz, M. G., Grandury, M., Reviriego, P., Martínez, G. and Brysbaert, M. (2025). Psycholinguistic word features: A new approach for the evaluation of llms alignment with humans, *Proceedings of the Fourth Workshop on Generation, Evaluation and Metrics (GEM²)*, pp. 8–17.

- Cuskley, C., Woods, R. and Flaherty, M. (2024). The limitations of large language models for understanding human language and cognition, *Open Mind* **8**: 1058–1083.
- Davidson, D. (1978). What metaphors mean, *Critical inquiry* **5**(1): 31–47.
- de Varda, A. G., Marelli, M. and Amenta, S. (2024). Cloze probability, predictability ratings, and computational estimates for 205 english sentences, aligned with existing eeg and reading time data, *Behavior Research Methods* **56**(5): 5190–5213.
- Desai, R. H. (2022). Are metaphors embodied? the neural evidence, *Psychological Research* **86**(8): 2417–2433.
- Dillion, D., Tandon, N., Gu, Y. and Gray, K. (2023). Can ai language models replace human participants?, *Trends in Cognitive Sciences* **27**(7): 597–600.
- Eluyode, O. and Akomolafe, D. T. (2013). Comparative study of biological and artificial neural networks, *European Journal of Applied Engineering and Scientific Research* **2**(1): 36–46.
- Ervas, F., Gola, E. et al. (2016). *Che cos' è una metafora*, Vol. 536, Carocci.
- Firth, J. R. (1962). A synopsis of linguistic theory, 1930–1955, *Studies in Linguistic Analysis*, Blackwell, Oxford. {original-date:1957}.
- Gallese, V. and Cuccio, V. (2014). The paradigmatic body: Embodied simulation, intersubjectivity, the bodily self, and language, *Open mind*, Open MIND. Frankfurt am Main: MIND Group.
- Gallese, V., Fadiga, L., Fogassi, L. and Rizzolatti, G. (1996). Action recognition in the premotor cortex, *Brain* **119**(2): 593–609.
- Gallese, V. and Lakoff, G. (2005). The brain's concepts: The role of the sensory-motor system in conceptual knowledge, *Cognitive neuropsychology* **22**(3-4): 455–479.
- Gazzaniga, M. S., Ivry, R. B. and Mangun, G. (2006). Cognitive neuroscience. the biology of the mind.(2014).
- Gibbs Jr, R. W. (2006). Metaphor interpretation as embodied simulation, *Mind & Language* **21**(3): 434–458.
- Gibbs Jr, R. W. and Matlock, T. (2008). Metaphor, imagination, and simulation: Psycholinguistic evidence.
- Gibson, J. J. (1979). *The Ecological Approach to Visual Perception*, Houghton Mifflin, Boston.

- Giraldo Ospina, D. L., Suaza Restrepo, A. and Suárez de la Torre, M. (2024). Embodied simulation as a mechanism for understanding concrete and metaphorical language: A literature review., *Revista de Estudos da Linguagem* **32**(2).
- Goatly, A. (2011). Metaphor as resource for the conceptualisation and expression of emotion, *Affective computing and sentiment analysis: Emotion, metaphor and terminology*, Springer, pp. 13–25.
- Günther, F., Cassani, G. and Günther, F. (2025). Large language models in psycholinguistic studies.
- Harnad, S. (1990). The symbol grounding problem, *Physica D: Nonlinear Phenomena* **42**(1-3): 335–346.
- Hauk, O., Johnsrude, I. and Pulvermüller, F. (2004). Somatotopic representation of action words in human motor and premotor cortex, *Neuron* **41**(2): 301–307.
- Hauser, M. D., Chomsky, N. and Fitch, W. T. (2002). The faculty of language: what is it, who has it, and how did it evolve?, *science* **298**(5598): 1569–1579.
- Horvat, A. W., Bolognesi, M. and Lahiri, A. (2021). Processing of literal and metaphorical meanings in polysemous verbs: An experiment and its methodological implications, *Journal of Pragmatics* **171**: 131–146.
- Hussain, Z., Binz, M., Mata, R. and Wulff, D. U. (2024). A tutorial on open-source large language models for behavioral science, *Behavior Research Methods* **56**(8): 8214–8237.
- Ichien, N., Stamenković, D. and Holyoak, K. J. (2024). Large language model displays emergent ability to interpret novel literary metaphors, *Metaphor and Symbol* **39**(4): 296–309.
- Jones, C. R., Chang, T. A., Coulson, S., Michaelov, J. A., Trott, S. and Bergen, B. (2022). Distrubutional semantics still can't account for affordances, *Proceedings of the annual meeting of the cognitive science society*, Vol. 44.
- Jones, C. R. and Trott, S. (2024). Multimodal language models show evidence of embodied simulation, *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 11928–11933.
- Jurafsky, D. and Martin, J. H. (2026). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*, 3rd edn. Online manuscript released January 6, 2026.
URL: <https://web.stanford.edu/~jurafsky/slp3/>

- Katz, A. N., Paivio, A., Marschark, M. and Clark, J. M. (1988). Norms for 204 literary and 260 nonliterary metaphors on 10 psychological dimensions, *Metaphor and Symbol* **3**(4): 191–214.
- Kosinski, M. (2024). Evaluating large language models in theory of mind tasks, *Proceedings of the National Academy of Sciences* **121**(45): e2405460121.
- Krenker, A., Bešter, J. and Kos, A. (2011). Introduction to the artificial neural networks, *Artificial Neural Networks: Methodological Advances and Biomedical Applications. InTech* pp. 1–18.
- Lakoff, G. (1993). The contemporary theory of metaphor, in A. Ortony (ed.), *Metaphor and Thought*, Cambridge University Press, pp. 202–251.
- Lakoff, G. (2008). The neural theory of metaphor, *The Cambridge Handbook of Metaphor and Thought* pp. 17–38.
- Lakoff, G. and Johnson, M. (1998). *Metafora e vita quotidiana*, Bompiani, Milano. Traduzione italiana di *Metaphors We Live By* (Chicago: University of Chicago Press, 1980).
- Lakoff, G. and Johnson, M. (1999). *Philosophy in the Flesh: The Embodied Mind and its Challenge to Western Thought*, Basic Books, New York.
- Lakoff, G. and Turner, M. (1989). *More than Cool Reason: A Field Guide to Poetic Metaphor*, University of Chicago Press, Chicago.
- Lee, J., Park, D., Lee, J., Choi, H. and Lee, S.-E. (2025). Exploring multimodal perception in large language models through perceptual strength ratings, *arXiv preprint arXiv:2503.06980*.
- Lynott, D., Connell, L., Brysbaert, M., Brand, J. and Carney, J. (2020). The lancaster sensorimotor norms: multidimensional measures of perceptual and action strength for 40,000 english words, *Behavior research methods* **52**(3): 1271–1291.
- Mangiaterra, V., Al-Azary, H., Pietro, C. B. d. S., Canal, P. and Bambini, V. (2025). Can gpt replace human raters? validity and reliability of machine-generated norms for metaphors, *arXiv preprint arXiv:2512.12444*.
- Mangiaterra, V., Barattieri Di San Pietro, C., Frau, F., Bambini, V. and Al-Azary, H. (2025). On choosing the vehicles of metaphors without a body: evidence from large language models, *Proceedings of the 2nd Workshop on Analogical Abstraction in Cognition, Perception, and Language (Analogy-Angle II)*(eds. G. Rambelli, F. Ilievski, M. Bolognesi & P. Sommerauer), pp. 37–44.
- Mikolov, T., Chen, K., Corrado, G. and Dean, J. (2013). Efficient estimation of word representations in vector space, *arXiv preprint arXiv:1301.3781*.

- Moro, A., Greco, M. and Cappa, S. F. (2023). Large languages, impossible languages and human brains, *Cortex* **167**: 82–85.
- Oh, B.-D. and Schuler, W. (2023). Transformer-based language model surprisal predicts human reading times best with about two billion training tokens, *arXiv preprint arXiv:2304.11389* .
- Osgood, C. E. (2018). The cognitive dynamics of synesthesia and metaphor, *Cognition and figurative language*, Routledge, pp. 203–238.
- Pavlick, E. (2023). Symbols and grounding in large language models, *Philosophical Transactions of the Royal Society A* **381**(2251): 20220041.
- Puccetti, G., Esuli, A. and Bolognesi, M. (2025). Wordnet and word ladders: Climbing the abstraction taxonomy with llms, *Proceedings of the 13th Global Wordnet Conference*, pp. 51–65.
- Putnam, H. (1981). *Reason, truth and history*, Vol. 3, Cambridge University Press.
- Ravelli, A. A. and Bolognesi, M. M. (2024). Yet another approximation of human semantic judgments using llms... but with quantized local models on novel data, *IJCoL. Italian Journal of Computational Linguistics* **10**(10-2).
- Schröder, S., Morgenroth, T., Kuhl, U., Vaquet, V. and Paaßen, B. (2025). Large language models do not simulate human psychology, *arXiv preprint arXiv:2508.06950* .
- Searle, J. R. (1979). Metaphor, in A. Ortony (ed.), *Metaphor and Thought*, Cambridge University Press, Cambridge, pp. 92–123.
- Searle, J. R. (1980). Minds, brains, and programs, *Behavioral and brain sciences* **3**(3): 417–424.
- Shani, C., Soffer, L., Jurafsky, D., LeCun, Y. and Shwartz-Ziv, R. (2025). From tokens to thoughts: How llms and humans trade compression for meaning, *arXiv preprint arXiv:2505.17117* .
- Skrynnikova, I. V. (2024). Interpreting metaphorical language: A challenge to artificial intelligence, *Вестник Волгоградского государственного университета. Серия 2: Языкознание* **23**(5): 99–107.
- Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S. et al. (2023). Llama 2: Open foundation and fine-tuned chat models, *arXiv preprint arXiv:2307.09288* .
- Trott, S. (2024). Can large language models help augment english psycholinguistic datasets?, *Behavior Research Methods* **56**(6): 6082–6100.

- Turing, A. M. (1969). Intelligent machinery, in B. Meltzer and D. Michie (eds), *Machine Intelligence 5*, Edinburgh University Press, Edinburgh, pp. 3–23. Rapporto del 1948, ripubblicato in questo volume.
- Turing, A. and Marconi, D. (2025). *Macchine calcolatrici e intelligenza*, Einaudi.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. and Polosukhin, I. (2017). Attention is all you need, *Advances in neural information processing systems* **30**.
- Vincent-Lamarre, P., Massé, A. B., Lopes, M., Lord, M., Marcotte, O. and Harnad, S. (2016). The latent structure of dictionaries, *Topics in cognitive science* **8**(3): 625–659.
- Vitale, F., Padrón, I., Avenanti, A. and De Vega, M. (2021). Enhancing motor brain activity improves memory for action language: A tdcS study, *Cerebral Cortex* **31**(3): 1569–1581.
- von Uexküll, J., Kriszat, G. and Mazzeo, M. (2013). *Ambienti animali e ambienti umani: una passeggiata in mondi sconosciuti e invisibili*, Quodlibet.
- Wang, T., Roberts, A., Hesslow, D., Le Scao, T., Chung, H. W., Beltagy, I., Launay, J. and Raffel, C. (2022). What language model architecture and pretraining objective works best for zero-shot generalization?, *International Conference on Machine Learning*, PMLR, pp. 22964–22984.
- Wicke, P. (2023). Lms stand their ground: Investigating the effect of embodiment in figurative language interpretation by language models, *arXiv preprint arXiv:2305.03445*.
- Wilson, M. (2002). Six views of embodied cognition, *Psychonomic bulletin & review* **9**(4): 625–636.
- Zhang, S., Dong, L., Li, X., Zhang, S., Sun, X., Wang, S., Li, J., Hu, R., Zhang, T., Wang, G. et al. (2026). Instruction tuning for large language models: A survey, *ACM Computing Surveys* **58**(7): 1–36.
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z. et al. (2023). A survey of large language models, *arXiv preprint arXiv:2303.18223* **1**(2).
- Zhong, Y., Todd, S., Xu, N. and Brehm, L. (2025). Evaluating llms as proxies for humans in psycholinguistic ratings: A comparison of statistical knowledge, *Research Methods in Applied Linguistics* **4**(3): 100274.
- Zipoli Caiani, S. (2016). *Corporeità e cognizione. La Filosofia della mente incorporata*, Mondadori Education spa.